


1. AI System 개발(예. 고객센터 챗봇) 음성인식(TTS, STT) text 채팅


언어모델 기존LLM + 만들어야. (Text 학습)

상품에 따라 상담내용 상이
범용언어모델+특화언어모델
(인사 등) (상품 내용)

CHAPTER 03



언어모델 개발
- 회사 상품 관련
Text, 상담 내용(문답)
등 Text 수집



머신러닝은 데이터 가공/변환, 모델 학습/예측, 그리고 평가(Evaluation)의 프로세스로 구성됩니다. 앞 장의 타이타닉 생존자 예제에서는 모델 예측 성능의 평가를 위해 정확도(Accuracy)를 이용했습니다. 머신러닝 모델은 여러 가지 방법으로 예측 성능을 평가할 수 있습니다. 성능 평가 지표(Evaluation Metric)는 일반적으로 모델이 분류나 회귀냐에 따라 여러 종류로 나뉩니다. 회귀의 경우 대부분 실제 값과 예측값의 오차 평균값에 기반합니다. 예를 들어 오차에 절댓값을 씌운 뒤 평균 오차를 구하거나 오차의 제곱 값에 루트를 씌운 뒤 평균 오차를 구하는 방법과 같이 기본적으로 예측 오차를 가지고 정규화 수준을 재가공하는 방법이 회귀의 성능 평가 지표 유형입니다. 회귀를 위한 평가는 그렇게 복잡하지 않으므로 5장의 회귀 장에서 다시 상세하게 설명합니다.

데이터는 문제와 답 포함. 원래 답(Label) 예측값


분류의 평가방법도 일반적으로는 실제 결과 데이터와 예측 결과 데이터가 얼마나 정확하고 오류가 적게 발생하는가에 기반하지만, 단순히 이러한 정확도만 가지고 판단했다가는 잘못된 평가 결과에 빠질 수 있습니다. 본 장에서는 분류에 사용되는 성능 평가 지표에 대해서 자세히 알아보겠습니다. 특히 0과 1로 결정값이 한정되는 이진 분류의 성능 평가 지표에 대해서 집중적으로 설명하겠습니다. 0이나 1이냐 혹은 긍정/부정을 판단하는 이진 분류에서는 정확도보다는 다른 성능 평가 지표가 더 중요시되는 경우가 많습니다.

먼저 분류의 성능 평가 지표부터 살펴보겠습니다.

평가지표

- 지도 - 분류 - 회귀
- 비지도 - 실루엣

- 정확도(Accuracy)
- 오차행렬(Confusion Matrix)



데이터 불균형? -Yes : 정확도 -> 정밀도&재현율, Auc+F1
- No: 정확도 -> Auc + F1

값이 더 클수록 예측값이 더 잘 나옴.(최하가 0.5)
정확도가 왜 떨어졌는지 확인이 가능.(실무적 입장에서 원하는 시선?)

분류는 결정 클래스 값 종류의 유형에 따라 긍정/부정과 같은 2개의 결괏값만을 가지는 이진 분류와 여러 개의 결정 클래스 값을 가지는 멀티 분류로 나눌 수 있습니다. 위에서 언급한 분류의 성능 지표는 이진/멀티 분류 모두에 적용되는 지표이지만, 특히 이진 분류에서 더욱 중요하게 강조하는 지표입니다. 다음 절에서 왜 이 지표가 모두 이진 분류에서 모두 중요한지 설명합니다.

01 정확도(Accuracy)

정확도는 실제 데이터에서 예측 데이터가 얼마나 같은지를 판단하는 지표입니다.

$$\text{정확도(Accuracy)} = \frac{\text{예측 결과가 동일한 데이터 건수}}{\text{전체 예측 데이터 건수}}$$

정확도 - 높 : 과대적합 먼저 확인 후 다른 평가지표 보기
- 낮 : 과소적합 다른 평가지표 필요x.
정확도만 보면 안 됨.

분류만. 우선적으로 봐야..?

정확도는 직관적으로 모델 예측 성능을 나타내는 평가 지표입니다. 하지만 이진 분류의 경우 데이터의 구성에 따라 ML 모델의 성능을 왜곡할 수 있기 때문에 정확도 수치 하나만 가지고 성능을 평가하지 않습니다. 정확도 지표가 어떻게 ML 모델의 성능을 왜곡하는지 예제로 살펴보겠습니다.

앞의 타이타닉 예제 수행 결과를 보면 한 가지 의구심이 생깁니다. ML 알고리즘을 적용한 후 예측 정확도의 결과가 보통 80%대였지만, 탑승객이 남자인 경우보다 여자인 경우에 생존 확률이 높았기 때문에 별다른 알고리즘의 적용 없이 무조건 성별이 여자인 경우 생존으로, 남자인 경우 사망으로 예측 결과를 예측해도 이와 비슷한 수치가 나올 수 있습니다. 단지 성별 조건 하나만을 가지고 결정하는 별거 아닌 알고리즘도 높은 정확도를 나타내는 상황이 발생하는 것입니다.

다음 예제에서는 사이킷런의 BaseEstimator 클래스를 상속받아 아무런 학습을 하지 않고, 성별에 따라 생존자를 예측하는 단순한 Classifier를 생성합니다. 사이킷런은 BaseEstimator를 상속받으면 Customized 형태의 Estimator를 개발자가 생성할 수 있습니다. 생성할 MyDummyClassifier 클래스는 학습을 수행하는 fit() 메서드는 아무것도 수행하지 않으며 예측을 수행하는 predict() 메서드는

단순히 Sex 피처가 1이면 0, 그렇지 않으면 1로 예측하는 매우 단순한 Classifier입니다. 새로운 주피터 노트북을 생성하고 다음 코드를 입력해 보겠습니다.

```
from sklearn.base import BaseEstimator

class MyDummyClassifier(BaseEstimator):
    # fit( ) 메서드는 아무것도 학습하지 않음.
    def fit(self, X, y=None):
        pass
    # predict( ) 메서드는 단순히 Sex 피처가 1이면 0, 그렇지 않으면 1로 예측함.
    def predict(self, X):
        pred = np.zeros( ( X.shape[0], 1))
        for i in range (X.shape[0]) :
            if X['Sex'].iloc[i] == 1:
                pred[i] = 0
            else :
                pred[i] = 1

        return pred
```

이제 생성된 MyDummyClassifier를 이용해 앞 장의 타이타닉 생존자 예측을 수행해 보겠습니다. 타이타닉 데이터인 titanic_train.csv 파일을 새로운 주피터 노트북을 생성한 디렉터리로 복사해 이동한 뒤, 데이터를 가공하고 나서 이 Classifier를 이용해 학습/예측/평가를 적용해 보겠습니다.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

# 원본 데이터를 재로딩, 데이터 가공, 학습 데이터/테스트 데이터 분할.
titanic_df = pd.read_csv('./titanic_train.csv')
y_titanic_df = titanic_df['Survived']
X_titanic_df = titanic_df.drop('Survived', axis=1)
X_titanic_df = transform_features(X_titanic_df)
X_train, X_test, y_train, y_test = train_test_split(X_titanic_df, y_titanic_df,
                                                    test_size=0.2, random_state=0)

# 위에서 생성한 Dummy Classifier를 이용해 학습/예측/평가 수행.
```

대출 사기, 불량 검출 등

98건 정상대출

(사건x)

2건 사기(사건o)

0.98 : 0.02 = 불균형한 Label 분포

```
myclf = MyDummyClassifier()
```

```
myclf.fit(X_train, y_train)
```

이건 모델(학습 안 시켜도) 안 만들어도

98%는 정답.

```
mypredictions = myclf.predict(X_test)
```

```
print('Dummy Classifier의 정확도는: {0:.4f}'.format(accuracy_score(y_test, mypredictions)))
```

[Output]

Dummy Classifier의 정확도는: 0.7877

따져볼 게 많음. 과적합 여부 확인 & 다른 지표 확인.

이렇게 단순한 알고리즘으로 예측을 하더라도 데이터의 구성에 따라 정확도 결과는 약 78.77%로 꽤 높은 수치가 나올 수 있기에 정확도를 평가 지표로 사용할 때는 매우 신중해야 합니다. 특히 정확도는 불균형한(imbalanced) 레이블 값 분포에서 ML 모델의 성능을 판단할 경우, 적합한 평가 지표가 아닙니다. 예를 들어 100개의 데이터가 있고 이 중에 90개의 데이터 레이블이 0, 단 10개의 데이터 레이블이 1이라고 한다면 무조건 0으로 예측 결과를 반환하는 ML 모델의 경우라도 정확도가 90%가 됩니다.

유명한 MNIST 데이터 세트를 변환해 불균형한 데이터 세트로 만든 뒤에 정확도 지표 적용 시 어떤 문제가 발생할 수 있는지 살펴보겠습니다. MNIST 데이터 세트는 0부터 9까지의 숫자 이미지의 픽셀 정보를 가지고 있으며, 이를 기반으로 숫자 Digit를 예측하는 데 사용됩니다. 사이킷런은 load_digits() API를 통해 MNIST 데이터 세트를 제공합니다. 원래 MNIST 데이터 세트는 레이블 값이 0부터 9까지 있는 멀티 레이블 분류를 위한 것입니다. 이것을 레이블 값이 7인 것만 True, 나머지 값은 모두 False로 변환해 이진 분류 문제로 살짝 바꿔 보겠습니다. 즉, 전체 데이터의 10%만 True, 나머지 90%는 False인 불균형한 데이터 세트로 변형하는 것입니다.

MNIST 데이터셋을 multi classification에서 binary classification으로 변경

손글씨
이미지

0	1	2	3	4	label
5	6	7	8	9	



False	False	False	False	False	
False	False	True	False	False	

90%는 7이 아님.
10%만 7
=> 불균형한
레이블 분포

10진 분류 문제

=>

이진 분류(7이니 아니니?)

이렇게 불균형한 데이터 세트에 모든 데이터를 False, 즉 0으로 예측하는 classifier를 이용해 정확도를 측정하면 약 90%에 가까운 예측 정확도를 나타냅니다. 아무것도 하지 않고 무조건 특정한 결과로 찍어

도(?) 데이터 분포도가 균일하지 않은 경우 높은 수치가 나타날 수 있는 것이 정확도 평가 지표의 맹점입니다. 예제 코드로 확인해 보겠습니다. 먼저 불균형한 데이터 세트와 Dummy Classifier를 생성합니다.

```
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from sklearn.base import BaseEstimator
from sklearn.metrics import accuracy_score
import numpy as np
import pandas as pd

class MyFakeClassifier(BaseEstimator):
    def fit(self, X, y):
        pass

    # 입력값으로 들어오는 X 데이터 세트의 크기만큼 모두 0값으로 만들어서 반환
    def predict(self, X):
        return np.zeros( (len(X), 1), dtype=bool)

# 사이킷런의 내장 데이터 세트인 load_digits( )를 이용해 MNIST 데이터 로딩
digits = load_digits()

# digits 번호가 7이면 True이고 이를 astype(int)로 1로 변환, 7번이 아니면 False이고 0으로 변환.
y = (digits.target == 7).astype(int)
X_train, X_test, y_train, y_test = train_test_split( digits.data, y, random_state=11)
```

다음으로 불균형한 데이터로 생성한 y_test의 데이터 분포도를 확인하고 MyFakeClassifier를 이용해 예측과 평가를 수행해 보겠습니다.

```
# 불균형한 레이블 데이터 분포도 확인.
print('레이블 테스트 세트 크기 :', y_test.shape)
print('테스트 세트 레이블 0 과 1의 분포도')
print(pd.Series(y_test).value_counts())

# Dummy Classifier로 학습/예측/정확도 평가
fakeclf = MyFakeClassifier()
fakeclf.fit(X_train, y_train)
```

```
fakepred = fakeclf.predict(X_test)
print('모든 예측을 0으로 하여도 정확도는:{:.3f}'.format(accuracy_score(y_test, fakepred)))
```

[Output]

```
레이블 테스트 세트 크기 : (450, )
테스트 세트 레이블 0 과 1의 분포도
0    405
1     45
dtype: int64
모든 예측을 0으로 하여도 정확도는:0.900
```

단순히 predict()의 결과를 np.zeros()로 모두 0 값으로 반환함에도 불구하고 450개의 테스트 데이터 세트에 수행한 예측 정확도는 90%입니다. 단지 모든 것을 0으로만 예측해도 MyFakeClassifier의 정확도가 90%로 유수의 ML 알고리즘과 어깨를 겨룰 수 있다는 것은 말도 안 되는 결과입니다.

이처럼 정확도 평가 지표는 불균형한 레이블 데이터 세트에서는 성능 수치로 사용돼서는 안 됩니다. 정확도가 가지는 분류 평가 지표로서 이러한 한계점을 극복하기 위해 여러 가지 분류 지표와 함께 적용하여 ML 모델 성능을 평가해야 합니다. 이를 위해, 먼저 True/False, Positive/Negative의 4분면으로 구성되는 오차 행렬(Confusion Matrix)에 대해 설명하겠습니다.

오차

오차

02 오차 행렬

이전 분류에서 성능 지표로 잘 활용되는 오차행렬(confusion matrix, 혼동행렬)은 학습된 분류 모델이 예측을 수행하면서 얼마나 헛갈리고(confused) 있는지도 함께 보여주는 지표입니다. 즉, 이진 분류의 예측 오류가 얼마인지와 더불어 어떠한 유형의 예측 오류가 발생하고 있는지를 함께 나타내는 지표입니다.


오차 행렬은 다음과 같은 4분면 행렬에서 실제 레이블 클래스 값과 예측 레이블 클래스 값이 어떠한 유형을 가지고 매핑되는지를 나타냅니다. 4분면의 왼쪽, 오른쪽을 예측된 클래스 값 기준으로 Negative와 Positive로 분류하고, 4분면의 위, 아래를 실제 클래스 값 기준으로 Negative와 Positive로 분류하면 예측 클래스와 실제 클래스의 값 유형에 따라 결정되는 TN, FP, FN, TP 형태로 오차 행렬의 4분면을 채울 수 있습니다. TN, FP, FN, TP 값을 다양하게 결합해 분류 모델 예측 성능의 오류가 어떠한 모습으로 발생하는지 알 수 있는 것입니다.

		예측 클래스 (Predicted Class)	
		예측값 0 Negative(0)	예측값 1 Positive(1)
실제 클래스 (Actual Class)	실제 답 0 Negative(0)	TN (True Negative) 답 0인데 0으로 예측	FP (False Positive) Positive 가 틀렸다.(1로 예측한 것이 틀렸다.)
	실제 답 1 Positive(1)	FN (False Negative) 0으로 예측한 것이 틀렸다.	TP (True Positive) 답 1인데 1로 예측

TN, FP, FN, TP는 예측 클래스와 실제 클래스의 Positive 결정 값(값 1)과 Negative 결정 값(값 0)의 결합에 따라 결정됩니다. 예를 들어 TN은 True Negative의 의미이며 앞 True는 예측 클래스 값과 실제 클래스 값이 같다는 의미고 뒤의 Negative는 예측값이 Negative 값이라는 의미입니다. 즉, TN은 예측을 Negative 값 0으로 예측했는데, 실제 값도 Negative 값 0이라는 의미입니다. TN, FP, FN, TP 기호가 의미하는 것은 앞 문자 True/False는 예측값과 실제값이 '같은가/틀린가'를 의미합니다. 뒤 문자 Negative/Positive는 예측 결과 값이 부정(0)/긍정(1)을 의미합니다.

- TN는 예측값을 Negative 값 0으로 예측했고 실제 값 역시 Negative 값 0
- FP는 예측값을 Positive 값 1로 예측했는데 실제 값은 Negative 값 0
- FN은 예측값을 Negative 값 0으로 예측했는데 실제 값은 Positive 값 1
- TP는 예측값을 Positive 값 1로 예측했는데 실제 값 역시 Positive 값 1

다음 그림은 TN, FP, FN, TP 구분을 재미있게 표현해서 발췌했습니다. 이해하는 데 도움이 됐으면 합니다.



출처: <https://twitter.com/bearda24>

사이킷런은 오차 행렬을 구하기 위해 `confusion_matrix()` API를 제공합니다. 정확도 예제에서 다른 `MyFakeClassifier`의 예측 성능 지표를 오차 행렬로 표현해 보겠습니다. 앞 절에서 사용한 주피터 노트북에서 코드를 입력하겠습니다. `MyFakeClassifier`의 예측 결과인 `fakepred`와 실제 결과인 `y_test`를 `confusion_matrix()`의 인자로 입력해 오차 행렬을 `confusion_matrix()`를 이용해 배열 형태로 출력합니다.

```
from sklearn.metrics import confusion_matrix
```

```
confusion_matrix(y_test, fakepred)
실제답  예측값
```

[Output]

array([[405, 0],	TN: 예측0, 실제0 = 405개	예측 기준으로 읽기.
[45, 0]], dtype=int64)	FP: 예측1, 실제0 = 0개 오류	
FN TP	FN: 예측0, 실제1 = 45개 오류	
	TP: 예측1, 실제1 = 0개	

출력된 오차 행렬은 `ndarray` 형태입니다. 이진 분류의 TN, FP, FN, TP는 상단 도표와 동일한 위치를 가지고 array에서 가져올 수 있습니다. 즉, TN은 `array[0,0]`로 405, FP는 `array[0,1]`로 0, FN은 `array[1,0]`로 45, TP는 `array[1,1]`로 0에 해당합니다. 앞 절의 `MyFakeClassifier`는 `load_digits()`에서 `target == 7`인지 아닌지에 따라 클래스 값을 True/False 이진 분류로 변경한 데이터 세트를 사용해 무조건 Negative로 예측하는 Classifier였고 테스트 데이터 세트의 클래스 값 분포는 0이 405건, 1이 45건입니다.

따라서 TN은 전체 450건 데이터 중 무조건 Negative 0으로 예측해서 True가 된 결과 405건, FP는 Positive 1로 예측한 건수가 없으므로 0건, FN은 Positive 1인 건수 45건을 Negative로 예측해서 False가 된 결과 45건, TP는 Positive 1로 예측한 건수가 없으므로 0건입니다.

		예측 클래스	
		Negative	Positive
실제 클래스	Negative	TN 예측: Negative(70이 아닌 Digit) 405개 실제: Negative(70이 아닌 Digit)	FP 예측: Positive(Digit 7) 0 실제: Negative(70이 아닌 Digit)
	Positive	FN 예측: Negative(70이 아닌 Digit) 45개 실제: Positive(Digit 7)	TP 실제: Positive(Digit 7) 0 실제: Positive(Digit 7)

TP, TN, FP, FN 값은 Classifier 성능의 여러 면모를 판단할 수 있는 기반 정보를 제공합니다. 이 값을 조합해 Classifier의 성능을 측정할 수 있는 주요 지표인 정확도(Accuracy), 정밀도(Precision), 재현율(Recall) 값을 알 수 있습니다.

앞에서도 소개한 정확도는 예측값과 실제 값이 얼마나 동일한가에 대한 비율만으로 결정됩니다. 즉, 오차 행렬에서 True에 해당하는 값인 TN과 TP에 좌우됩니다. 정확도는 오차 행렬상에서 다음과 같이 재정의될 수 있습니다.

정확도 = 예측 결과와 실제 값이 동일한 건수/전체 데이터 수 = $(TN + TP) / (TN + FP + FN + TP)$

레이블: 9:1 => 불균형 레이블.

찾아야 하는 적은 수 Positive
암기. 많은 수 Negative



관례적.

일반적으로 이러한 불균형한 레이블 클래스를 가지는 이진 분류 모델에서는 많은 데이터 중에서 중점적으로 찾아야 하는 매우 적은 수의 결핍값에 Positive를 설정해 1값을 부여하고, 그렇지 않은 경우는 Negative로 0 값을 부여하는 경우가 많습니다. 예를 들어 사기 행위 예측 모델에서는 사기 행위가 Positive 양성으로 1, 정상 행위가 Negative 음성으로 0 값이 결정 값으로 할당되거나 암 검진 예측 모델에서는 암이 양성일 경우 Positive 양성으로 1, 암이 음성일 경우 Negative 음성으로 0 값이 할당되는 경우가 일반적입니다.

불균형한 이진 분류 데이터 세트에서는 Positive 데이터 건수가 매우 작기 때문에 데이터에 기반한 ML 알고리즘은 Positive보다는 Negative로 예측 정확도가 높아지는 경향이 발생합니다. 10,000건의 데이

터 세트에서 9,900건이 Negative이고 100건이 Positive라면 Negative로 예측하는 경향이 더 강해져서 TN은 매우 커지고 TP는 매우 작아지게 됩니다. 또한 Negative로 예측할 때 정확도가 높기 때문에 FN(Negative로 예측할 때 틀린 데이터 수)이 매우 작고, Positive로 예측하는 경우가 작기 때문에 FP 역시 매우 작아집니다. 결과적으로 정확도 지표는 비대칭한 데이터 세트에서 Positive에 대한 예측 정확도를 판단하지 못한 채 Negative에 대한 예측 정확도만으로도 분류의 정확도가 매우 높게 나타나는 수치적인 판단 오류를 일으키게 됩니다.

정확도는 분류(Classification) 모델의 성능을 측정할 수 있는 한 가지 요소일 뿐입니다. 불균형한 데이터 세트에서 정확도만으로는 모델 신뢰도가 떨어질 수 있는 사례를 봤습니다. 다음으로 불균형한 데이터 세트에서 정확도보다 더 선호되는 평가 지표인 정밀도(Precision)와 재현율(Recall)에 대해 알아보겠습니다.

반드시 확인 필요

매우 적은 레이블 예측 성능을 평가

03 정밀도와 재현율

레이블 기준
정밀도와 재현율은 Positive 데이터 세트의 예측 성능에 좀 더 초점을 맞춘 평가 지표입니다. 앞서 만든 MyFakeClassifier는 Positive로 예측한 TP 값이 하나도 없기 때문에 정밀도와 재현율 값이 모두 0입니다

TP가 0이면 정밀도, 재현율 0
정밀도와 재현율은 다음과 같은 공식으로 계산됩니다.
얼마나 정밀하게 예측

예측 기준 $\text{정밀도} = \text{TP} / (\text{FP} + \text{TP})$ max 1이 되려면 fp=0이어야.
실제 기준 $\text{재현율} = \text{TP} / (\text{FN} + \text{TP})$ max 1이 되려면 fn=0이어야.

		예측	
		N	P
실제	N	TN	FP
	P	FN	TP
		재현율	

얼마나 실제로 재현
FP 따져보기 정밀도 는 예측을 Positive로 한 대상 중에 예측과 실제 값이 Positive로 일치한 데이터의 비율을 뜻합니다. 공식의 분모인 FP + TP는 예측을 Positive로 한 모든 데이터 건수이며, 공식의 분자인 TP는 예측과 실제 값이 Positive로 일치한 데이터 건수입니다. Positive 예측 성능을 더욱 정밀하게 측정하기 위한 평가 지표로 양성 예측도라고도 불립니다.

FN 따져보기 재현율 은 실제 값이 Positive인 대상 중에 예측과 실제 값이 Positive로 일치한 데이터의 비율을 뜻합니다. 공식의 분모인 FN + TP는 실제 값이 Positive인 모든 데이터 건수이며 공식의 분자인 TP는 예측과 실제 값이 Positive로 일치한 데이터 건수입니다. 민감도(Sensitivity) 또는 TPR(True Positive Rate)라고도 불립니다.



스팸메일 잡느라 일반(중요)메일까지 들어갈 수 있음.(재현율)
스팸메일 덜 잡더라도 일반메일 안 들어가도록(정밀도)
positive

정밀도와 재현율 지표 중에 이진 분류 모델의 업무 특성에 따라서 특정 평가 지표가 더 중요한 지표로 간주될 수 있습니다. 재현율이 중요 지표인 경우는 실제 Positive 양성 데이터를 Negative로 잘못 판단하게 되면 업무상 큰 영향이 발생하는 경우입니다. 예를 들어 암 판단 모델은 재현율이 훨씬 중요한 지표입니다. 왜냐하면 실제 Positive인 암 환자를 Positive 양성인 Negative 음성으로 잘못 판단했을 경우 오류의 대가가 생명을 앗아갈 정도로 심각하기 때문입니다. 반면에 실제 Negative인 건강한 환자를 암 환자인 Positive로 예측한 경우면 다시 한번 재검사를 하는 수준의 비용이 소모될 것입니다.

보험 사기와 같은 금융 사기 적발 모델도 재현율이 중요합니다. 실제 금융거래 사기인 Positive 건을 Negative로 잘못 판단하게 되면 회사에 미치는 손해가 클 것입니다. 반면에 정상 금융거래인 Negative를 금융사기인 Positive로 잘못 판단하더라도 다시 한번 금융 사기인지 재확인하는 절차를 가동하면 됩니다. 물론 고객에게 금융 사기 혐의를 잘못 씌우면 문제가 될 수 있기에 정밀도도 중요 평가 지표지만, 업무적인 특성을 고려하면 재현율이 상대적으로 더 중요한 지표입니다.

보통은 재현율이 정밀도보다 상대적으로 중요한 업무가 많지만, 정밀도가 더 중요한 지표인 경우도 있습니다. 예를 들어 스팸메일 여부를 판단하는 모델의 경우 실제 Positive인 스팸 메일을 Negative인 일반 메일로 분류하더라도 사용자가 불편함을 느끼는 정도이지만, 실제 Negative인 일반 메일을 Positive인 스팸 메일로 분류할 경우에는 메일을 아예 받지 못하게 돼 업무에 차질이 생깁니다.

- 재현율이 상대적으로 더 중요한 지표인 경우는 실제 Positive 양성인 데이터 예측을 Negative로 잘못 판단하게 되면 업무상 큰 영향이 발생하는 경우
- 정밀도가 상대적으로 더 중요한 지표인 경우는 실제 Negative 음성인 데이터 예측을 Positive 양성으로 잘못 판단하게 되면 업무상 큰 영향이 발생하는 경우

다시 한번 재현율과 정밀도의 공식을 살펴보면, $\text{재현율} = \text{TP} / (\text{FN} + \text{TP})$, $\text{정밀도} = \text{TP} / (\text{FP} + \text{TP})$ 입니다. 재현율과 정밀도 모두 TP를 높이는 데 동일하게 초점을 맞추지만, 재현율은 FN(실제 Positive, 예측 Negative)를 낮추는 데, 정밀도는 FP를 낮추는 데 초점을 맞춥니다. 이 같은 특성 때문에 재현율과 정밀도는 서로 보완적인 지표로 분류의 성능을 평가하는 데 적용됩니다. 가장 좋은 성능 평가는 재현율과 정밀도 모두 높은 수치를 얻는 것입니다. 반면에 둘 중 어느 한 평가 지표만 매우 높고, 다른 수치는 매우 낮은 결과를 나타내는 경우는 바람직하지 않습니다.

앞의 타이타닉 예제에서는 정확도에만 초점을 맞췄지만, 이번에 오차 행렬 및 정밀도, 재현율을 모두 구해서 예측 성능을 평가해 보겠습니다. 사이킷런은 정밀도 계산을 위해 `precision_score()`를, 재현율 계산을 위해 `recall_score()`를 API로 제공합니다. 평가를 간편하게 적용하기 위해서 confusion

matrix, accuracy, precision, recall 등의 평가를 한꺼번에 호출하는 `get_clf_eval()` 함수를 만들도록 하겠습니다. 그리고 이후에 타이타닉 데이터를 다시 로드한 후 가공해 로지스틱 회귀로 분류를 수행하겠습니다. 생존(T,F) 이진분류

앞 절에서 사용한 주피터 노트북에 계속 이어서 코드를 작성하겠습니다. 먼저 `get_clf_eval()` 함수는 다음과 같습니다.

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, confusion_matrix

def get_clf_eval(y_test, pred):
    confusion = confusion_matrix(y_test, pred)
    accuracy = accuracy_score(y_test, pred)
    precision = precision_score(y_test, pred)
    recall = recall_score(y_test, pred)
    print('오차 행렬')
    print(confusion)
    print('정확도: {0:.4f}, 정밀도: {1:.4f}, 재현율: {2:.4f}'.format(accuracy, precision, recall))
```

이제 로지스틱 회귀 기반으로 타이타닉 생존자를 예측하고 confusion matrix, accuracy, precision, recall 평가를 수행합니다. LogisticRegression 객체의 생성 인자로 입력되는 `solver='liblinear'`는 로지스틱 회귀의 최적화 알고리즘 유형을 지정하는 것입니다. 보통 작은 데이터 세트의 이진 분류인 경우 `solver`는 `liblinear`가 약간 성능이 좋은 경향이 있습니다. `solver`의 기본값은 `lbfgs`이며 데이터 세트가 상대적으로 크고 다중 분류인 경우 적합합니다.


```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression

# 원본 데이터를 재로딩, 데이터 가공, 학습 데이터/테스트 데이터 분할.
titanic_df = pd.read_csv('./titanic_train.csv')
y_titanic_df = titanic_df['Survived']
X_titanic_df = titanic_df.drop('Survived', axis=1)
X_titanic_df = transform_features(X_titanic_df)

X_train, X_test, y_train, y_test = train_test_split(X_titanic_df, y_titanic_df,
                                                    test_size=0.20, random_state=11)

lr_clf = LogisticRegression(solver='liblinear')


lr_clf.fit(X_train, y_train)
```

```
pred = lr_clf.predict(X_test)
get_clf_eval(y_test, pred)
```

[Output]

```
오차 행렬
[[104 14]
 [ 13 48]]
정확도: 0.8492, 정밀도: 0.7742, 재현율: 0.7869
```



정밀도/재현율 트레이드오프

분류하려는 업무의 특성상 정밀도 또는 재현율이 특별히 강조돼야 할 경우 **분류의 결정 임계값 (Threshold)**을 조정해 정밀도 또는 재현율의 수치를 높일 수 있습니다. 하지만 정밀도와 재현율은 상호 보완적인 평가 지표이기 때문에 어느 한쪽을 강제로 높이면 다른 하나의 수치는 떨어지기 쉽습니다. 이를 **정밀도/재현율의 트레이드오프(Trade-off)**라고 부릅니다.

사이킷런의 분류 알고리즘은 **예측 데이터가 특정 레이블(Label, 결정 클래스 값)에 속하는지를 계산하기 위해 먼저 개별 레이블별로 결정 확률을 구합니다.** 그리고 **예측 확률이 큰 레이블값으로 예측하게 됩니다.** 가령 이진 분류 모델에서 특정 데이터가 **0이 될 확률이 10%, 1이 될 확률이 90%**로 예측됐다면 최종 예측은 더 큰 확률을 가진, 즉 **90% 확률을 가진 1로 예측합니다.** 일반적으로 이진 분류에서는 이 임계값을 0.5, 즉 **50%로 정하고 이 기준 값보다 확률이 크면 Positive, 작으면 Negative로 결정합니다.**

퍼센테이지 수정하면 FP, FN 수치 비율 조정 가능

사이킷런은 개별 데이터별로 예측 확률을 반환하는 메서드인 `predict_proba()`를 제공합니다. `predict_proba()` 메서드는 학습이 완료된 사이킷런 Classifier 객체에서 호출이 가능하며 테스트 피쳐 데이터 세트를 파라미터로 입력해주면 테스트 피쳐 레코드의 개별 클래스 예측 확률을 반환합니다. `predict()` 메서드와 유사하지만 단지 반환 결과가 예측 결과 클래스값이 아닌 예측 확률 결과입니다.

입력 파라미터	테스트 데이터 들어가야. <code>predict()</code> 메서드와 동일하게 보통 테스트 피쳐 데이터 세트를 입력
반환 값	개별 클래스의 예측 확률을 ndarray m x n (m: 입력값의 레코드 수, n: 클래스 값 유형) 형태로 반환. 입력 테스트 데이터 세트의 표본 개수가 100개이고 예측 클래스 값 유형이 2개(이진 분류)라면 반환 값은 100 x 2 ndarray임. 각 열은 개별 클래스의 예측 확률입니다. 이진 분류에서 첫 번째 칼럼은 0 Negative의 확률, 두 번째 칼럼은 1 Positive의 확률입니다.

이진 분류에서 `predict_proba()`를 수행해 반환되는 `ndarray`는 첫 번째 칼럼이 클래스 값 0에 대한 예측 확률, 두 번째 칼럼이 클래스 값 1에 대한 예측 확률입니다. 바로 앞 예제의 타이타닉 생존자 데이터를 학습한 `LogisticRegression` 객체에서 `predict_proba()` 메서드를 수행한 뒤 반환 값을 확인하고, `predict()` 메서드의 결과와 비교해 보겠습니다. 앞 절에서 사용한 주피터 노트북에 계속 이어서 코드를 작성합니다.

```
pred_proba = lr_clf.predict_proba(X_test)  # 예측확률
pred = lr_clf.predict(X_test)  # 예측값
print('pred_proba()결과 Shape : {0}'.format(pred_proba.shape))
print('pred_proba array에서 앞 3개만 샘플로 추출 \n:', pred_proba[:3])

# 예측 확률 array와 예측 결과값 array를 병합(concatenate)해 예측 확률과 결과값을 한눈에 확인
pred_proba_result = np.concatenate([pred_proba, pred.reshape(-1, 1)], axis=1)
print('두 개의 class 중에서 더 큰 확률을 클래스 값으로 예측 \n', pred_proba_result[:3])
```

【Output】

```
pred_proba()결과 Shape : (179, 2)
pred_proba array에서 앞 3개만 샘플로 추출
: [[0.44935227 0.55064773]
   [0.86335512 0.13664488]
   [0.86429645 0.13570355]]
두 개의 class 중에서 더 큰 확률을 클래스 값으로 예측
[[0.44935227 0.55064773 1.      ]
 [0.86335512 0.13664488 0.      ]
 [0.86429645 0.13570355 0.      ]]
```

반환 결과인 `ndarray`는 0과 1에 대한 확률을 나타내므로 첫 번째 칼럼 값과 두 번째 칼럼 값을 더하면 1이 됩니다. 그리고 맨 마지막 줄의 `predict()` 메서드의 결과 비교에서도 나타나듯이, 두 개의 칼럼 중에서 더 큰 확률 값으로 `predict()` 메서드가 최종 예측하고 있습니다.

사실 `predict()` 메서드는 `predict_proba()` 메서드에 기반해 생성된 API입니다. `predict()`는 `predict_proba()` 호출 결과로 반환된 배열에서 **분류 결정 임계값**보다 큰 값이 들어 있는 칼럼의 위치(첫 번째 칼럼 또는 두 번째 칼럼)를 받아서 최종적으로 예측 클래스를 결정하는 API입니다. 이를 이해하는 것은 사이킷런이 어떻게 정밀도/재현율 트레이드오프를 구현했는지를 이해하는 데 도움을 줍니다. 사이킷런은 **분류 결정 임계값을 조절해 정밀도와 재현율의 성능 수치를 상호 보완적으로 조절할 수** 있습니다.

지금부터 이러한 로직을 직접 코드로 구현하면서 사이킷런의 정밀도/재현율 트레이드오프 방식을 이해해 보겠습니다. 사이킷런의 `predict()`는 `predict_proba()` 메서드가 반환하는 확률 값을 가진 `ndarray`에서 정해진 임계값(바로 앞에서는 0.5였음)을 만족하는 `ndarray`의 칼럼 위치를 최종 예측 클래스로 결정한다고 했습니다. 이러한 구현을 위해 사이킷런의 `Binarizer` 클래스를 이용하겠습니다. 먼저 `Binarizer` 클래스의 사용법부터 간단히 알아보겠습니다.

다음 예제에서는 `threshold` 변수를 특정 값으로 설정하고 `Binarizer` 클래스를 객체로 생성합니다. 생성된 `Binarizer` 객체의 `fit_transform()` 메서드를 이용해 넘파이 `ndarray`를 입력하면 입력된 `ndarray`의 값을 지정된 `threshold`보다 같거나 작으면 0값으로, 크면 1값으로 변환해 반환합니다. 다음 예제를 보면 쉽게 이해할 수 있을 겁니다.

```
from sklearn.preprocessing import Binarizer

X = [[ 1, -1, 2],
      [ 2,  0, 0],
      [ 0, 1.1, 1.2]]

# X의 개별 원소들이 threshold값보다 같거나 작으면 0을, 크면 1을 반환
binarizer = Binarizer(threshold=1.1)
print(binarizer.fit_transform(X))
```

[Output]

```
[[0. 0. 1.]
 [1. 0. 0.]
 [0. 0. 1.]]
```

입력된 X 데이터 세트에서 `Binarizer`의 `threshold` 값이 1.1보다 같거나 작으면 0, 크면 1로 변환됨을 알 수 있습니다. 이제 이 `Binarizer`를 이용해 사이킷런 `predict()`의 의사(pseudo) 코드를 만들어 보겠습니다. 바로 앞 예제의 `LogisticRegression` 객체의 `predict_proba()` 메서드로 구한 각 클래스별 예측 확률값인 `pred_proba` 객체 변수에 분류 결정 임계값(`threshold`)을 0.5로 지정한 `Binarizer` 클래스를 적용해 최종 예측값을 구하는 방식입니다. 이렇게 구한 최종 예측값에 대해 `get_clf_eval()` 함수를 적용해 평가 지표도 출력해 보겠습니다.


```

from sklearn.preprocessing import Binarizer

# Binarizer의 threshold 설정값. 분류 결정 임계값임.
custom_threshold = 0.5

# predict_proba( ) 반환값의 두 번째 칼럼, 즉 Positive 클래스 칼럼 하나만 추출해 Binarizer를 적용
pred_proba_1 = pred_proba[:, 1].reshape(-1, 1)

binarizer = Binarizer(threshold=custom_threshold).fit(pred_proba_1)
custom_predict = binarizer.transform(pred_proba_1)

get_clf_eval(y_test, custom_predict)

```

[Output]

```

오차 행렬
[[108  10]
 [ 14  47]]
정확도: 0.8659, 정밀도: 0.8246, 재현율: 0.7705

```

이 의사 코드로 계산된 평가 지표는 앞 예제의 타이타닉 데이터로 학습된 로지스틱 회귀 Classifier 객체에서 호출된 predict()로 계산된 지표 값과 정확히 같습니다. predict()가 predict_proba()에 기반함을 알 수 있습니다.

만일 이 분류 결정 임계값을 낮추면 평가 지표가 어떻게 변할까요? 임계값을 0.4로 낮춰보겠습니다.

```

# Binarizer의 threshold 설정값을 0.4로 설정. 즉 분류 결정 임계값을 0.5에서 0.4로 낮춤
custom_threshold = 0.4
pred_proba_1 = pred_proba[:, 1].reshape(-1, 1)
binarizer = Binarizer(threshold=custom_threshold).fit(pred_proba_1)
custom_predict = binarizer.transform(pred_proba_1)

get_clf_eval(y_test, custom_predict)

```


[Output]

```

오차 행렬
[[97 21]
 [11 50]]
정확도: 0.8212, 정밀도: 0.7042, 재현율: 0.8197

```


임꺽값을 낮추니 재현율 값이 올라가고 정밀도가 떨어졌습니다. 이유가 뭘까요? 분류 결정 임꺽값은 Positive 예측값을 결정하는 확률의 기준이 됩니다. 확률이 0.5가 아닌 0.4부터 Positive로 예측을 더 너그럽게 하기 때문에 임꺽값 값을 낮출수록 True 값이 많아지게 됩니다. 다음 그림을 보면 이해하기가 쉬울 것 같습니다.



Positive 예측값이 많아지면 상대적으로 재현율 값이 높아집니다. 양성 예측을 많이 하다 보니 실제 양성을 음성으로 예측하는 횟수가 상대적으로 줄어들기 때문입니다.

[임꺽값 0.5일 때 오차 행렬]

TN	FP
108	10
FN	TP
14	47

[임꺽값 0.4일 때 오차 행렬]

TN	FP
97	21
FN	TP
11	50

임꺽값이 0.5에서 0.4로 낮아지면서 TP가 47에서 50으로 늘었고 FN이 14에서 11로 줄었습니다. 그에 따라 재현율이 0.770에서 0.820으로 좋아졌습니다. 하지만 FP는 10에서 21로 늘면서 정밀도가 0.825에서 0.704로 많이 나빠졌습니다. 그리고 정확도도 0.866에서 0.821로 나빠졌습니다.

이번에는 임꺽값을 0.4에서부터 0.6까지 0.05씩 증가시키며 평가 지표를 조사하겠습니다. 이를 위해 `get_eval_by_threshold()` 함수를 만들겠습니다.

```
# 테스트를 수행할 모든 임꺽값을 리스트 객체로 저장.
thresholds = [0.4, 0.45, 0.50, 0.55, 0.60]

def get_eval_by_threshold(y_test, pred_proba_c1, thresholds):
    # thresholds list객체 내의 값을 차례로 iteration하면서 Evaluation 수행.
```

```

for custom_threshold in thresholds:
    binarizer = Binarizer(threshold=custom_threshold).fit(pred_proba_c1)
    custom_predict = binarizer.transform(pred_proba_c1)
    print('임계값:', custom_threshold)
    get_clf_eval(y_test, custom_predict)

get_eval_by_threshold(y_test, pred_proba[:, 1].reshape(-1, 1), thresholds )


```

위 예제의 출력이 조금 길고 보기가 어려울 수 있어 다음과 같이 수행 결과를 임계값에 따른 평가 지표 별로 정리했습니다. 임계값이 0.45일 경우에 디폴트 0.5인 경우와 비교해서 정확도는 동일하고 정밀도는 약간 떨어졌으나 재현율이 올랐습니다. 재현율을 향상시키면서 다른 수치를 어느 정도 감소하는 희생을 해야 한다면 임계값 0.45가 가장 적당해 보입니다.

평가 지표	분류 결정 임계값				
	0.4	0.45	0.5	0.55	0.6
정확도	0.8212	0.8547	0.8659	0.8715	0.8771
정밀도	0.7042	0.7869	0.8246	0.8654	0.8980
재현율	0.8197	0.7869	0.7705	0.7377	0.7213

지금까지 임계값 변화에 따른 평가 지표 값을 알아보는 코드를 작성했습니다. 사이킷런은 이와 유사한 `precision_recall_curve()` API를 제공합니다. `precision_recall_curve()` API의 입력 파라미터와 반환 값은 다음과 같습니다.

입력 파라미터	y_true: 실제 클래스값 배열 (배열 크기= [데이터 건수])
	probas_pred: Positive 칼럼의 예측 확률 배열 (배열 크기= [데이터 건수])
반환 값	정밀도: 임계값별 정밀도 값을 배열로 반환
	재현율: 임계값별 재현율 값을 배열로 반환



`precision_recall_curve()`를 이용해 타이타닉 예측 모델의 임계값별 정밀도와 재현율을 구해 보겠습니다. `precision_recall_curve()`의 인자로 실제 값 데이터 세트와 레이블 값이 1일 때의 예측 확률 값을 입력합니다. 레이블 값이 1일 때의 예측 확률 값은 `predict_proba(X_test)[:, 1]`로 `predict_proba()`의 반환 ndarray의 두 번째 칼럼(즉, 칼럼 인덱스 1)값에 해당하는 데이터 세트입니다. `precision_recall_curve()`는 일반적으로 0.11 ~ 0.95 정도의 임계값을 담은 넘파이 ndarray와 이 임계값에 해당하는 정밀도 및 재현율 값을 담은 넘파이 ndarray를 반환합니다.

반환되는 임계값이 너무 작은 값 단위로 많이 구성돼 있습니다. 반환된 임계값의 데이터가 147건이므로 샘플로 10건만 추출하되, 임계값을 15 단계로 추출해 좀 더 큰 값의 임계값과 그때의 정밀도와 재현율 값을 같이 살펴보겠습니다.

```
from sklearn.metrics import precision_recall_curve

# 레이블 값이 1일 때의 예측 확률을 추출
pred_proba_class1 = lr_clf.predict_proba(X_test)[: , 1]

# 실제값 데이터 세트와 레이블 값이 1일 때의 예측 확률을 precision_recall_curve 인자로 입력
정밀도, 재현율, 임계값 = precision_recall_curve(y_test, pred_proba_class1)
print('반환된 분류 결정 임계값 배열의 Shape:', thresholds.shape)

# 반환된 임계값 배열 로우가 147건이므로 샘플로 10건만 추출하되, 임계값을 15 Step으로 추출.
thr_index = np.arange(0, thresholds.shape[0], 15)
print('샘플 추출을 위한 임계값 배열의 index 10개:', thr_index)
print('샘플용 10개의 임계값: ', np.round(thresholds[thr_index], 2))

# 15 step 단위로 추출된 임계값에 따른 정밀도와 재현율 값
print('샘플 임계값별 정밀도: ', np.round(precisions[thr_index], 3))
print('샘플 임계값별 재현율: ', np.round(recalls[thr_index], 3))
```

[Output]

```
반환된 분류 결정 임계값 배열의 Shape: (147, )
샘플 추출을 위한 임계값 배열의 index 10개: [ 0 15 30 45 60 75 90 105 120 135]
샘플용 10개의 임계값: [0.12 0.13 0.15 0.17 0.26 0.38 0.49 0.63 0.76 0.9 ]
샘플 임계값별 정밀도: [0.379 0.424 0.455 0.519 0.618 0.676 0.797 0.93 0.964 1. ]
샘플 임계값별 재현율: [1. 0.967 0.902 0.902 0.902 0.82 0.77 0.656 0.443 0.213]
```

추출된 임계값 샘플 10개에 해당하는 정밀도 값과 재현율 값을 살펴보면 임계값이 증가할수록 정밀도 값은 동시에 높아지나 재현율 값은 낮아짐을 알 수 있습니다. precision_recall_curve() API는 정밀도와 재현율의 임계값에 따른 값 변화를 곡선 형태의 그래프로 시각화하는 데 이용할 수 있습니다. 이 API를 이용해 정밀도와 재현율 곡선을 시각화해 보겠습니다.

```
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
%matplotlib inline
```



```
def precision_recall_curve_plot(y_test, pred_proba_c1):
    # threshold ndarray와 이 threshold에 따른 정밀도, 재현율 ndarray 추출.
    precisions, recalls, thresholds = precision_recall_curve( y_test, pred_proba_c1)


    # X축을 threshold값으로, Y축은 정밀도, 재현율 값으로 각각 Plot 수행. 정밀도는 점선으로 표시
    plt.figure(figsize=(8, 6))
    threshold_boundary = thresholds.shape[0]
    plt.plot(thresholds, precisions[0:threshold_boundary], linestyle='--', label='precision')
    plt.plot(thresholds, recalls[0:threshold_boundary], label='recall')

    # threshold 값 X 축의 Scale을 0.1 단위로 변경
    start, end = plt.xlim()
    plt.xticks(np.round(np.arange(start, end, 0.1), 2))

    # x축, y축 label과 legend, 그리고 grid 설정
    plt.xlabel('Threshold value'); plt.ylabel('Precision and Recall value')
    plt.legend(); plt.grid()
    plt.show()

precision_recall_curve_plot( y_test, lr_clf.predict_proba(X_test)[: , 1] )
```

[Output]



정밀도는 점선으로, 재현율은 실선으로 표현했습니다. 그림에서 보다시피 임곗값이 낮을수록 많은 수의 양성 예측으로 인해 재현율 값이 극도로 높아지고 정밀도 값이 극도로 낮아집니다.

임꺽값을 계속 증가시킬수록 재현율 값이 낮아지고 정밀도 값이 높아지는 반대의 양상이 됩니다. 앞 예제의 로지스틱 회귀 기반의 타이타닉 생존자 예측 모델의 경우 임꺽값이 약 0.45 지점에서 재현율과 정밀도가 비슷해지는 모습을 보였습니다.

정밀도와 재현율의 맹점

앞에서도 봤듯이 Positive 예측의 임꺽값을 변경함에 따라 정밀도와 재현율의 수치가 변경됩니다. 임꺽값의 이러한 변경은 업무 환경에 맞게 두 개의 수치를 상호 보완할 수 있는 수준에서 적용돼야 합니다. 그렇지 않고 단순히 하나의 성능 지표 수치를 높이기 위한 수단으로 사용돼서는 안 됩니다. 다음은 정밀도 또는 재현율 평가 지표 수치 중 하나를 극단적으로 높이는 방법이지만 숫자 놀음에 불과한 방법입니다.

정밀도가 100%가 되는 방법

확실한 기준이 되는 경우만 Positive로 예측하고 나머지는 모두 Negative로 예측합니다. 예를 들어 환자가 80세 이상이고 비만이며 이전에 암 진단을 받았고 암 세포의 크기가 상위 0.1% 이상이면 무조건 Positive, 다른 경우는 Negative로 예측하는 겁니다.

정밀도 = $TP / (TP + FP)$ 입니다. 전체 환자 1000명 중 확실한 Positive 징후만 가진 환자는 단 1명이라고 하면 이 한 명만 Positive로 예측하고 나머지는 모두 Negative로 예측하더라도 FP는 0, TP는 1이 되므로 정밀도는 $1/(1+0)$ 으로 100%가 됩니다.

재현율이 100%가 되는 방법

모든 환자를 Positive로 예측하면 됩니다. 재현율 = $TP / (TP + FN)$ 이므로 전체 환자 1000명을 다 Positive로 예측하는 겁니다. 이 중 실제 양성인 사람이 30명 정도라도 TN이 수치에 포함되지 않고 FN은 아예 0이므로 $30/(30 + 0)$ 으로 100%가 됩니다.

이처럼 정밀도와 재현율 성능 수치도 어느 한쪽만 참조하면 극단적인 수치 조작이 가능합니다. 따라서 정밀도 또는 재현율 중 하나만 스코어가 좋고 다른 하나는 스코어가 나쁜 분류는 성능이 좋지 않은 분류로 간주할 수 있습니다. 물론 앞의 예제에서와 같이 분류가 정밀도 또는 재현율 중 하나에 상대적인 중요도를 부여해 각 예측 상황에 맞는 분류 알고리즘을 튜닝할 수 있지만, 그렇다고 정밀도/재현율 중 하나만 강조하는 상황이 돼서는 안 됩니다(예를 들어, 암 예측 모델에서 재현율을 높인다고 걸맞다면 양성으로 판단할 경우 환자의 부담과 불평이 커지게 됩니다).

정밀도와 재현율의 수치가 적절하게 조합돼 분류의 종합적인 성능 평가에 사용될 수 있는 평가 지표가 필요합니다.

04 F1 스코어

F1 스코어(Score)는 정밀도와 재현율을 결합한 지표입니다. F1 스코어는 정밀도와 재현율이 어느 한 쪽으로 치우치지 않는 수치를 나타낼 때 상대적으로 높은 값을 가집니다. F1 스코어의 공식은 다음과 같습니다.

$$F1 = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 * \frac{precision * recall}{precision + recall}$$

만일 A 예측 모델의 경우 정밀도가 0.9, 재현율이 0.1로 극단적인 차이가 나고, B 예측 모델은 정밀도가 0.5, 재현율이 0.5로 정밀도와 재현율이 큰 차이가 없다면 A 예측 모델의 F1 스코어는 0.18이고, B 예측 모델의 F1 스코어는 0.5로 B 모델이 A모델에 비해 매우 우수한 F1 스코어를 가지게 됩니다.

사이킷런은 F1 스코어를 구하기 위해 `f1_score()`라는 API를 제공합니다. 이를 이용해 정밀도와 재현율 절의 예제에서 학습/예측한 로지스틱 회귀 기반 타이타닉 생존자 모델의 F1 스코어를 구해 보겠습니다. 앞 절에서 사용한 주피터 노트북에 계속 이어서 코드를 작성하겠습니다.

```
from sklearn.metrics import f1_score
f1 = f1_score(y_test, pred)
print('F1 스코어: {0:.4f}'.format(f1))
```

【Output】

F1 스코어: 0.7966 조화평균: 한쪽으로 치우치지 않고 조화로움.

이번에는 타이타닉 생존자 예측에서 임계값을 변화시키면서 F1 스코어를 포함한 평가 지표를 구해 보겠습니다. 이를 위해 앞에서 작성한 `get_clf_eval()` 함수에 F1 스코어를 구하는 로직을 추가하겠습니다. 그리고 앞에서 작성한 `get_eval_by_threshold()` 함수를 이용해 임계값 0.4 ~ 0.6별로 정확도, 정밀도, 재현율, F1 스코어를 알아보겠습니다.

```
def get_clf_eval(y_test, pred):
    confusion = confusion_matrix(y_test, pred)
    accuracy = accuracy_score(y_test, pred)
    precision = precision_score(y_test, pred)
    recall = recall_score(y_test, pred)
    # F1 스코어 추가
    f1 = f1_score(y_test, pred)
    print('오차 행렬')
    print(confusion)
    # f1 score print 추가
    print('정확도: {0:.4f}, 정밀도: {1:.4f}, 재현율: {2:.4f},
          F1:{3:.4f}'.format(accuracy, precision, recall, f1))

thresholds = [0.4, 0.45, 0.50, 0.55, 0.60]
pred_proba = lr_clf.predict_proba(X_test)
get_eval_by_threshold(y_test, pred_proba[:, 1].reshape(-1, 1), thresholds)
```

위 예제의 출력 결과를 다음과 같이 도표로 정리했습니다. F1 스코어는 임계값이 0.6일 때 가장 좋은 값을 보여줍니다. 하지만 임계값이 0.6인 경우에는 재현율이 크게 감소하고 있으니 주의하기 바랍니다.

평가 지표	분류 결정 임계값				
	0.4	0.45	0.5	0.55	0.6
정확도	0.8212	0.8547	0.8659	0.8715	0.8771
정밀도	0.7042	0.7869	0.8246	0.8654	0.8980
재현율	0.8197	0.7869	0.7705	0.7377	0.7213
F1	0.7576	0.7869	0.7966	0.7965	0.800

정량화

05

ROC 곡선과 AUC

평가지표: 모델 성능이 좋은가? 안 좋은가?

ROC 곡선과 이에 기반한 **AUC 스코어**는 이진 분류의 예측 성능 측정에서 중요하게 사용되는 지표입니다. ROC 곡선(Receiver Operation Characteristic Curve)은 우리말로 수신자 판단 곡선으로 불립니다. 이름이 약간 이상한 것은 원래 2차대전 때 통신 장비 성능 평가를 위해 고안된 수치이기 때문

$$\text{precision} = \text{TP} / (\text{TP} + \text{FP})$$

FP / (FP+TN) 전체 사망자 중 잘못 예측한 것.
예. 실제 사망자 중 몇 %를 생존자로 오판했나?

입니다. 일반적으로 의학 분야에서 많이 사용되지만, 머신러닝의 이진 분류 모델의 예측 성능을 판단하는 중요한 평가 지표이기도 합니다. ROC 곡선은 FPR(False Positive Rate)이 변할 때 TPR(True Positive Rate)이 어떻게 변하는지를 나타내는 곡선입니다. FPR을 X 축으로, TPR을 Y 축으로 잡으면 FPR의 변화에 따른 TPR의 변화가 곡선 형태로 나타납니다.

$$\text{TP} / (\text{FN} + \text{TP}) (= \text{재현율})$$

TPR은 True Positive Rate의 약자이며, 이는 재현율을 나타냅니다. 따라서 TPR은 $\text{TP} / (\text{FN} + \text{TP})$ 입니다. TPR, 즉 재현율은 민감도로도 불립니다. 그리고 민감도에 대응하는 지표로 TNR(True Negative Rate)이라고 불리는 특이성(Specificity)이 있습니다.

- 민감도(TPR)는 실제값 Positive(양성)가 정확히 예측되어야 하는 수준을 나타냅니다(질병이 있는 사람은 질병이 있는 것으로 양성 판정).
- 특이성(TNR)은 실제값 Negative(음성)가 정확히 예측되어야 하는 수준을 나타냅니다(질병이 없는 건강한 사람은 질병이 없는 것으로 음성 판정).


TNR(True Negative Rate)인 특이성은 다음과 같이 구할 수 있습니다. $\text{TNR} = \text{TN} / (\text{FP} + \text{TN})$. 그리고 ROC 곡선의 X 축 기준인 FPR(False Positive Rate)은 $\text{FP} / (\text{FP} + \text{TN})$ 이므로 $1 - \text{TNR}$ 또는 $1 - \text{특이성}$ 으로 표현됩니다.

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN}) = 1 - \text{TNR} = 1 - \text{특이성}$$

다음은 ROC 곡선의 예입니다. 가운데 직선은 ROC 곡선의 최저 값입니다. 왼쪽 하단과 오른쪽 상단을 대각선으로 이은 직선은 동전을 무작위로 던져 앞/뒤를 맞추는 랜덤 수준의 이진 분류의 ROC 직선입니다(AUC는 0.5임). ROC 곡선이 가운데 직선에 가까울수록 성능이 떨어지는 것이며, 멀어질수록 성능이 뛰어난 것입니다.

ROC 곡선은 FPR을 0부터 1까지 변경하면서 TPR의 변화 값을 구합니다. 그럼 어떻게 FPR을 0부터 1까지 변경할 수 있을까요? 바로 앞에서 배운 분류 결정 임계값을 변경하면 됩니다. 분류 결정 임계값은 Positive 예측값을

결정하는 확률의 기준이기 때문에 FPR을 0으로 만들려면 임계값을 1로 지정하면 됩니다. 임계값을 1로 지정하면 Positive 예측 기준이 매우 높기 때문에 분류기(Classifier)가 임계값보다 높은 확률을 가진



〈ROC 곡선 예시〉

데이터를 Positive로 예측할 수 없기 때문입니다. 앞의 FPR 결정 공식을 다시 한번 보겠습니다. $FPR = FP / (FP + TN)$ 입니다. 즉, 아예 Positive로 예측하지 않기 때문에 FP 값이 0이 되므로 자연스럽게 FPR은 0이 됩니다.

반대로 FPR을 어떻게 1로 만들 수 있을까요? 바로 TN을 0으로 만들면 됩니다. TN을 0으로 만들려면 분류 결정 임계값을 0으로 지정하면 됩니다. 그럼 분류기의 Positive 확률 기준이 너무 낮아서 다 Positive로 예측합니다. 그럼 아예 Negative 예측이 없기 때문에 TN이 0이 되고 FPR 값은 1이 됩니다. 이렇게 임계값을 1부터 0까지 변화시키면서 FPR을 구하고 이 FPR 값의 변화에 따른 TPR 값을 구하는 것이 ROC 곡선입니다(그래서 임계값을 1부터 0까지 거꾸로 변화시키면서 구한 재현율 곡선의 형태와 비슷합니다).

사이킷런은 ROC 곡선을 구하기 위해 `roc_curve()` API를 제공합니다. 사용법은 `precision_recall_curve()` API와 유사합니다. 단지 **반환값이 FPR, TPR, 임계값으로** 구성돼 있을 뿐입니다. 다음은 `roc_curve()`의 주요 입력 파라미터와 반환 값을 기술한 것입니다.

입력 파라미터	y_true : 실제 클래스 값 array (array shape = [데이터 건수])	cl1
	y_score : <code>predict_proba()</code> 의 반환 값 array에서 Positive 칼럼의 예측 확률이 보통 사용됨. array, shape = [n_samples]	
반환 값	fpr : fpr 값을 array로 반환	} 차트(그래프)
	tpr : tpr 값을 array로 반환	
	thresholds : threshold 값 array	

`roc_curve()` API를 이용해 타이타닉 생존자 예측 모델의 FPR, TPR, 임계값을 구해 보겠습니다. 앞 정밀도와 재현율에서 학습한 `LogisticRegression` 객체의 `predict_proba()` 결과를 다시 이용해 `roc_curve()`의 결과를 도출하겠습니다.

```
from sklearn.metrics import roc_curve

# 레이블 값이 1일때의 예측 확률을 추출
pred_proba_class1 = lr_clf.predict_proba(X_test)[: , 1]

fprs , tprs , thresholds = roc_curve(y_test, pred_proba_class1)
# 반환된 임계값 배열에서 샘플로 데이터를 추출하되, 임계값을 5 Step으로 추출.
# thresholds[0]은 max(예측확률)+1로 임의 설정됨. 이를 제외하기 위해 np.arange는 1부터 시작
thr_index = np.arange(1, thresholds.shape[0], 5)
```

```
print('샘플 추출을 위한 임계값 배열의 index:', thr_index)
print('샘플 index로 추출한 임계값: ', np.round(thresholds[thr_index], 2))
```

```
# 5 step 단위로 추출된 임계값에 따른 FPR, TPR 값
print('샘플 임계값별 FPR: ', np.round(fprs[thr_index], 3))
print('샘플 임계값별 TPR: ', np.round(tprs[thr_index], 3))
```

【Output】

```
샘플 추출을 위한 임계값 배열의 index: [ 1  6 11 16 21 26 31 36 41 46]
샘플 index로 추출한 임계값: [0.94 0.73 0.62 0.52 0.44 0.28 0.15 0.14 0.13 0.12]
샘플 임계값별 FPR: [0.    0.008 0.025 0.076 0.127 0.254 0.576 0.61  0.746 0.847]
샘플 임계값별 TPR: [0.016 0.492 0.705 0.738 0.803 0.885 0.902 0.951 0.967 1.    ]
```


roc_curve()의 결과를 살펴보면 임계값이 1에 가까운 값에서 점점 작아지면서 FPR이 점점 커집니다. 그리고 FPR이 조금씩 커질 때 TPR은 가파르게 커짐을 알 수 있습니다. FPR의 변화에 따른 TPR의 변화를 ROC 곡선으로 시각화해 보겠습니다.

```
def roc_curve_plot(y_test, pred_proba_c1):
    # 임계값에 따른 FPR, TPR 값을 반환받음.
    fprs, tprs, thresholds = roc_curve(y_test, pred_proba_c1)
    # ROC 곡선을 그래프 곡선으로 그림.
    plt.plot(fprs, tprs, label='ROC')
    # 가운데 대각선 직선을 그림.
    plt.plot([0, 1], [0, 1], 'k--', label='Random')

    # FPR X 축의 Scale을 0.1 단위로 변경, X, Y축 명 설정 등
    start, end = plt.xlim()
    plt.xticks(np.round(np.arange(start, end, 0.1), 2))
    plt.xlim(0, 1); plt.ylim(0, 1)
    plt.xlabel('FPR( 1 - Sensitivity )'); plt.ylabel('TPR( Recall )')
    plt.legend()

roc_curve_plot(y_test, pred_proba[:, 1])
```


[Output]



일반적으로 ROC 곡선 자체는 FPR과 TPR의 변화 값을 보는 데 이용하며 분류의 성능 지표로 사용되는 것은 ROC 곡선 면적에 기반한 AUC 값으로 결정합니다. AUC(Area Under Curve) 값은 ROC 곡선 밑의 면적을 구한 것으로서 일반적으로 1에 가까울수록 좋은 수치입니다. AUC 수치가 커지려면 FPR이 작은 상태에서 얼마나 큰 TPR을 얻을 수 있는냐가 관건입니다. 가운데 직선에서 멀어지고 왼쪽 상단 모서리 쪽으로 가파르게 곡선이 이동할수록 직사각형에 가까운 곡선이 되어 면적이 1에 가까워지는 좋은 ROC AUC 성능 수치를 얻게 됩니다. 가운데 대각선 직선은 랜덤 수준의(동전 던지기 수준) 이진 분류 AUC 값으로 0.5입니다. 따라서 보통의 분류는 0.5 이상의 AUC 값을 가집니다.

```
from sklearn.metrics import roc_auc_score

pred_proba = lr_clf.predict_proba(X_test)[: , 1]
roc_score = roc_auc_score(y_test, pred_proba)
print('ROC AUC 값: {0:.4f}'.format(roc_score))
```

[Output]

```
ROC AUC 값: 0.8987
```

타이타닉 생존자 예측 로지스틱 회귀 모델의 ROC AUC 값은 약 0.9024로 측정됐습니다. 마지막으로 `get_clf_eval()` 함수에 `roc_auc_score()`를 이용해 ROC AUC값을 측정하는 로직을 추가하는데, ROC AUC는 예측 확률값을 기반으로 계산되므로 이를 `get_clf_eval()` 함수의 인자로 받을 수 있도록 `get_clf_eval(y_test, pred=None, pred_proba=None)`로 함수형을 변경해 줍니다. 이제 `get_clf_eval()` 함수는 정확도, 정밀도, 재현율, F1 스코어, ROC AUC 값까지 출력할 수 있습니다.

```
def get_clf_eval(y_test, pred=None, pred_proba=None):
    confusion = confusion_matrix(y_test, pred)
    accuracy = accuracy_score(y_test, pred)
    precision = precision_score(y_test, pred)
    recall = recall_score(y_test, pred)
    f1 = f1_score(y_test, pred)
    # ROC-AUC 추가
    roc_auc = roc_auc_score(y_test, pred_proba)
    print('오차 행렬')
    print(confusion)
    # ROC-AUC print 추가
    print('정확도: {0:.4f}, 정밀도: {1:.4f}, 재현율: {2:.4f},\n
          F1: {3:.4f}, AUC:{4:.4f}'.format(accuracy, precision, recall, f1, roc_auc))
```

06 피마 인디언 당뇨병 예측

예측

이번에는 피마 인디언 당뇨병(Pima Indian Diabetes) 데이터 세트를 이용해 **당뇨병 여부를** 판단하는 머신러닝 예측 모델을 수립하고, 지금까지 설명한 평가 지표를 적용해 보겠습니다. 피마 인디언 당뇨병 데이터 세트는 북아메리카 피마 지역 원주민의 Type-2 당뇨병 **결과 데이터**입니다. 보통 당뇨 원인으로 식습관과 유전을 꼽습니다. 피마 지역은 고립된 지역에서 인디언 고유의 혈통이 지속돼 왔지만, 20세기 후반에 들어서면서 서구화된 식습관으로 **많은 당뇨 환자**가 생겨났습니다. 고립된 유전적 특성 때문에 당뇨학회에서는 피마 인디언의 당뇨병 자료에 대해 많은 연구를 했습니다.

데이터 세트는 <https://www.kaggle.com/uciml/pima-indians-diabetes-database> 페이지에 접속 후 Download 버튼을 클릭해 압축 파일을 내려받습니다. 내려받은 압축 파일에서 diabetes.csv 파일을 개인 PC의 적당한 위치에 저장하면 됩니다.

Dataset
Released Under CC0: Public Domain
405

Pima Indians Diabetes Database

Predict the onset of diabetes based on diagnostic measures

UCI ML UCI Machine Learning • updated 2 years ago (Version 1)

Data
Overview
Kernels (527)
Discussion (8)
Activity
Download (9 KB)
New Kernel

피마 인디언 당뇨병 데이터 세트는 다음 피처로 구성돼 있습니다.

- Pregnancies: 임신 횟수
- Glucose: 포도당 부하 검사 수치
- BloodPressure: 혈압(mm Hg)
- SkinThickness: 팔 삼두근 뒤쪽의 피하지방 측정값(mm)
- Insulin: 혈청 인슐린(mu U/ml)
- BMI: 체질량지수(체중(kg)/(키(m))^2)
- DiabetesPedigreeFunction: 당뇨 내력 가중치 값
- Age: 나이
- Outcome: 클래스 결정 값(0또는 1)

새로운 주피터 노트북을 생성하고, 내려받은 diabetes.csv 파일을 새로운 노트북이 생성된 디렉터리로 이동합니다. 필요한 모듈을 임포트하고, diabetes.csv는 DataFrame으로 로딩하겠습니다. 로딩 후에는 Outcome 클래스 결정값의 분포와 데이터를 개략적으로 확인해 보겠습니다.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline

from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, precision_score, recall_score, roc_auc_score
from sklearn.metrics import f1_score, confusion_matrix, precision_recall_curve, roc_curve
from sklearn.preprocessing import StandardScaler
```



```
from sklearn.linear_model import LogisticRegression

diabetes_data = pd.read_csv('diabetes.csv')
print(diabetes_data['Outcome'].value_counts())
diabetes_data.head(3)
```

[Output]

```
0    500
1    268
Name: Outcome, dtype: int64
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1

전체 768개의 데이터 중에서 Negative 값 0이 500개, Positive 값 1이 268개로 Negative가 상대적으로 많습니다. feature의 타입과 Null 개수를 살펴보겠습니다.

```
diabetes_data.info( )
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
Pregnancies      768 non-null int64
Glucose          768 non-null int64
BloodPressure    768 non-null int64
SkinThickness    768 non-null int64
Insulin          768 non-null int64
BMI              768 non-null float64
DiabetesPedigreeFunction 768 non-null float64
Age              768 non-null int64
Outcome          768 non-null int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
```

Null 값은 없으며 피처의 타입은 모두 숫자형입니다. 임신 횟수, 나이와 같은 숫자형 피처와 당뇨 검사 수치 피처로 구성된 특징으로 볼 때 별도의 피처 인코딩은 필요하지 않아 보입니다.

이제 로지스틱 회귀를 이용해 예측 모델을 생성해 보겠습니다. 데이터 세트를 피처 데이터 세트와 클래스 데이터 세트로 나누고 학습 데이터 세트와 테스트 데이터 세트로 분리하겠습니다. 로지스틱 회귀를 이용해 예측을 수행하고 앞 예제에서 사용한 유틸리티 함수인 `get_clf_eval()`, `get_eval_by_threshold()`, `precision_recall_curve_plot()`을 이용해 성능 평가 지표를 출력하고 재현율 곡선을 시각화해 보겠습니다.

```
# 피처 데이터 세트 X, 레이블 데이터 세트 y를 추출.
# 맨 끝이 Outcome 칼럼으로 레이블 값임. 칼럼 위치 -1을 이용해 추출
X = diabetes_data.iloc[:, :-1]
y = diabetes_data.iloc[:, -1]

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 156, stratify=y)

# 로지스틱 회귀로 학습, 예측 및 평가 수행.
lr_clf = LogisticRegression(solver='linear')
lr_clf.fit(X_train, y_train)
pred = lr_clf.predict(X_test)
pred_proba = lr_clf.predict_proba(X_test)[: , 1]

get_clf_eval(y_test, pred, pred_proba)
```

[Output]

오차 행렬


```
[[87 13]
```

```
 [22 32]]
```

정확도: 0.7727, 정밀도: 0.7111, 재현율: 0.5926, F1: 0.6465, AUC:0.8083

예측 정확도가 77.27%, 재현율은 59.26%로 측정됐습니다. 전체 데이터의 65%가 Negative이므로 정밀도보다는 재현율 성능에 조금 더 초점을 맞춰 보겠습니다. 먼저 정밀도 재현율 곡선을 보고 임계값별 정밀도와 재현율 값의 변화를 확인하겠습니다. 이를 위해 `precision_recall_curve_plot()` 함수를 이용하겠습니다.

```
pred_proba_c1 = lr_clf.predict_proba(X_test)[: , 1]
precision_recall_curve_plot(y_test, pred_proba_c1)
```



재현율 곡선을 보면 임계값을 0.42 정도로 낮추면 정밀도와 재현율이 어느 정도 균형을 맞출 것 같습니다. 하지만 두 개의 지표 모두 0.7이 안 되는 수치로 보입니다. 여전히 두 지표의 값이 낮습니다. 임계값을 인위적으로 조작하기 전에 다시 데이터 값을 점검하겠습니다. 먼저 원본 데이터 DataFrame의 `describe()` 메서드를 호출해 피쳐 값의 분포를 살펴보겠습니다.


```
diabetes_data.describe()
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479	31.992578	0.471876	33.240885	0.348958
std	3.369578	31.972618	19.355807	15.952218	115.244002	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000	27.300000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000	32.000000	0.372500	29.000000	0.000000
75%	6.000000	140.250000	80.000000	32.000000	127.250000	36.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	846.000000	67.100000	2.420000	81.000000	1.000000

`diabetes_data.describe()` 데이터 값을 보면 `min()` 값이 0으로 돼 있는 피쳐가 상당히 많습니다. 예를 들어 Glucose 피쳐는 포도당 수치인데 `min` 값이 0인 것은 말이 되지 않습니다. Glucose 피쳐의 히스토그램을 확인해 보면 0 값이 일정 수준 존재하는 것을 알 수 있습니다.

```
plt.hist(diabetes_data['Glucose'], bins=100)
plt.show()
```

[Output]



`min()` 값이 0으로 돼 있는 피처에 대해 0 값의 건수 및 전체 데이터 건수 대비 몇 퍼센트의 비율로 존재하는지 확인해 보겠습니다. 확인할 피처는 'Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI'입니다(Pregnancies는 출산 횟수를 의미하므로 제외합니다).

```
# 0값을 검사할 피처명 리스트
zero_features = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']

# 전체 데이터 건수
total_count = diabetes_data['Glucose'].count()

# 피처별로 반복하면서 데이터 값이 0인 데이터 건수를 추출하고, 퍼센트 계산
for feature in zero_features:
    zero_count = diabetes_data[diabetes_data[feature] == 0][feature].count()
    print('{0} 0 건수는 {1}, 퍼센트는 {2:.2f} %'.format(feature, zero_count,
                                                         100*zero_count/total_count))
```

[Output]

```
Glucose 0 건수는 5, 퍼센트는 0.65 %
BloodPressure 0 건수는 35, 퍼센트는 4.56 %
SkinThickness 0 건수는 227, 퍼센트는 29.56 %
```


Insulin 0 건수는 374, 퍼센트는 48.70 %

BMI 0 건수는 11, 퍼센트는 1.43 %

SkinThickness와 Insulin의 0 값은 각각 전체의 29.56%, 48.7%로 대단히 많습니다. 전체 데이터 건수가 많지 않기 때문에 이들 데이터를 일괄적으로 삭제할 경우에는 학습을 효과적으로 수행하기 어려울 것 같습니다. 위 피처의 0 값을 평균값으로 대체하겠습니다.

```
# zero_features 리스트 내부에 저장된 개별 피처들에 대해서 0값을 평균 값으로 대체
mean_zero_features = diabetes_data[zero_features].mean()
diabetes_data[zero_features]=diabetes_data[zero_features].replace(0, mean_zero_features)
```

0 값을 평균값으로 대체한 데이터 세트에 피처 스케일링을 적용해 변환하겠습니다. 로지스틱 회귀의 경우 일반적으로 숫자 데이터에 스케일링을 적용하는 것이 좋습니다. 이후에 다시 학습/테스트 데이터 세트로 나누고 로지스틱 회귀를 적용해 성능 평가 지표를 확인하겠습니다.

```
X = diabetes_data.iloc[:, :-1]
y = diabetes_data.iloc[:, -1]

# StandardScaler 클래스를 이용해 피처 데이터 세트에 일괄적으로 스케일링 적용
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size = 0.2, random_state = 156, stratify=y)

# 로지스틱 회귀로 학습, 예측 및 평가 수행.
lr_clf = LogisticRegression()
lr_clf.fit(X_train, y_train)
pred = lr_clf.predict(X_test)
pred_proba = lr_clf.predict_proba(X_test)[:, 1]

get_clf_eval(y_test, pred, pred_proba)
```

【Output】

오차 행렬

[[90 10]

[21 33]]

정확도: 0.7987, 정밀도: 0.7674, 재현율: 0.6111, F1: 0.6804, AUC:0.8433

데이터 변환과 스케일링을 통해 성능 수치가 일정 수준 개선됐습니다. 로지스틱 회귀에 대해 본격적으로 학습하지 않았으니 하이퍼 파라미터에 대한 튜닝은 생략하겠습니다. 하지만 여전히 재현율 수치는 개선이 필요해 보입니다. 분류 결정 임계값을 변화시키면서 재현율 값의 성능 수치가 어느 정도나 개선되는지 확인해 보겠습니다. 다음 코드는 임계값을 0.3에서 0.5까지 0.03씩 변화시키면서 재현율과 다른 평가 지표의 값 변화를 출력합니다. 임계값에 따른 평가 수치 출력은 앞에서 사용한 `get_eval_by_threshold()` 함수를 이용합니다.

```
thresholds = [0.3, 0.33, 0.36, 0.39, 0.42, 0.45, 0.48, 0.50]
pred_proba = lr_clf.predict_proba(X_test)
get_eval_by_threshold(y_test, pred_proba[:, 1].reshape(-1, 1), thresholds)
```

Output을 정리하면 다음과 같습니다.

평가 지표	분류 결정 임계값							
	0.3	0.33	0.36	0.39	0.42	0.45	0.48	0.50
정확도	0.7013	0.7403	0.7468	0.7532	0.7792	0.7857	0.7987	0.7987
정밀도	0.5513	0.5972	0.6190	0.6333	0.6923	0.7059	0.7447	0.7674
재현율	0.7963	0.7963	0.7222	0.7037	0.6667	0.6667	0.6481	0.6111
F1	0.6515	0.6825	0.6667	0.6667	0.6792	0.6857	0.6931	0.6804
ROC AUC	0.8433	0.8433	0.8433	0.8433	0.8433	0.8433	0.8433	0.8433

위 표를 근거로 하면 정확도와 정밀도를 희생하고 재현율을 높이는 데 가장 좋은 임계값은 0.33으로, 재현율 값이 0.7963입니다. 하지만 정밀도가 0.5972로 매우 저조해졌으니 극단적인 선택으로 보입니다. 임계값 0.48이 전체적인 성능 평가 지표를 유지하면서 재현율을 약간 향상시키는 좋은 임계값으로 보입니다. 임계값 0.48일 경우 정확도는 0.7987, 정밀도는 0.7447, 재현율은 0.6481, F1 스코어는 0.6931, ROC AUC는 0.8433이 됩니다.

앞에서 학습된 로지스틱 회귀 모델을 이용해 임계값을 0.48로 낮춘 상태에서 다시 예측을 해보겠습니다. 사이킷런의 `predict()` 메서드는 임계값을 마음대로 변환할 수 없으므로 별도의 로직으로 이를 구현해야 합니다. 앞에서 살펴본 `Binarizer` 클래스를 이용해 `predict_proba()`로 추출한 예측 결과 확률 값을 변환해 변경된 임계값에 따른 예측 클래스 값을 구해 보겠습니다.

```
# 임계값을 0.48로 설정한 Binarizer 생성
binarizer = Binarizer(threshold=0.48)
```

```
# 위에서 구한 lr_clf의 predict_proba() 예측 확률 array에서 1에 해당하는 칼럼값을 Binarizer 변환.
pred_th_048 = binarizer.fit_transform(pred_proba[:, 1].reshape(-1, 1))

get_clf_eval(y_test, pred_th_048, pred_proba[:, 1])
```

【Output】

오차 행렬

[[88 12]

[19 35]]

정확도: 0.7987, 정밀도: 0.7447, 재현율: 0.6481, F1: 0.6931, AUC:0.8433

07 정리

지금까지 분류에 사용되는 정확도, 오차 행렬, 정밀도, 재현율, F1 스코어, ROC-AUC와 같은 성능 평가 지표를 살펴보았습니다. 특히 이진 분류의 레이블 값이 불균형하게 분포될 경우(즉 0이 매우 많고, 1이 매우 적을 경우 또는 반대의 경우) 단순히 예측 결과와 실제 결과가 일치하는 지표인 정확도만으로는 머신러닝 모델의 예측 성능을 평가할 수 없습니다.

오차 행렬은 Negative와 Positive 값을 가지는 실제 클래스 값과 예측 클래스 값이 True와 False에 따라 TN, FP, FN, TP로 매핑되는 4분면 행렬을 기반으로 예측 성능을 평가합니다. 정확도, 정밀도, 재현율 수치는 TN, FP, FN, TP 값을 다양하게 결합해 만들며, 이를 통해 분류 모델 예측 성능의 오류가 어떠한 모습으로 발생하는지 알 수 있는 것입니다.

정밀도(Precision)와 재현율(Recall)은 Positive 데이터 세트의 예측 성능에 좀 더 초점을 맞춘 평가 지표입니다. 특히 재현율이 상대적으로 더 중요한 지표인 경우는 암 양성 예측 모델과 같이 실제 Positive 양성인 데이터 예측을 Negative로 잘못 판단하게 되면 업무상 큰 영향이 발생하는 경우입니다. 분류하려는 업무의 특성상 정밀도 또는 재현율이 특별히 강조돼야 할 경우 분류의 결정 임계값(Threshold)을 조정해 정밀도 또는 재현율의 수치를 높이는 방법에 대해서 배웠습니다.

F1 스코어는 정밀도와 재현율을 결합한 평가 지표이며, 정밀도와 재현율이 어느 한쪽으로 치우치지 않을 때 높은 지표값을 가지게 됩니다. ROC-AUC는 일반적으로 이진 분류의 성능 평가를 위해 가장 많이 사용되는 지표입니다. AUC(Area Under Curve) 값은 ROC 곡선 밑의 면적을 구한 것으로서 일반적으로 1에 가까울수록 좋은 수치입니다.

이제 분류 평가 지표를 배웠으니, 다음 장에서 본격적으로 머신러닝 기반의 분류를 구현해 보겠습니다.