

2.5 데이터 전처리(Data Preprocessing)

목차

1. 데이터 전처리 개요
2. 데이터 인코딩
 1. 레이블 인코딩(Label Encoding)
 2. 인코딩 클래스 확인과 디코딩
 3. 레이블 인코딩의 한계
 4. 원-핫 인코딩(One-Hot Encoding)
 5. 판다스 `get_dummies()`
3. 피처 스케일링과 정규화
 1. 스케일링이 필요한 이유
 2. `StandardScaler`
 3. `MinMaxScaler`
4. 학습/테스트 데이터의 스케일링 변환 시 유의사항
 1. 실습용 데이터 생성
 2. 잘못된 사례 - 테스트 데이터에 `fit()` 재호출
 3. 올바른 사례 - `transform()`만 호출
5. 핵심 요약 및 머신러닝 활용 포인트

1. 데이터 전처리 개요

머신러닝 알고리즘만큼 중요한 것이 **데이터 전처리**입니다. **Garbage In, Garbage Out**이라는 말처럼, 아무리 뛰어난 알고리즘도 잘못된 데이터로는 좋은 결과를 낼 수 없습니다.

사이킷런의 머신러닝 알고리즘을 적용하기 전에 반드시 처리해야 할 사항은 다음과 같습니다.

처리 항목	내용
결손값(NaN, Null) 처리	허용되지 않으므로 고정값이나 평균값으로 대체하거나 해당 피처를 삭제해야 합니다. Null이 매우 많은 피처는 삭제를, 일부라면 대체를 고려합니다.
문자열 값 처리	사이킷런은 문자열 값을 입력값으로 허용하지 않습니다. 모든 문자열은 인코딩되어 숫자형으로 변환되어야 합니다.
불필요한 피처 제거	주민번호, 아이디 같은 식별자 성격의 피처는 예측에 중요하지 않으므로 삭제하는 것이 좋습니다.
피처 스케일링	피처마다 값의 범위가 크게 다르면 특정 피처가 과도한 영향을 주므로 범위를 맞춰 줍니다.

■ 문자열 피처의 두 유형

- **카테고리형** : 성별, 등급, 지역 등 범주를 나타내는 값. → 코드값으로 인코딩합니다.
- **텍스트형** : 상품 설명, 리뷰 등 자유로운 문장. → 피처 벡터화(TF-IDF 등)를 하거나, 불필요하면 삭제합니다.

2. 데이터 인코딩

머신러닝을 위한 대표적인 인코딩 방식은 **레이블 인코딩**과 **원-핫 인코딩** 두 가지입니다.

2.1 레이블 인코딩(Label Encoding)

카테고리형 데이터 값 개수가 달라지면 안 됨.

레이블 인코딩은 **카테고리 피처**를 **코드형 숫자값으로 변환**하는 것입니다.

```
from sklearn.preprocessing import LabelEncoder

items=['TV', '냉장고', '전자레인지', '컴퓨터', '선종기', '선종기', '믹서', '믹서']

# LabelEncoder를 객체로 생성한 후, fit() 과 transform() 으로 label 인코딩 수행.
encoder = LabelEncoder()
encoder.fit(items)
labels = encoder.transform(items)
print('인코딩 변환값:', labels)
```

줄	코드	상세 설명
1	from sklearn.preprocessing import LabelEncoder	sklearn.preprocessing 모듈에서 LabelEncoder 클래스를 임포트합니다.
3	items=['TV', '냉장고', ..., '믹서']	8개의 상품명 문자열 리스트입니다. 고유값은 TV, 냉장고, 전자레인지, 컴퓨터, 선종기, 믹서의 6가지이며, 선종기와 믹서는 2번씩 등장합니다.
6	encoder = LabelEncoder()	인코더 객체를 생성합니다. 이 시점에는 아무것도 학습되지 않은 상태입니다.
7	encoder.fit(items)	fit()은 데이터를 변환하지 않습니다. 어떤 고유값들이 있는지 파악해 알파벳·가나다순으로 정렬한 매핑 규칙을 학습할 뿐입니다.

8	<code>labels = encoder.transform(items)</code>	transform()이 실제 변환을 수행합니다. fit에서 만든 매핑에 따라 각 문자열을 숫자로 바꿔 ndarray로 반환합니다.
9	<code>print('인코딩 변환값:', labels)</code>	결과는 <code>[0 1 4 5 3 3 2 2]</code> 입니다. TV→0, 냉장고→1, 전자레인지→4, 컴퓨터→5, 선풍기→3, 믹서→2로 변환되었습니다. 같은 값(선풍기, 믹서)은 항상 같은 숫자가 됩니다.

▶ 실행 결과

```
인코딩 변환값: [0 1 4 5 3 3 2 2]
```

■ 숫자 부여 기준

등장 순서가 아니라 **정렬 순서**로 번호가 매겨집니다. 영문은 알파벳순, 한글은 가나다순입니다. 그래서 'TV'가 0, 그다음 가나다순으로 '냉장고'(1), '믹서'(2), '선풍기'(3), '전자레인지'(4), '컴퓨터'(5)가 됩니다. `fit_transform( )` 을 쓰면 두 단계를 한 줄로 처리할 수 있습니다.

2.2 인코딩 클래스 확인과 디코딩

```
print('인코딩 클래스:', encoder.classes_)
```

줄	코드	상세 설명
1	<code>encoder.classes_</code>	학습된 매핑 정보 를 담은 속성입니다. 배열의 인덱스가 곧 인코딩된 숫자 이고 값이 원본 문자열입니다. 즉 <code>classes_[0]='TV'</code> 이므로 TV가 0입니다. 언더스코어(_)로 끝나는 것은 fit 이후에 생성되는 속성 이라는 사이킷런의 관례입니다.

▶ 실행 결과

```
인코딩 클래스: ['TV' '냉장고' '믹서' '선풍기' '전자레인지' '컴퓨터']
```

```
print('디코딩 원본 값:', encoder.inverse_transform([4, 5, 2, 0, 1, 1, 3, 3]))
```

줄	코드	상세 설명
1	<code>encoder.inverse_transform([4,5,2,0,1,1,3,3])</code>	인코딩의 역변환 입니다. 숫자를 다시 원본 문자열로 되돌립니다. 4→전자레인지, 5→컴퓨터, 2→믹서 순으로 변환됩니다. 모델의 예측 결과를 사람이 읽을 수 있는 형태로 되돌릴 때 매우 유용합니다.

▶ 실행 결과

```
디코딩 원본 값: ['전자레인지' '컴퓨터' '믹서' 'TV' '냉장고' '냉장고' '선풍기' '선풍기']
```

2.3 레이블 인코딩의 한계

순서와 간격이 생김. 예. 냉장고(1), 컴퓨터(5)

1. 냉장고(1) < 컴퓨터(5) 가 아님.

2. 컴퓨터(5)는 냉장고(1)의 5배가 아님.

⚠ 숫자에 없던 크기 관계가 생긴다

레이블 인코딩은 문자를 숫자로 바꾸지만, 그 과정에서 **원래 없던 대소 관계와 순서가 생겨 버립니다**. 냉장고(1)보다 컴퓨터(5)가 **5배 크거나 우수하다는 의미는 전혀 없는데**, 알고리즘은 숫자를 그대로 받아들여 가중치를 다르게 부여합니다.

따라서 **선형 회귀, 로지스틱 회귀, SVM 같은 알고리즘에는 레이블 인코딩을 적용하면 안 됩니다**. 반면 **결정 트리 계열** (Decision Tree, Random Forest, GBM 등)은 숫자의 크기를 그대로 해석하지 않고 **분기 기준으로만** 사용하므로 레이블 인코딩을 써도 무방합니다.

2.4 원-핫 인코딩(One-Hot Encoding)

원-핫 인코딩은 **고유값의 개수만큼 새로운 컬럼을 만들고**, 해당하는 컬럼에만 1을 표시하고 나머지는 0으로 채우는 방식입니다. 이렇게 하면 **숫자의 크기 관계 문제가 사라집니다**.

```
from sklearn.preprocessing import OneHotEncoder
import numpy as np

items=['TV', '냉장고', '전자레인지', '컴퓨터', '선풍기', '선풍기', '믹서', '믹서']

# 2차원 ndarray로 변환합니다.
items = np.array(items).reshape(-1, 1)

# 원-핫 인코딩을 적용합니다.
oh_encoder = OneHotEncoder()
oh_encoder.fit(items)
oh_labels = oh_encoder.transform(items)

# OneHotEncoder로 변환한 결과는 희소행렬이므로 toarray()를 이용해 밀집 행렬로 변환.
print('원-핫 인코딩 데이터')
print(oh_labels.toarray())
print('원-핫 인코딩 데이터 차원')
print(oh_labels.shape)
```

줄	코드	상세 설명
7	<code>items = np.array(items).reshape(-1, 1)</code>	매우 중요한 단계 입니다. OneHotEncoder는 2차원 데이터 만 입력받으므로, 리스트를 ndarray로 바꾼 뒤 <code>reshape(-1, 1)</code> 로 (8, 1) 형태의 2차원 으로 만들어야 합니다. 이 과정을 빠뜨리면 오류가 발생합니다.
10	<code>oh_encoder = OneHotEncoder()</code>	원-핫 인코더 객체를 생성합니다.
11	<code>oh_encoder.fit(items)</code>	고유값 6개를 파악해 컬럼 구성을 학습 합니다.
12	<code>oh_labels = oh_encoder.transform(items)</code>	실제 변환을 수행합니다. 반환값은 일반 배열이 아니라 희소 행렬(sparse matrix) 입니다. 원-핫 결과는 대부분이 0이므로 0이 아닌 위치만 저장해 메모리를 절약하는 형식입니다.
16	<code>oh_labels.toarray()</code>	희소 행렬을 사람이 볼 수 있는 밀집 행렬(일반 ndarray) 로 변환합니다. 이 과정을 거치지 않으면 내용이 아니라 행렬 요약 정보만 출력됩니다.
18	<code>oh_labels.shape</code>	(8, 6) → 8개 행 (원본 데이터 수)과 6개 열 (고유값 수)입니다. 컬럼이 1개에서 6개로 늘어났습니다 .

▶ 실행 결과

```
원-핫 인코딩 데이터
[[1. 0. 0. 0. 0. 0.]
 [0. 1. 0. 0. 0. 0.]
 [0. 0. 0. 0. 1. 0.]
 [0. 0. 0. 0. 0. 1.]
 [0. 0. 0. 1. 0. 0.]
 [0. 0. 0. 1. 0. 0.]
 [0. 0. 1. 0. 0. 0.]
 [0. 0. 1. 0. 0. 0.]]
원-핫 인코딩 데이터 차원
(8, 6)
```

■ 결과 해석

컬럼 순서는 `classes_` 와 같은 ['TV','냉장고','믹서','선풍기','전자레인지','컴퓨터']입니다. 첫 행은 'TV'이므로 0번 위치만 1이고, 세 번째 행은 '전자레인지'이므로 4번 위치만 1입니다. 각 행에는 정확히 하나의 1만 존재해서 '원-핫(One-Hot)'이라는 이름이 붙었습니다.

⚠ 원-핫 인코딩의 부작용

고유값이 많으면 컬럼 수가 폭발적으로 증가합니다(차원의 저주). 예를 들어 우편번호처럼 값이 수천 개인 피처를 원-핫 인코딩하면 컬럼이 수천 개가 되어 메모리와 학습 시간이 급증하고 성능도 떨어질 수 있습니다. 이럴 때는 값을 상위 몇 개로 묶거나 다른 인코딩 기법을 검토해야 합니다.

⚠ 버전 차이 - `sparse_output` 파라미터

사이킷런 1.2부터 `sparse` 파라미터가 `sparse_output` 으로 이름이 바뀌었고, 1.4에서 기존 이름은 제거되었습니다. 처음부터 일반 배열로 받고 싶다면 `OneHotEncoder(sparse_output=False)` 를 사용하세요. 구버전 교재의 `sparse=False` 코드는 현재 버전에서 `TypeError`가 발생합니다.

2.5 판다스 `get_dummies()`

판다스는 원-핫 인코딩을 훨씬 간편하게 지원합니다.

```
import pandas as pd

df = pd.DataFrame({'item':['TV','냉장고','전자레인지','컴퓨터','선풍기','선풍기','믹서','믹서']})
pd.get_dummies(df)
```

줄	코드	상세 설명
3	<code>df = pd.DataFrame({'item':[...]})</code>	상품명명을 담은 DataFrame을 만듭니다.
4	<code>pd.get_dummies(df)</code>	숫자 변환 없이 문자열을 바로 넣어도 원-핫 인코딩이 수행됩니다. <code>reshape</code> 도, <code>fit/transform</code> 도 필요 없습니다. 새 컬럼명은 원본컬럼명_값 형태(<code>item_TV</code> 등)로 자동 생성되어 의미를 바로 알 수 있습니다.

▶ 실행 결과

```
item_TV  item_냉장고  item_믹서  item_선풍기  item_전자레인지  item_컴퓨터
0      True      False      False      False      False      False
1      False      True      False      False      False      False
2      False      False      False      False      True      False
3      False      False      False      False      False      True
4      False      False      False      True      False      False
```

5	False	False	False	True	False	False
6	False	False	True	False	False	False
7	False	False	True	False	False	False

⚠ 버전 차이 - 결과 타입이 bool로 변경

pandas 2.0부터 `get_dummies()`의 결과가 0/1 정수가 아니라 True/False(bool)로 반환됩니다. 사이킷런 모델에 그대로 넣어도 내부적으로 0/1로 처리되어 학습에는 문제가 없습니다. 숫자로 받고 싶다면 `pd.get_dummies(df, dtype=int)`를 사용하세요.

■ OneHotEncoder vs get_dummies

구분	OneHotEncoder	get_dummies
입력 준비	2차원 변환 필요(reshape)	DataFrame 그대로
사용 편의	fit → transform 2단계	한 줄
컬럼명	별도 확인 필요	자동 생성
매핑 재사용	가능 (학습된 기준을 테스트에 적용)	불가 (호출할 때마다 새로 계산)
권장 상황	모델 파이프라인에 포함할 때	탐색적 분석, 일회성 변환

실무에서는 학습 데이터와 테스트 데이터의 컬럼 구성이 반드시 같아야 하므로, 파이프라인에서는 OneHotEncoder가 안전합니다.

3. 피쳐 스케일링과 정규화

x-평균은 특징이 됨. (normal 평균보다 얼마나 차이가 난다.)

3.1 스케일링이 필요한 이유

피쳐 스케일링(Feature Scaling)은 서로 다른 변수의 값 범위를 일정한 수준으로 맞추는 작업입니다. 예를 들어 나이(0~100)와 연봉(0~100,000,000)이 함께 있으면, 거리 기반 알고리즘은 숫자가 큰 연봉에만 좌우됩니다. 범위가 다름..

방식	설명	결과 범위
표준화 (Standardization)	평균이 0, 분산이 1인 가우시안 정규 분포를 가진 값으로 변환 $(x - \text{평균}) / \text{표준편차}$	제한 없음 (대부분 -3 ~ 3)
정규화 (Normalization)	서로 다른 피쳐의 크기를 0~1 사이로 통일 $(x - \text{최솟값}) / (\text{최댓값} - \text{최솟값})$	0 ~ 1

■ 스케일링이 특히 중요한 알고리즘

SVM, 선형 회귀, 로지스틱 회귀는 데이터가 가우시안 분포를 가진다고 가정하므로 표준화가 성능에 큰 영향을 줍니다. K-Means, KNN 등 거리 기반 알고리즘도 스케일링이 필수입니다. 반면 결정 트리 계열은 분기 기준만 사용하므로 스케일링이 거의 영향을 주지 않습니다.

3.2 StandardScaler : 스케일러(원래 Data의 범위를 일정하게 만드는 기능)

먼저 변환 전 붓꽃 데이터의 평균과 분산을 확인합니다.

컬럼 { S_L
S_W
P_L
P_W

평균 / 분산 확인 => 범위가 일정하지 않음을 확인. => (평균으로부터 얼마나 떨어져 있는지 확인.)

확인한 이후 SS

```

from sklearn.datasets import load_iris
import pandas as pd
# 붓꽃 데이터 셋을 로딩하고 DataFrame으로 변환합니다.
iris = load_iris()
iris_data = iris.data
iris_df = pd.DataFrame(data=iris_data, columns=iris.feature_names)

print('feature 들의 평균 값')
print(iris_df.mean())
print('\nfeature 들의 분산 값')
print(iris_df.var())

```

줄	코드	상세 설명
6	iris_df = pd.DataFrame(data=iris_data, columns=iris.feature_names)	ndarray를 DataFrame으로 변환해 통계를 보기 쉽게 만듭니다.
9	iris_df.mean()	컬럼별 평균 입니다. 5.84, 3.06, 3.76, 1.20으로 제각각 입니다.
11	iris_df.var()	컬럼별 분산 입니다. 0.19에서 3.12까지 16배 이상 차이 가 납니다.

▶ 실행 결과

```

feature 들의 평균 값
sepal length (cm)    5.843333
sepal width (cm)     3.057333
petal length (cm)    3.758000
petal width (cm)     1.199333
dtype: float64

```

```

feature 들의 분산 값
sepal length (cm)    0.685694
sepal width (cm)     0.189979
petal length (cm)    3.116278
petal width (cm)     0.581006
dtype: float64

```

```

from sklearn.preprocessing import StandardScaler

# StandardScaler객체 생성
scaler = StandardScaler()
# StandardScaler 로 데이터 셋 변환. fit( ) 과 transform( ) 호출.
scaler.fit(iris_df)  x-m / std
iris_scaled = scaler.transform(iris_df)  표준화 변환

#transform( )시 scale 변환된 데이터 셋이 numpy ndarray로 반환되어 이를 DataFrame으로 변환
iris_df_scaled = pd.DataFrame(data=iris_scaled, columns=iris.feature_names)
print('feature 들의 평균 값')
print(iris_df_scaled.mean())
print('\nfeature 들의 분산 값')
print(iris_df_scaled.var())

```

줄	코드	상세 설명
4	scaler = StandardScaler()	표준화 스케일러 객체를 생성합니다.
6	scaler.fit(iris_df)	각 컬럼의 평균과 표준편차를 계산해 기억 합니다. 아직 데이터는 바뀌지 않습니다.

7	<code>iris_scaled = scaler.transform(iris_df)</code>	기억한 평균·표준편차로 $(x - \text{평균}) / \text{표준편차}$ 계산을 수행합니다. 반환값은 DataFrame이 아니라 ndarray 입니다.
10	<code>iris_df_scaled = pd.DataFrame(data=iris_scaled, columns=iris.feature_names)</code>	ndarray를 다시 DataFrame으로 되돌립니다. 컬럼명이 사라지므로 다시 지정해 주는 것이 중요합니다.
12~15	<code>mean() / var()</code>	변환 후 평균은 0에 가까운 값 , 분산은 1에 가까운 값 이 됩니다.

▶ 실행 결과

```
feature 들의 평균 값
sepal length (cm)  -1.690315e-15
sepal width (cm)   -1.842970e-15
petal length (cm)  -1.698641e-15
petal width (cm)   -1.409243e-15
dtype: float64

feature 들의 분산 값
sepal length (cm)   1.006711
sepal width (cm)    1.006711
petal length (cm)   1.006711
petal width (cm)    1.006711
dtype: float64
```

■ 결과 해석 - 왜 정확히 0과 1이 아닌가

- 평균이 $-1.69e-15$ 처럼 표시되는 것은 **0.000000000000000169**를 의미합니다. 이론적으로는 0이지만 **부동소수점 연산의 미세한 오차**로 완전한 0이 되지 않을 뿐, 사실상 0입니다.
- 분산이 1.0067인 이유는 판다스의 `var()` 가 기본적으로 **표본 분산($n-1$ 로 나눔)**을 계산하는 반면, 사이킷런은 **모분산(n 으로 나눔)**을 사용하기 때문입니다. 150개 데이터에서 $150/149 \approx 1.0067$ 의 차이가 발생합니다. `var(ddof=0)` 으로 계산하면 정확히 1.0이 나옵니다.
- 네 피처의 분산이 **모두 동일**해졌다는 점이 핵심입니다. 이제 어떤 피처도 크기 때문에 과도한 영향을 주지 않습니다.

3.3 MinMaxScaler

```
from sklearn.preprocessing import MinMaxScaler

# MinMaxScaler 객체 생성
scaler = MinMaxScaler()
# MinMaxScaler 로 데이터 셋 변환. fit() 과 transform() 호출.
scaler.fit(iris_df)
iris_scaled = scaler.transform(iris_df)

# transform()시 scale 변환된 데이터 셋이 numpy ndarray로 반환되어 이를 DataFrame으로 변환
iris_df_scaled = pd.DataFrame(data=iris_scaled, columns=iris.feature_names)
print('feature들의 최솟값')
print(iris_df_scaled.min())
print('\nfeature들의 최댓값')
print(iris_df_scaled.max())
```

줄	코드	상세 설명
4	<code>scaler = MinMaxScaler()</code>	0~1 범위로 정규화하는 스케일러입니다. 사용법은 StandardScaler와 완전히 동일 합니다 — 이것이 사이킷런 API의 일관성입니다.

6	<code>scaler.fit(iris_df)</code>	각 컬럼의 최솟값 과 최댓값 을 계산해 기억합니다.
7	<code>iris_scaled = scaler.transform(iris_df)</code>	$(x - \text{최솟값}) / (\text{최댓값} - \text{최솟값})$ 을 적용합니다.
12~15	<code>min() / max()</code>	모든 피처의 최솟값이 정확히 0 , 최댓값이 정확히 1 이 되었습니다.

▶ 실행 결과

```
feature들의 최솟값
sepal length (cm)    0.0
sepal width (cm)     0.0
petal length (cm)    0.0
petal width (cm)     0.0
dtype: float64
```

```
feature들의 최댓값
sepal length (cm)    1.0
sepal width (cm)     1.0
petal length (cm)    1.0
petal width (cm)     1.0
dtype: float64
```

■ StandardScaler vs MinMaxScaler 선택 기준

- **StandardScaler** : 데이터가 **정규 분포에 가깝고** 이상치가 적을 때. 선형 모델·SVM에 적합합니다.
- **MinMaxScaler** : 값의 범위를 **명확히 제한**해야 할 때(이미지 픽셀, 신경망 입력 등). 단, **이상치에 매우 취약**합니다 — 극단 값 하나가 최댓값이 되면 나머지 값들이 0 근처로 몰립니다.
- 이상치가 많다면 중앙값과 사분위수를 쓰는 **RobustScaler** 를 고려하세요.

4. 학습/테스트 데이터의 스케일링 변환 시 유의사항

이 절은 실무에서 가장 많은 실수가 발생하는 부분이므로 특히 주의 깊게 봐야 합니다.

4.1 실습용 데이터 생성

```
from sklearn.preprocessing import MinMaxScaler
import numpy as np

# 학습 데이터는 0 부터 10까지, 테스트 데이터는 0 부터 5까지 값을 가지는 데이터 세트로 생성
# Scaler클래스의 fit(), transform()은 2차원 이상 데이터만 가능하므로 reshape(-1, 1)로 차원 변경
train_array = np.arange(0, 11).reshape(-1, 1)
test_array = np.arange(0, 6).reshape(-1, 1)
```

줄	코드	상세 설명
6	<code>train_array = np.arange(0, 11).reshape(-1, 1)</code>	0~10 의 11개 값을 가진 학습 데이터를 만듭니다. <code>reshape(-1, 1)</code> 로 (11, 1) 2차원 으로 변환합니다 — 스케일러가 2차원만 받기 때문입니다.
7	<code>test_array = np.arange(0, 6).reshape(-1, 1)</code>	0~5 의 6개 값을 가진 테스트 데이터입니다. 학습 데이터와 값의 범위가 다르다 는 점이 이 실습의 핵심입니다.

4.2 잘못된 사례 - 테스트 데이터에 fit() 재호출

```
# MinMaxScaler 객체에 별도의 feature_range 파라미터 값을 지정하지 않으면 0~1 값으로 변환
scaler = MinMaxScaler()

# fit()하게 되면 train_array 데이터의 최솟값이 0, 최댓값이 10으로 설정.
scaler.fit(train_array)

# 1/10 scale로 train_array 데이터 변환함. 원본 10-> 1로 변환됨.
train_scaled = scaler.transform(train_array)

print('원본 train_array 데이터:', np.round(train_array.reshape(-1), 2))
print('Scale된 train_array 데이터:', np.round(train_scaled.reshape(-1), 2))
```

줄	코드	상세 설명
5	scaler.fit(train_array)	학습 데이터의 최솟값 0, 최댓값 10 을 기억합니다.
8	train_scaled = scaler.transform(train_array)	0~10이 0~1로 변환 됩니다. 즉 1/10 스케일 이 적용되어 원본 1은 0.1, 5는 0.5, 10은 1이 됩니다.
11	np.round(train_scaled.reshape(-1), 2)	2차원을 reshape(-1) 로 1차원으로 펼쳐 보기 좋게 출력합니다.

▶ 실행 결과

```
원본 train_array 데이터: [ 0  1  2  3  4  5  6  7  8  9 10]
Scale된 train_array 데이터: [0.  0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1. ]
```

```
# MinMaxScaler에 test_array를 fit()하게 되면 원본 데이터의 최솟값이 0, 최댓값이 5로 설정됨
scaler.fit(test_array)

# 1/5 scale로 test_array 데이터 변환함. 원본 5->1로 변환.
test_scaled = scaler.transform(test_array)

# test_array의 scale 변환 출력.
print('원본 test_array 데이터:', np.round(test_array.reshape(-1), 2))
print('Scale된 test_array 데이터:', np.round(test_scaled.reshape(-1), 2))
```

줄	코드	상세 설명
2	scaler.fit(test_array)	여기가 치명적인 실수입니다. 같은 scaler 객체에 테스트 데이터로 다시 fit() 을 호출하면, 기억하고 있던 학습 데이터의 기준(0~10) 이 지워지고 테스트 데이터 기준(0~5)으로 덮어써집니다.
5	test_scaled = scaler.transform(test_array)	이제 1/5 스케일 이 적용됩니다. 원본 5가 1로 변환됩니다.
8~9	print(...)	결과를 보면 0, 0.2, 0.4, 0.6, 0.8, 1 로 변환되었습니다.

▶ 실행 결과

```
원본 test_array 데이터: [0 1 2 3 4 5]
Scale된 test_array 데이터: [0.  0.2 0.4 0.6 0.8 1. ]
```

⚠ 무엇이 잘못되었는가 - 같은 값이 다른 숫자가 된다

학습 데이터에서 원본 5는 0.5로 변환되었는데, 테스트 데이터에서는 원본 5가 1.0으로 변환되었습니다. 동일한 원본 값이 서로 다른 값으로 스케일링된 것입니다.

모델은 "0.5 = 원본 5"라고 학습했는데 예측 시에는 "1.0 = 원본 5"인 데이터를 받게 되므로, 예측 결과가 완전히 어긋납니다. 학습과 예측의 기준이 달라지는 이 문제는 오류 메시지 없이 조용히 성능만 떨어뜨리기 때문에 더욱 위험합니다.

4.3 올바른 사례 - transform()만 호출

```
scaler = MinMaxScaler()
scaler.fit(train_array)
train_scaled = scaler.transform(train_array)
print('원본 train_array 데이터:', np.round(train_array.reshape(-1), 2))
print('Scale된 train_array 데이터:', np.round(train_scaled.reshape(-1), 2))

# test_array에 Scale 변환을 할 때는 반드시 fit()을 호출하지 않고 transform() 만으로 변환해야 함.
test_scaled = scaler.transform(test_array)
print('\n원본 test_array 데이터:', np.round(test_array.reshape(-1), 2))
print('Scale된 test_array 데이터:', np.round(test_scaled.reshape(-1), 2))
```

줄	코드	상세 설명
1~2	scaler = MinMaxScaler() / scaler.fit(train_array)	스케일러를 새로 만들고 학습 데이터로만 fit()합니다. 기준: 최솟값 0, 최댓값 10.
3	train_scaled = scaler.transform(train_array)	학습 데이터를 1/10 스케일로 변환합니다.
8	test_scaled = scaler.transform(test_array)	핵심입니다. fit() 을 다시 호출하지 않고 transform() 만 호출합니다. 학습 데이터에서 만든 1/10 기준이 그대로 적용되어 원본 5가 0.5로 변환됩니다.
10	print(...)	테스트 결과가 0, 0.1, 0.2, 0.3, 0.4, 0.5로 학습 데이터와 완벽히 동일한 척도를 갖게 되었습니다.

▶ 실행 결과

```
원본 train_array 데이터: [ 0  1  2  3  4  5  6  7  8  9 10]
Scale된 train_array 데이터: [0.  0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1. ]

원본 test_array 데이터: [0 1 2 3 4 5]
Scale된 test_array 데이터: [0.  0.1 0.2 0.3 0.4 0.5]
```

■ 반드시 기억할 규칙

1. 가능하다면 전체 데이터를 나누기 전에 스케일링을 먼저 수행합니다.
2. 그것이 어렵다면, 테스트 데이터에는 절대 fit() 이나 fit_transform() 을 사용하지 말고 학습 데이터로 fit한 객체의 transform() 만 호출합니다.
3. 이 원칙은 모든 전처리 클래스(스케일러, 인코더, Imputer 등)에 동일하게 적용됩니다.

실무에서는 Pipeline 을 사용하면 이 규칙이 자동으로 지켜지므로 실수를 원천적으로 방지할 수 있습니다.

```
pipe = make_pipeline(MinMaxScaler(), DecisionTreeClassifier())
```

5. 핵심 요약 및 머신러닝 활용 포인트

5.1 핵심 API 요약표

구분	API	기능	주의 사항
인코딩	<code>LabelEncoder</code>	문자열 → 코드 숫자	크기 관계 발생. 선형 모델에는 부적합 <code>classes_</code> , <code>inverse_transform()</code> 활용
	<code>OneHotEncoder</code>	고유값 수만큼 컬럼 생성	2차원 입력 필요 , 결과는 희소 행렬 <code>sparse_output=False</code> 로 밀집 행렬 반환
	<code>pd.get_dummies()</code>	판다스 원-핫 인코딩	한 줄로 처리, 컬럼명 자동 생성 pandas 2.x부터 bool 반환
스케일링	<code>StandardScaler</code>	평균 0, 분산 1로 표준화	정규 분포 가정 알고리즘에 유리
	<code>MinMaxScaler</code>	0~1 범위로 정규화	이상치에 취약
	<code>RobustScaler</code>	중앙값·IQR 기준 변환	이상치가 많을 때 권장
공통 메서드	<code>fit()</code>	변환 기준 학습	학습 데이터에만 호출
	<code>transform()</code>	실제 변환 수행	학습·테스트 데이터 모두에 호출
	<code>fit_transform()</code>	두 작업을 한 번에	테스트 데이터에는 사용 금지

5.2 인코딩 방식 선택 가이드

상황	권장 방식	이유
결정 트리 계열 모델	레이블 인코딩	숫자 크기를 해석하지 않아 문제 없음. 차원도 늘지 않음
선형 회귀·로지스틱·SVM	원-핫 인코딩	레이블 인코딩의 크기 관계가 가중치를 왜곡함
고유값이 매우 많은 피처	상위 값 묶기 후 인코딩	원-핫은 차원 폭발, 레이블은 의미 왜곡
순서가 있는 카테고리 (초급<중급<고급)	레이블/순서 인코딩	크기 관계가 실제로 의미가 있는 경우

5.3 머신러닝 활용 포인트

- **전처리 순서** : 결측치 처리 → 불필요 피처 제거 → 인코딩 → 스케일링 순으로 진행하는 것이 일반적입니다.
- **알고리즘에 맞는 전처리** : 트리 계열은 스케일링이 거의 불필요하지만, 선형·거리 기반 모델은 필수입니다. 무조건 다 적용하기보다 **모델 특성을 고려**하세요.
- **데이터 누수(Data Leakage) 방지** : 테스트 데이터의 통계 정보가 전처리 과정에 스며들면 성능이 부풀려집니다. `fit` 은 반드시 학습 데이터에만 적용하세요.
- **Pipeline 활용** : 전처리와 모델을 하나로 묶으면 교차 검증에서도 폴드마다 올바르게 fit/transform이 적용되어 **누수를 자동으로 방지**합니다.
- **변환 후 검증** : 스케일링 후 평균·분산·최솟값·최댓값을 직접 출력해 **의도대로 변환되었는지 확인**하는 습관을 들이세요.

⚠ 안정화 버전 참고

- **scikit-learn 1.2+** : `OneHotEncoder` 의 `sparse` → `sparse_output` 으로 변경(1.4에서 구 파라미터 제거).
- **pandas 2.0+** : `get_dummies( )` 결과가 0/1 정수에서 **True/False(bool)**로 변경. `dtype=int` 로 기존 동작 유지 가능.
- `LabelEncoder` 는 원래 **레이블(y) 전용**으로 설계된 클래스입니다. 피처(X)의 카테고리 인코딩에는 `OrdinalEncoder` 를 쓰는 것이 사이킷런의 공식 권장 사항입니다. 다만 교재와 실무에서는 관행적으로 피처에도 널리 사용됩니다.