

인터넷 검색을 활용해 답변하는 챗봇 만들기

언어 모델은 학습한 데이터 내에서만 답변을 생성하므로 학습한 시점 이후의 최신 정보를 물어보면 정확히 답을 하지 못합니다. 하지만 언어 모델에게 인터넷 검색이나 유튜브 검색 기능을 추가하면 최신 자료를 바탕으로 답변을 제공할 수 있습니다. 이 장에서는 랭체인 기능을 활용하여 인터넷과 유튜브에서 검색한 후 답변을 생성하는 챗봇에 대해 다루겠습니다.



- 10-1 인터넷 검색 후 답변하기 — 덕덕고 검색
- 10-2 자료 조사 후 기사 쓰기 — 타빌리 검색
- 10-3 유튜브 영상 요약하기
- 10-4 웹과 유튜브 검색을 활용한 챗봇 만들기



10-1 인터넷 검색 후 답변하기 – 덕덕고 검색

랭체인은 구글 검색 [Google Search](#), Bing 검색 [Bing Search](#), 덕덕고 검색 [DuckDuckGo Search](#), 타빌리 검색 [Tavily Search](#) 등 다양한 도구를 제공하여 인터넷 검색 기능을 추가할 수 있습니다. 이번 실습에서는 무료로 사용할 수 있는 덕덕고 검색 엔진을 사용하겠습니다. 덕덕고는 ‘사용자의 데이터를 수집하지 않는다’는 메시지를 강력히 내세우는 검색 엔진입니다. 온라인 활동의 프라이버시를 보장한다는 장점이 있죠. 또한 API를 무료로 제공하므로 검색 결과를 언어 모델과 결합한 프로그램을 개발하려는 사람에게 유용합니다. 만약 여러분이 만드는 프로그램에 구글 검색이나 Bing 검색 기능이 꼭 필요하다면 덕덕고 검색 대신 원하는 도구를 선택해도 됩니다.

Do it! 실습 GPT에 인터넷 검색 기능 추가하기

■ 결과 파일: chap10/sec01/duckduckgo.ipynb

세상 모든 것을 다 알 것 같은 GPT지만 ‘요즘 블랙핑크 로제가 발표한 신곡은 무엇인가요?’와 같은 질문을 한다면 정확한 답변을 기대하기 어렵습니다. GPT 모델 자체는 학습한 시점까지의 정보만 갖고 있기 때문입니다.

◆ 이 절의 예제는 2024년 11월 기준으로 작성되었습니다. 여러분이 책을 읽는 시점에 화제가 되고 있는 뉴스나 사건을 키워드로 검색하길 바랍니다.

1. 새 파일 `duckduckgo.ipynb`를 만들고 주피터 노트북에서 언어 모델을 `gpt-4o-mini`로 설정합니다. 그리고 최근 블랙핑크 멤버 로제가 발표한 곡은 무엇인지 물어보았습니다.

최신 정보를 알려 주지 못하는 GPT

duckduckgo.ipynb (1)

```
from langchain_openai import ChatOpenAI

model = ChatOpenAI(model="gpt-4o-mini")
model.invoke("최근 로제가 발표한 신곡은 무엇인가요?")
```

셀을 실행하면 다음과 같이 답변합니다.

제가 알고 있는 정보에 따르면, 로제는 2021년 "On The Ground"와 "GONE"이라는 솔로 곡을 발표했습니다. 그러나 2023년 이후의 신곡에 대한 정보는 업데이트되지 않았습니다. 최신 소식을 확인하려면 공식 팬 사이트나 음악 플랫폼을 참고하시기 바랍니다.

이 질문을 한 2024년 11월을 기준으로 로제가 발표한 신곡은 'A.P.T.'입니다. GPT의 답변은 너무 오래된 정보입니다. 이처럼 이미 'A.P.T.'라는 곡이 전 세계적으로 엄청난 인기를 끌고 있지만 GPT는 이와 관련한 정보를 알지 못합니다. 이제 덕덕고 검색을 활용해 웹 검색 기능을 추가해보겠습니다.

2. 덕덕고 검색을 위한 패키지를 설치합니다.

 덕덕고 검색 설치하기

 duckduckgo.ipynb (2)

```
%pip install -U duckduckgo-search
```

3. DuckDuckGoSearchResults 클래스를 사용하여 덕덕고에서 검색 결과를 가져오는 코드를 작성합니다. `results_separator` 파라미터를 `';\n'`으로 설정하여 검색 결과를 구분하는 방식을 지정하고 `invoke()` 메서드로 검색 쿼리를 전송합니다. 검색 결과는 `docs` 변수에 저장되며 `print()`를 사용해 이를 출력할 수 있습니다.

 덕덕고 검색 테스트하기

 duckduckgo.ipynb (3)

```
from langchain_community.tools import DuckDuckGoSearchResults

search = DuckDuckGoSearchResults(results_separator=';\n')
docs = search.invoke("최근 로제가 발표한 신곡은 무엇인가요?")

print(docs)
```

코드를 실행하면 다음과 같이 검색 결과인 스니펫과
기사 제목, 해당 페이지의 링크가 반환됩니다.

◆ 스니펫(snippet)은 작은 정보나 소식 또는 대화나 음악 등에서 한 토막을 뜻합니다.

```
snippet: 블랙핑크의 로제가 팝스타 브루노 마스와 듀엣한 '아파트'(APT.)로 미국 빌보드 메인 싱글 차트 '핫 100'에 8위로 데뷔하며 K팝 여성 가수 최고 순위를 기록했다. 미국 빌보드는 29일 공식 사회관계망서비스(SNS)를 통해 '아파트'가 빌리 아일리시의 '버즈 오브 어 페더 ...', title: 로제 '아파트' 빌보드 핫100 8위...유비 2억뷰 '눈앞'(종합2보) | 연합뉴스, link: https://www.yna.co.kr/view/AKR20241028127352005;
```

(... 생략 ...)

```
snippet: 로제가 오는 12월 첫 정규 앨범 '로지'에 앞서 선보이는 앨범 공개 시각은 18일 오후 1시다. 앨범에는 로제가 직접 작사·작곡에 참여한 12곡의 음악이 담길 예정이며, 브루노 마스와 함께 나온 사진을 공식 SNS에 게시했다., title: 블랙핑크 로제, 브루노 마스와 듀엣곡 '아파트' 발표 - 경향신문, link: https://www.khan.co.kr/culture/culture-general/article/202410181031001;
```

(... 생략 ...)

4. 이제 웹 검색을 문맥에 맞게 더 잘 수행하기 위해 질의 확장을 구현해 보겠습니다. 다음은 09-2절에서 RAG를 구성할 때 사용한 프롬프트와 체인 코드입니다. question_answering_prompt는 코드를 그대로 가져오고 document_chain은 이전에 사용했던 create_stuff_documents_chain 대신 LCEL 방식으로 프롬프트 바로 뒤에 | 연산자로 GPT 모델만 연결하여 구현합니다.

◆ LCEL을 자세히 알고 싶다면 08-2절을 참고하세요.

질의 확장 구현하기

duckduckgo.ipynb (4)

```
from langchain_core.prompts import ChatPromptTemplate, MessagesPlaceholder

question_answering_prompt = ChatPromptTemplate.from_messages(
    [
        (
            "system",
            "아래 context에 기반하여 사용자의 질문에 답변하라.\n\n{context}",
        ),
        MessagesPlaceholder(variable_name="messages"),
    ]
)

document_chain = question_answering_prompt | model
```


5. 사용자와 나눈 메시지를 저장하고 그 내용을 활용해 `document.chain`으로 AI 답변을 생성합니다. 그리고 AI의 메시지를 저장하고 결과를 출력하는 코드를 작성합니다. 다음 코드도 09-2절에서 RAG를 만들 때 사용한 코드를 그대로 가져왔습니다.



메시지 저장하고 답변 생성 후 출력하기

duckduckgo.ipynb (5)

```
from langchain.memory import ChatMessageHistory

# 채팅 메시지를 저장할 메모리 객체 생성
chat_history = ChatMessageHistory()
# 사용자 질문을 메모리에 저장
chat_history.add_user_message("요즘 로제가 발표한 신곡은 무엇인가요?")

# 문서 검색하고 답변 생성
answer = document_chain.invoke(
    {
        "messages": chat_history.messages,
        "context": docs,
    }
)

# 생성된 답변을 메모리에 저장
chat_history.add_ai_message(answer)

print(answer)
```

코드를 실행하면 다음과 같이 최신 정보가 반환됩니다. 현재 인터넷에서 검색된 결과를 바탕으로 2024년 11월의 최신 정보로 답변을 제공합니다.

```
content=" 로제가 최근 발표한 신곡은 '아파트'(APT.)입니다. 이 곡은 팝스타 브루노 마스와의 듀엣으로, 미국 빌보드 '핫 100' 차트에서 8위로 데뷔하며 K팝 여성 가수 최고 순위를 기록했습니다"
(... 생략 ...)
```

Do it! 실습 검색 기능에 옵션 설정하기

결과 파일: sec01/duckduckgo.ipynb

답변에 사용할 정보를 최근 소식이나 뉴스, 특정 웹 사이트로만 한정하고 싶을 수 있습니다. 이런 경우 API 래퍼 `Wrapper`를 사용하여 검색 옵션을 설정할 수 있습니다

최신 뉴스 기사만 검색하기

DuckDuckGoSearchAPIWrapper를 활용해 검색 지역과 기간을 설정해 보겠습니다.

1. `region`을 "kr-kr"로 설정해 검색 결과를 '한국-한국어 우선'으로 설정합니다. 이어서 `time`을 "w"로 입력해 최근 일주일 내의 검색 결과만 가져옵니다. 최근 일주일은 'w', 1개월은 'm', 하루는 'd'로 설정하면 됩니다.

◆ 지역별 설정을 자세히 알고 싶다면 <https://pypi.org/project/duckduckgo-search/#regions>에서 확인하세요

최근 일주일 뉴스만 검색하기

duckduckgo.ipynb (6)

```
# DuckDuckGo API 래퍼를 사용하여 검색할 때 검색 매개변수를 설정하는 클래스 import
from langchain_community.utilities import DuckDuckGoSearchAPIWrapper

# 한국 지역("kr-kr")을 기준, 최근 일주일("w") 내의 검색 결과를 가져오도록 초기화
wrapper = DuckDuckGoSearchAPIWrapper(region="kr-kr", time="w")
```

2. `api_wrapper`를 `wrapper`로 설정합니다. DuckDuckGoSearchAPIWrapper를 DuckDuckGoSearchResults에 전달해 앞에서 설정한 지역과 기간 옵션을 적용합니다. 그리고 `source`를 "news"로 설정해 뉴스 소스만을 검색하도록 지정합니다. 소스를 뉴스로 한정하면 좀 더 신뢰할 수 있는 최신 소식을 확인할 수 있습니다. 이어서 `results_separator`를 설정해 검색 결과를 보기 좋게 줄 바꿈 합니다.

뉴스 소스 위주로 검색하도록 지정하기

duckduckgo.ipynb (7)

```
# 검색 기능을 위한 DuckDuckGoSearchResults 초기화
search = DuckDuckGoSearchResults(
    api_wrapper=wrapper,      # 앞에서 정의한 API 래퍼를 사용
    source="news",           # 뉴스 소스에서만 검색하도록 지정
    results_separator=';\n'  # 결과 항목 사이에 구분자 사용(세미콜론과 줄 바꿈)
)
```

3. `search.invoke()`로 검색을 수행하여 결과를 반환하고 `print(docs)`로 출력합니다.

검색 결과 반환하고 출력하기

 duckduckgo.ipynb (8)

```
# "로제의 신곡 APT에 대한 반응"을 검색하고 결과를 docs에 저장
docs = search.invoke("로제의 신곡 APT에 대한 반응")

# 검색 결과 출력
print(docs)
```

코드를 실행하면 최근 일주일 동안의 기사만 검색됩니다.

```
snippet: 전 세계가 블랙핑크 로제의 신곡 '아파트(apt.)' 매력에 흠뻑 빠져들고 있다. 로제가 미국 팝
스타 브루노 마스와 함께 부른 아파트는 10월 18일 공개 하루 만에 국내 주요 음원 차트 1위를 석권했으
며, 세계 3대 음악 스트리밍 플랫폼인 스포티파이 글로벌 차트 ..., title: '소맥' 즐기는 로제, K팝 새
역사 썼다 | 주간동아, link: https://weekly.donga.com/culture/article/all/11/5259649/1;
snippet: 로제의 《apt.》가 주목받으면서 윤수일의 《아파트》도 원조 '아파트'로 화제가 됐다. 노래
의 연관성은 없지만 제목이 같다는 이유에서다. 로제의 아파트는 신축이고 윤수일의 아파트는 구축이라고
들 한다. ... '체육 대통령'에 한 발 더 내딘 이기홍 대한 ..., title: 로제의 《Apt.》가 세계를 강
타했다 < 연예 > 기사본문 - 시사저널, link: https://www.sisajournal.com/news/articleView.
html?idxno=313003;
(... 생략 ...)
```

최근 일주일로 검색 기간을 제한하면 여러분이 책을 읽는 시점에는 검색 결과가 달라질 수 있습니다. 책을 읽는 시점에 이슈가 되고 있는 주제로 검색해 보세요.

특정 웹 사이트에서 검색하기

인터넷 전체가 아니라 특정 웹 사이트 내에서만 검색 결과를 가져올 수 있습니다.

`search.invoke()`의 쿼리문에 `site:ytn.co.kr`을 추가하여 특정 웹 사이트를 지정합니다.

‘ytn.co.kr’ 위치에 원하는 웹 사이트 주소를 넣으
면 됩니다.

◆ 이 책을 읽는 시점의 최신 뉴스를 검색하세요. 최근 일주일 동안의 기사만 가져오므로 이 책에서 사용한 키워드를 검색하면 엉뚱한 결과가 나올 수 있습니다.

특정 웹 사이트 지정하기

 duckduckgo.ipynb (9)

```
# DuckDuckGo를 이용해 ytn.co.kr 웹 사이트에서 로제의 신곡 APT에 대한 분석을 검색
docs = search.invoke("site:ytn.co.kr 로제의 신곡 APT에 대한 분석")
docs
```

실행하면 주소가 'ytn.co.kr'인 웹 사이트에서 검색한 내용만 결과로 보여 줍니다.

```
'snippet: 6일(현지 시간) 미국 음악 전문 매체 빌보드에 따르면, 로제의 \'아파트\'가 빌보드 메인 음
원 차트인 \'핫(hot) 100\' 5위에 등극했다. 이는 k팝 여성 아티스트 중 최고 기록이다. 지난해 10월
18일 발매된 로제의 \'아파트\'는 이 차트에 8위로 진입한 이후 꾸준히 머물렀다., title: [가요]로제
\'아파트\', 신년에도 흥행 계속...미국 빌보드 핫 100 최고 기록 달성 | Ytn, link: https://star.
ytn.co.kr/_sn/0117_202501071627338403;\nsnippet: 로제의 눈부셨던 2024년 "힘든 여정, 친구·
팬들 덕에 이겨내" ... 가수 로제가 2024년에 대한 소회와 함께 팬들을 향한 감사 인사를 전했다. 로제는
오늘(7일) 자신의 인스타그램에 "2024년은 제게 가장 힘들었지만, 동시에 가장 보람 있는 한 해였다"며 장
문의 ..., title: [가요]로제의 눈부셨던 2024년 "힘든 여정, 친구·팬들 덕에 이겨내" | Ytn, link:
https://star.ytn.co.kr/_sn/0117_202501071436231818
(... 생략 ...)
```

Do it! 실습 기사 링크 가져오기

결과 파일: sec01/duckduckgo.ipynb

앞서 덕덕고를 사용할 때 스니펫과 제목을 활용한 짧은 내용으로 결과를 생성했습니다. 상황에 따라 검색된 링크의 본문 정보까지 활용하여 더 상세한 답을 얻고 싶을 수도 있습니다. DuckDuckGoSearchResult로 검색한 결과에는 페이지의 링크가 포함되어 있으므로 URL을 이용해 웹 페이지의 텍스트를 가져올 수 있습니다.

1. ducduckgo.ipynb 파일에 이어서 작성하겠습니다. 우선 가져온 link를 확인해 봅시다.

링크 확인하기

duckduckgo.ipynb (10)

```
# 검색 결과의 링크들을 저장할 빈 리스트 초기화
links = []

# 검색 결과를 세미콜론과 줄 바꿈 기준으로 분리하고, 각 결과 항목에서 링크 추출
for doc in docs.split(";\\n"):
    print(doc)                                # 각 검색 결과 항목을 출력하여 확인
    link = doc.split("link:")[1].strip()      # 각 항목에서 'link:' 이후의 URL 부분만 추출
    links.append(link)                        # 추출한 링크를 리스트에 추가

# 모든 링크를 출력
print(links)
```


셀을 실행하면 다음처럼 검색으로 가져온 링크가 표시됩니다.

```
snippet: 6일(현지 시간) 미국 음악 전문 매체 빌보드에 따르면, 로제의 '아파트'가 빌보드 메인 음원 차트인 '핫(hot) 100' 5위에 등극했다. 이는 k팝 여성 아티스트 중 최고 기록이다. 지난해 10월 18일 발매된 로제의 '아파트'는 이 차트에 8위로 진입한 이후 꾸준히 머물렀다., title: [가요]로제 '아파트', 신년에도 흥행 계속...미국 빌보드 핫 100 최고 기록 달성 | Ytn, link: https://star.ytn.co.kr/_sn/0117_202501071627338403
snippet: 로제의 눈부셨던 2024년 "힘든 여정, 친구·팬들 덕에 이겨내" ... 가수 로제가 2024년에 대한 소회와 함께 팬들을 향한 감사 인사를 전했다. 로제는 오늘(7일) 자신의 인스타그램에 "2024년은 제게 가장 힘들었지만, 동시에 가장 보람 있는 한 해였다"며 장문의 ..., title: [가요]로제의 눈부셨던 2024년 "힘든 여정, 친구·팬들 덕에 이겨내" | Ytn, link: https://star.ytn.co.kr/_sn/0117_202501071436231818
(... 생략 ...)

['https://star.ytn.co.kr/_sn/0117_202501071627338403', 'https://star.ytn.co.kr/_sn/0117_202501071436231818', 'https://www.ytn.co.kr/_ln/0103_202501071142587708',
(... 생략 ...)]
```

각 기사의 링크를 클릭했을 때 열리는 웹 페이지 내용을 가져오겠습니다. 랭체인에서 제공하는 WebBaseLoader를 사용하면 링크의 내용을 읽어 올 수 있습니다.

2. links 리스트를 WebBaseLoader의 web_paths로 지정하고 각 웹 페이지의 내용을 읽어 옵니다. 여러 웹 페이지를 동시에 읽어 오기 위해 비동기 함수 `alazy_load()`로 웹 페이지를 비동기 방식으로 불러옵니다. 이렇게 처리하면 웹 브라우저에서 창을 여러 개 띄워 놓고 검색하는 효과가 있어 작업을 더 빠르게 마칠 수 있습니다.

 웹 페이지 내용을 비동기로 읽어 오기

 duckduckgo.ipynb (11)

```
# 랭체인 WebBaseLoader를 사용하여 웹 페이지의 내용 불러오기
from langchain_community.document_loaders import WebBaseLoader

# WebBaseLoader 객체를 생성. 'links'는 웹 페이지의 URL 목록을 담고 있는 변수
# bs_get_text_kwargs는 BeautifulSoup의 get_text() 메서드에 전달될 추가 인자
loader = WebBaseLoader(
    web_paths=links, # 웹 페이지의 링크 목록을 지정
    bs_get_text_kwargs={
        "strip": True # 웹 페이지에서 텍스트를 가져올 때 앞뒤의 공백 제거
    },
)
```

```
# 비동기로 웹 페이지의 내용을 로드하고, 각 문서를 page_contents 리스트에 추가
page_contents = [] # 각 웹 페이지의 내용을 저장할 리스트
async for doc in loader.alazy_load():
    page_contents.append(doc) # 불러온 문서를 page_contents 리스트에 추가

# page_contents에 있는 각 웹 페이지의 내용 출력
for content in page_contents:
    print(content) # 웹 페이지의 내용 출력
    print('-----') # 웹 페이지를 구분하는 구분선 출력
```

셀을 실행하면 웹 페이지에 보이는 거의 모든 텍스트를 가져옵니다. 결과를 보면 기사 내용은 물론 상단과 하단, 오른쪽의 메뉴바에 들어가는 텍스트까지 모두 포함되어 있습니다.

(... 생략 ...)

통신사 연합뉴스최신기사정치정체기사대통령실/총리실국회/정당외교국방북한경제경제전체기사경제/정책금융부동산취업/창업소비자마켓 +마켓 +전체기사국내주식해외주식채권펀드/ETF글로벌시장증권/운용사리포트공
시산업산업전체기사산업/기업전기전자중화학자동차건설에너지/

(... 생략 ...)

블랙핑크의 로제가 팝스타 브루노 마스와 듀엣한 '아파트'(APT.)로 미국 빌보드 메인 싱글 차트 '핫 100'에 8위로 데뷔하며 K팝 여성 가수 최고 순위를 기록했다. 미국 빌보드는 29일 공식 사회관계망서비스(SNS)를 통해 '아파트'가 빌리 아일리시의 '버즈 오브 어 페더'(Birds Of A Feather·3위

(... 생략 ...)

에르메스 상속남 18조원 분실사건...정원사 자작극? 매니저 횡령?"훔치면 100배 변상"...일부 무인점포, 도넛은 '합의금 장사' 평창 스노보드 금메달리스트 화이트, 배우 도브레브와

(... 생략 ...)

Do it! 실습 뷰티풀수프를 이용해 특정 영역만 가져오기

■ 결과 파일: sec01/duckduckgo.ipynb


웹 페이지의 텍스트를 대부분 가져오면 불필요한 텍스트도 많이 포함됩니다. 따라서 필요한 부분의 텍스트만 가져오도록 설정해 보겠습니다. 뷰티풀수프 [BeautifulSoup](#)를 활용하면 웹 페이지에서 원하는 특정 영역의 텍스트만 가져올 수 있습니다. 뷰티풀수프는 파이썬에서 HTML이나 XML 문서를 쉽게 파싱할 수 있도록 도와주는 라이브러리로, 웹 페이지의 구조를 분석하고 특정 태그의 텍스트 등 원하는 요소를 쉽게 추출할 수 있게 해줍니다. 그래서 뷰티풀수프는 웹 스크래핑을 할 때도 많이 이용합니다.

- ◆ 파싱(parsing)은 특정 규칙에 따라 텍스트나 데이터를 분석하여 원하는 정보를 추출하는 것을 말합니다.
- ◆ 웹 스크래핑(web scraping)은 특정 웹 사이트에서 필요한 데이터를 수집하는 방법을 말합니다.




1. 크롬 브라우저에서 뉴스 웹 사이트에 접속한 후, [F12]를 눌러 개발자 도구를 열고 [요소 (Elements)]를 선택합니다.

◆ 맥에서는 [Command] + [option] + [I]를 눌러 개발자 도구를 실행하세요.




2. 현재 열려 있는 웹 페이지의 HTML 코드가 보입니다. 코드에 마우스를 올려 확인해 보면 그중에서 기사 영역만 음영으로 표시되는 요소가 있습니다. 웹 사이트마다 기사나 본문을 표시하는 영역 설정이 다르므로 개발자 도구를 사용해 본문 영역을 찾아야 합니다. 예를 들어 연합뉴스 웹 사이트에서는 <article class="story-news article"> 부분이 기사 영역입니다.



같은 뉴스 웹 사이트라도 양식은 다를 수 있습니다. 예를 들어 연합뉴스에서 검색된 내용 가운데 YTN에서 방영한 뉴스의 웹 페이지는 앞에서 살펴본 기사만 있는 웹 페이지와 달랐습니다. 웹 페이지 상단에 동영상과 있고 <article> 영역 내에 텍스트가 있었습니다.

◆ 연합뉴스 동영상 기사는 <https://www.yna.co.kr/view/MYH20241029011400641> 링크를 참고하세요.



3. 살펴본 2가지 경우에 모두 대응할 수 있도록 코드를 만들겠습니다. 다음은 주어진 URL에서 특정 <article> 태그의 내용을 가져오는 코드입니다.

주어진 URL에서 텍스트를 가져오는 함수 만들기

duckduckgo.ipynb (12)

```
import requests
from bs4 import BeautifulSoup ①

# 주어진 URL에서 기사 텍스트를 가져오는 함수
def get_article_text(url):
    try:
        # URL에 GET 요청을 보냄
        response = requests.get(url)
        # 요청이 성공하지 못하면 예외를 발생시킴
        response.raise_for_status()

        # BeautifulSoup을 사용하여 HTML 내용 파싱
        soup = BeautifulSoup(response.content, 'html.parser')

        # 클래스가 'story-news article'인 <article> 태그 찾기
        article = soup.find('article', class_='story-news article') ②

        # 기사를 찾았다면 그 텍스트를 반환
        if article:
            return article.get_text(strip=True) ②
        else:
            try:
                if soup.find('article'):
                    return soup.find('article').get_text(strip=True) ③
                elif soup.find('div', id="CmAdContent"):
                    return soup.find('div', id="CmAdContent").get_text(strip=True) ④
            except:
                return "기사 내용을 찾을 수 없습니다."

    # 요청이 실패할 경우 예외 처리
    except requests.exceptions.RequestException as e:
        return f"URL을 가져오는 중 오류 발생: {e}"
```

- ① requests와 BeautifulSoup 라이브러리를 임포트합니다. requests 라이브러리는 웹 페이지를 요청하고 BeautifulSoup은 HTML을 파싱하는 데 사용됩니다. 이 코드에서는 BeautifulSoup을 사용하여 웹 페이지에서 <article> 태그를 찾아 그 내용을 가져올 계획입니다.
- ② get_article_text(url) 함수는 주어진 URL에서 <article> 태그의 텍스트를 추출합니다. 요청이 실패하면 예외를 처리하고 클래스가 'story-news article'인 <article> 태그를 찾아 내용을 반환합니다.

- ③ 만약 해당 태그를 찾지 못하면 첫 번째 <article> 태그의 내용을 반환합니다.
- ④ 이 밖에도 여러 가지 예외 상황이 발생할 수 있으므로 오류를 확인하면서 읽을 수 있는 웹 페이지를 눌러 가도 록 노력해야 합니다. `soup.find('div', id="CmAdContent")`는 `start.yna.co.kr`로 시작하는 주소의 뉴스 웹 페이지의 형태가 달라서 적용한 예입니다.

4. 이제 주어진 URL에서 원하는 영역의 텍스트를 추출하겠습니다. `for` 문을 사용해 기사 영역의 텍스트를 출력하고 가져온 내용을 `articles`에 추가합니다.

주어진 URL에서 텍스트 가져오기

duckduckgo.ipynb (13)

```
# URL 목록의 각 링크를 반복하면서 기사 텍스트 출력
articles = [] # 가져온 내용을 리스트에 담는 변수 선언
for link in links:
    print(f"URL: {link}\n")
    article_text = get_article_text(link)
    print(f"Content:\n{article_text}")
    print("-----")
    articles.append(article_text)
```

셀을 실행하면 Content에 기사 영역의 텍스트가 출력됩니다.

URL: <https://www.yna.co.kr/view/AKR20241028127352005>

Content:
이태수기자k팝 여성 최고 순위..**英** 싱글 4위 이어 세계 양대 차트 '톱 10'"모든 이들에 감사, 내 꿈이

5. 검색된 연합뉴스 본문을 모두 활용하여 답변을 생성해 봅시다.

답변 생성하기

duckduckgo.ipynb (14)

```
chat_history.add_user_message("로제의 신곡 APT에 대한 반응")

# 문서 검색하고 답변 생성
answer = document_chain.invoke(
    {
        "messages": chat_history.messages,
        "context": docs,
    }
)
```

```
# 생성된 답변 메모리에 저장
chat_history.add_ai_message(answer)
print(answer)
```

셀을 실행해 보니 다음과 같이 답변이 구체적으로 잘 생성되었습니다.

로제의 신곡 'APT.'는 전 세계적으로 큰 반향을 일으키고 있습니다. 이 곡은 미국 빌보드 '핫 100' 차트에서 8위로 데뷔하며 K팝 여성 아티스트로서의 최고 순위를 기록했습니다. 또한, 영국 오피셜 싱글 차트에서도 4위에 올라 최상위권에 안착했습니다.

곡의 인트로와 멜로디가 귀에 잘 들어온다는 평가를 받으며, 로제와 브루노 마스의 조화로운 듀엣이 많은 사랑을 받고 있습니다. 팬들과 대중은 이 곡을 듣고 즐거움을 느끼며, 특히 로제의 팬덤인 '블링크'와 '넘버원'이 이 곡의 성공에 크게 기여하고 있습니다.

또한, 'APT.'의 뮤직비디오는 공개 5일 만에 1억 뷰를 돌파하며, 로제의 음악적 역량과 글로벌 인기를 더욱 강화하고 있습니다. 전반적으로, 'APT.'는 로제의 음악 경력을 한 단계 끌어올리는 곡으로 평가되고 있습니다.

특정 웹 사이트로 검색 범위를 한정하면 언어 모델에게 넘겨주는 텍스트를 불필요한 내용 없이 깔끔하게 정리할 수 있습니다. 이런 실행 결과를 얻으려면 이번 예제에 살펴봤듯이 해당 웹 페이지의 소스 코드를 분석하고 뷰티풀수프를 사용해 원하는 부분의 텍스트를 추출하는 작업을 해야 합니다.

물론 불필요한 내용까지 포함한 상태에서 언어 모델이 알아서 처리하게 하는 방법도 고려할 수 있습니다. 특히 특정 웹 사이트를 지정하지 않고 여러 웹 페이지에서 검색하는 경우에는 뷰티풀수프를 이용한 전처리를 하지 못하므로 언어 모델이 알아서 처리하도록 할 수밖에 없습니다. 이때 토큰을 많이 사용하는 문제뿐만 아니라 의도치 않은 내용이 답변에 포함되어 생성되는 문제가 발생할 수도 있으므로 주의해서 사용해야 합니다.

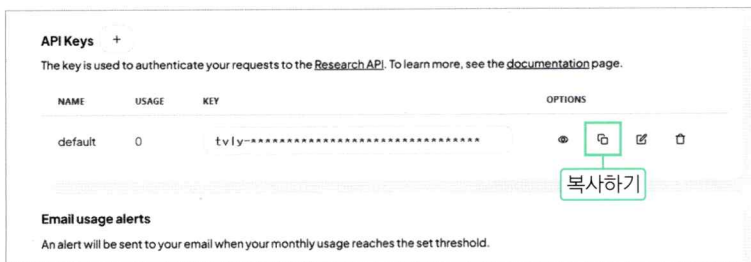
10-2 자료 조사 후 기사 쓰기 - 타빌리 검색

타빌리 검색(Tavily Search)은 덕덕고 API와 비슷한 기능을 제공하지만 유료로 구독해야 하는 서비스입니다. 그러나 안정성 측면에서 타빌리 검색의 API는 덕덕고 검색의 API에 비해 훨씬 뛰어납니다. 첫 1,000번의 API 콜은 무료로 제공되므로 이 책을 실습하는 데는 전혀 문제가 없습니다.


Do it! 실습 타빌리 활용하기

결과 파일: sec02/tavily_search.ipynb

1. 타빌리 웹 사이트(<https://tavily.com>)에 접속하여 로그인한 후, API 키를 클릭해 복사합니다.



2. 복사한 API 키를 .env 파일에 붙여 넣어 다음처럼 설정합니다.



3. 주피터 노트북 파일 tavily_search.ipynb을 생성하고 타빌리 API를 사용하기 위해 tavily-python을 설치합니다.



4. 랭체인에서 제공하는 TavilySearchResults 기능을 사용하기 위해 다음과 같이 임포트합니다. 그리고 검색 결과를 몇 개 가져올지 max_results로 설정합니다.

TavilySearchResults 설치하기

tavily_search.ipynb (2)

```
from langchain_community.tools import TavilySearchResults

tavily_search = TavilySearchResults(
    max_results=5
)
```

5. 다음처럼 query를 딕셔너리 형태로 설정하고 질문을 검색합니다.

질문하기

tavily_search.ipynb (3)

```
res = tavily_search.invoke({"query": "2025 한국 경제 전망"})
for r in res:
    print(r)
```

셀을 실행하면 다음처럼 결과가 리스트 형태로 출력됩니다. 검색 결과로 찾은 페이지들의 본문이 나오지는 않지만 텍스트 일부 내용은 content에 들어 있습니다.

```
{ 'url': 'https://biz.chosun.com/policy/policy_sub/2024/12/31/CI647NQHPVE5HEKV5HAOLMV7KI/',
  'content': '국내 경제 전문가 34명 중 85%가 넘는 29명이 내년 한국경제 성장률이 2%를 넘지 못할 것으로 전망했다.
  (... 생략 ...)
```

6. 주피터 노트북에서 보기 좋게 출력하려면 다음처럼 작성하고 실행합니다.

주피터 노트북에서 가독성 좋게 출력하기

tavily_search.ipynb (4)

```
# 주피터 노트북에서 보기 좋게 출력하는 코드
from IPython.display import JSON
JSON(res).data
```

```
{ 'url': 'https://biz.chosun.com/policy/policy_sub/2024/12/31/CI647NQHPVE5HEKV5HAOLMV7KI/',
  'content': '국내 경제 전문가 34명 중 85%가 넘는 29명이 내년 한국경제 성장률이 2%를 넘지 못할 것으로 전망했다. 특히 전문가 34명 중 12명은 내년 한
  { 'url': 'https://www.hci.co.kr/upload/board/2887810266_WZ85c0kj_20241210123438.pdf',
    'content': 'Dec 10, 2024 · 2025년 한국경제는 내수 경기 회복 지연 속 높은 외수 경기 불확실성으로 1.7% 정도의 성장세를 기록해 잠재성장률을 하회할
  { 'url': 'https://www.khan.co.kr/article/202411052101005',
    'content': '얼마 전 발표된 2024년 3분기 경제성장률은 전분기 대비 0.1%로 한국경제가 경기침체 속에 여전히 허덕이고 있음을 보여줬다. 더욱이 정부는 9
```

7. 랭체인에서 제공하는 TavilySearchResult가 아니라 타빌리에서 제공하는 TavilyClient를 사용하면 해당 웹 페이지의 전체 텍스트까지 불러올 수 있습니다. 다음과 같이 작성하고, 특히 include_raw_content를 True로 작성하는 것을 잊지 마세요.

웹 페이지 전문 불러오기

tavily_search.ipynb (5)

```
from tavily import TavilyClient

client = TavilyClient()

content = client.search(
    "2025년 한국 경제 전망",
    search_depth="advanced",
    include_raw_content=True,
)

JSON(content).data
```

이 셀을 실행하면 다음과 같이 웹 페이지 내용까지 가져올 수 있습니다.

```
{'query': '2025년 한국 경제 전망',
 'follow_up_questions': None,
 'answer': None,
 'images': [],
 'results': [{'url': 'https://www.hri.co.kr/upload/board/2887010266_WZR5c0kj_20241210123438.pdf',
               'title': '[PDF] 2025년 한국경제 수정전망',
               'content': '2025년 한국경제는 내수 경기 회복 지연 속 높은 외수 경기 불확실성으로 1.7% 정도의 성장세를 기록해 잠재성장률을 하회할 전망이다. (민간소비) 금리',
               'score': 0.945243,
               'raw_content': '24-21(통권 979호) 2024.12.06. 2025년 한국경제 수정전망 - 성장경로 이탈이 우려되는 한국경제 목 차 ■2025년 한국경제 수정전망
(... 생략 ...)
영세 자영업자 등 취약계층에 대한 사회 안전망 및 일자리 지원 등과 같은 정책 노력도 지속적으로 강화해 나갈 필요가 있다.\n- 사회 안전망 강화 수단으로 추진되는 재정적 지원은 취약계층별 특성에 따라 차별적으로 추진함으로써 국민 공감대를 형성할 필요가 있고 재정 건전성 측면에서도 부정적인 영향을 최소화하는 것이 바람직 주 원경제연구실장 (2072-6235, j uwon@hri .co.kr) 이부형이사대우(2072-6306, leebuh@hri.co.kr) 이택근연구위원(2072-6366, tk l e e @h ri .co. k r) 신지영선임연구원(2072-6240, j yshin@hri.co.kr) 노시연선임연구원(2072-6248, syroh@hri .co.k r)'},
               (... 생략 ...)]}
```

일부 웹 페이지는 웹 사이트 자체에서 기계적으로 데이터를 긁어 가지 못하도록 처리했거나 해당 페이지의 내용이 삭제되어서 가져오지 못할 수도 있습니다. 그러나 가져온 여러 페이지 중 일부에서 일어나는 현상이므로 현재 결과만으로도 충분히 활용할 수 있습니다.

```
{'url': 'https://biz.chosun.com/policy/policy_sub/2024/12/31/CI647NQHPE5HEKV5HAOLMV7KI/',
'title': '[2025 경제전망] 전문가 85% "내년 2% 성장 어렵다"... 저성장 직면 ...',
'content': '국내 경제 전문가 34명 중 85%가 넘는 29명이 내년 한국경제 성장률이 2%를 넘지 못할 것으로',
'score': 0.9407083,
'raw_content': None},
{'url': 'https://www.kif.re.kr/kif4/publication/viewer?mid=20&vid=0&cno=341976&fcd=2024012421N',
'title': '[PDF] 2025년 경제전망과 정책시사점',
'content': '2025년 국내 거시경제 전망. 우리 경제는 2024년 2.2%, 2025년 2.0%로 성장세가 둔화할 전망',
'score': 0.91563576,
'raw_content': None},
```

Do it! 실습 인터넷에서 자료 조사 후 기사 쓰는 기자 만들기

결과 파일: sec02/tavily_search.ipynb

GPT 언어 모델과 타빌리 검색을 활용해 신문 기사를 쓰는 기사를 만들어 보겠습니다.

1. 쓰고 싶은 기사 내용을 query로 설정합니다. 그리고 client.search에 이 query를 사용하고, 이 query로 검색한 결과의 웹 페이지 내용까지 가져오도록 include_raw_content를 True로 설정합니다.

◆ 이 예제는 타빌리의 공식 문서에 있는 예제를 이 책의 내용에 맞게 수정한 버전입니다. 타빌리의 공식 문서에 있는 예제는 <https://docs.tavily.com/docs/python-sdk/tavily-search/examples>를 참고하세요.



질문에 대한 자료 검색하기

tavily_search.ipynb (6)

```
from langchain.adapters.openai import convert_openai_messages
from langchain_openai import ChatOpenAI

llm = ChatOpenAI(model="gpt-4o")

# 질문에 대한 자료를 TavilyClient로 가져오기
query = "현대자동차 미국 시장 2025년 전망"

content = client.search(
    query,
    include_raw_content=True,
    search_depth="advanced"
)["results"]
```

2. 기사를 작성하기 위한 프롬프트를 설정해 보겠습니다. 시스템 메시지로 GPT의 역할이 무엇인지 설명하고 **f-string**을 이용해 **query**와 검색 결과인 **content**를 넣어서 메시지를 만듭니다.

◆ 여기서 말하는 MLA는 Markdown Language Association의 줄임말로 마크다운 언어 협회를 의미합니다.

프롬프트 설정

tavily_search.ipynb (6)

```

# 프롬프트 설정
prompt = [{
    "role": "system",
    "content": (
        "당신은 신문 기사를 쓰는 기자 AI입니다. \n"
        "당신은 주어진 정보를 바탕으로 객관적이고 체계적으로 작성된 기사를 써야 합니다. \n"
    )
}, {
    "role": "user",
    "content": (
        f'정보: "{content}"\n\n'
        f'위의 정보를 사용하여, 다음 질문에 대해 자세한 보고서를 한국어로 작성하세요.: "{query}"\n\n'
        '-신문 기사 형식을 사용하되, MLA 표준을 준수하는 markdown 문법을 사용해주세요.'
        '-활용한 자료는 출처를 명시하세요.'
    )
}]

```

3. 이 메시지 리스트로 구성된 프롬프트를 `llm.invoke()`로 실행시켜 GPT가 답을 생성하도록 했습니다.

오픈AI를 랭체인으로 실행하고 출력하기


tavily_search.ipynb (8)

```

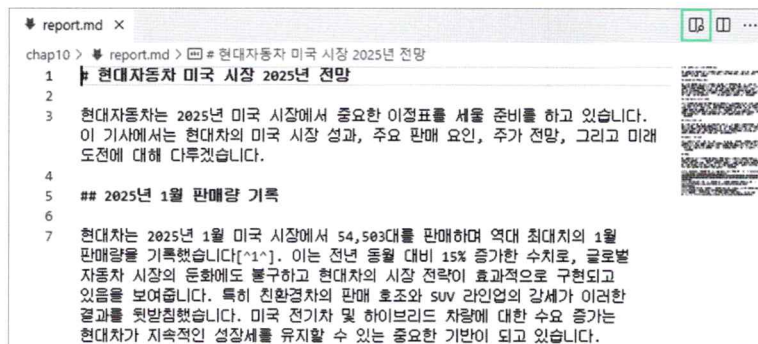
# 오픈AI를 랭체인으로 실행하고 출력
report = llm.invoke(prompt).content
print(report)

```

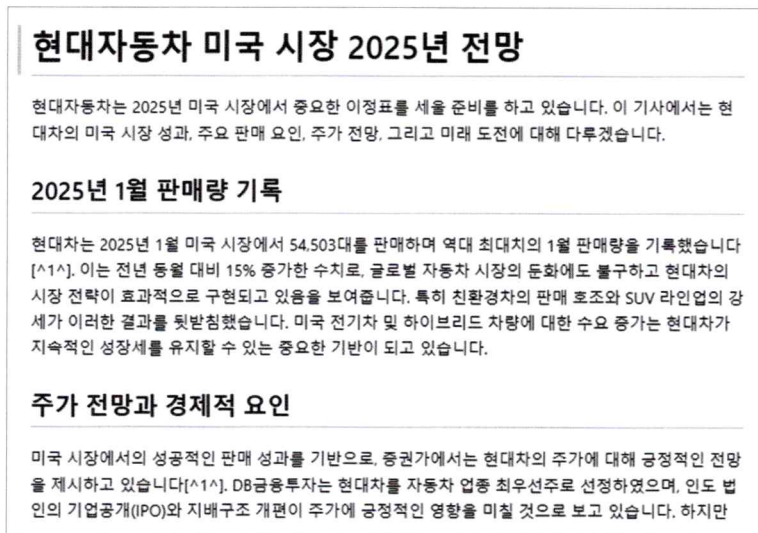
4. 셀을 실행하고 출력된 결과를 마크다운 문서로 만들겠습니다. 주피터 노트북에서 나온 출력 결과를 [...] → 셀 출력 복사(Copy Cell Output)를 클릭해 복사한 후 .md 파일로 저장합니다.



5. 마크다운 파일을 VS Code에서 열고 화면 오른쪽 위에서  [open preview the slide] 아이콘을 클릭합니다.



다음처럼 요청한 주제에 관한 기사가 렌더링된 마크다운 파일이 나옵니다.




10-3 유튜브 영상 요약하기

요즘은 유튜브에도 좋은 정보가 많습니다. 유튜브에 올라온 최신 뉴스 영상 여러 개를 요약해야 하는 상황을 가정해 봅시다. 10분에서 20분 정도 분량의 영상 수십 개를 직접 시청한 후 요약하기는 어렵습니다. 이번 절에서는 유튜브에서 원하는 내용을 검색하고 텍스트로 가져와 언어 모델로 응용하는 방법을 다루겠습니다.

Do it! 실습 YoutubeSearch 패키지로 유튜브 검색하기

■ 결과 파일: sec03/youtube_summary.ipynb

1. 먼저 기능을 단계별로 구현하기 위해 새로운 주피터 노트북 파일을 생성합니다. 이름은 youtube_summary.ipynb로 지정합니다.



2. 유튜브에서 원하는 내용을 검색하는 기능을 개발해 봅시다. 랭체인에서는 YoutubeSearchTool 패키지를 제공하지만 아직 기능이 제한적이므로 그 대신 파이썬 패키지인 YoutubeSearch를 사용하겠습니다. 다음과 같이 입력해 패키지를 설치합니다.



YoutubeSearch 패키지 설치하기

■ youtube_summary.ipynb (1)

```
%pip install youtube-search
```

3. 이 기능을 활용해 원하는 키워드로 검색해 봅시다. ‘미국 대선’을 검색하고 최대 5개의 결과를 딕셔너리 형태로 가져옵니다.

```
from youtube_search import YoutubeSearch

videos = YoutubeSearch("미국 대선", max_results=5).to_dict()
videos
```

셀을 실행하면 다음과 같이 검색 결과가 딕셔너리 형태로 나옵니다. 유튜브 영상 제목은 물론이고 섬네일, 채널명, 길이, 조회수, 배포일, 영상 주소까지 담겨 있습니다.

```
[{'id': 'oTpiRBV4kpw',
  'thumbnails': ['https://i.ytimg.com/vi/oTpiRBV4kpw/hq720.jpg?sqp=-oaymwEjC0gCE-MoBSFryq4qpAxUIARUAAAAAGAEIAADIQj0AgKJDeAE&rs=A0n4CLBoWaMgWU4RjMjE0zWPr0mgUUE15w',
                  'https://i.ytimg.com/vi/oTpiRBV4kpw/hq720.jpg?sqp=-oaymwEXCNAFEJQDSFryq4qpAwkIARU-AAIhCGAE&rs=A0n4CLABaxIVYLGfmyz8V0FZ-Yw7Sw96hw'],
  'title': '7개 경합주 싸움이 '압승'..무너뜨린 '파란 장벽' (2024.11.07/930MBC뉴스)",
  'long_desc': None,
  'channel': 'MBCNEWS',
  'duration': '1:55',
  'views': '조회수 9,152회',
  'publish_time': '1일 전',
  'url_suffix': '/watch?v=oTpiRBV4kpw&pp=ygUN66-46rWtI0uMg0yEoA%3D%3D'}],

(... 생략 ...)
```

```
{'id': 'rY5_-jEUJYw',
  'thumbnails': ['https://i.ytimg.com/vi/rY5_-jEUJYw/hq720.jpg?sqp=-oaymwEjC0gCE-MoBSFryq4qpAxUIARUAAAAAGAEIAADIQj0AgKJDeAE&rs=A0n4CLBYnU7eCb5SPSpQCM3gDh0f1bt73g',
                  'https://i.ytimg.com/vi/rY5_-jEUJYw/hq720.jpg?sqp=-oaymwEXCNAFEJQDSFryq4qpAwkIARU-AAIhCGAE&rs=A0n4CLDcZRS4dfb0_u3K-XKj5S99g25Wiw'],
  'title': '[LIVE] 2024 미국 대선 결과 분석 정리',
  'long_desc': None,

(... 생략 ...)
```

```
'channel': 'YTN',
'duration': '11:39:04',
'views': '조회수 238,790회',
'publish_time': '스트리밍 시간: 1일 전',
'url_suffix': '/watch?v=bL5pD-BV7lI&pp=ygUN66-46rWtI0uMg0yEoA%3D%3D'}]]
```

4. 영상 페이지를 열기 위해 결과로 표시되는 `url_suffix` 앞에 `'https://youtube.com'`을 붙여 온전한 경로를 만듭니다. 다음 코드에서 `videos[3]`의 3은 예시로 골랐을 뿐 특별한 의미는 없습니다.

온전한 경로 만들기

youtube_summary.ipynb (3)

```
video_url = 'https://youtube.com' + videos[3]['url_suffix']
video_url
```

실행하면 다음처럼 온전한 경로를 만들 수 있습니다.

```
'https://youtube.com/watch?v=34PYyv0X4Sc&pp=ygUN66-46rWtIOuMg0yEoA%3D%3D'
```

Do it! 실습 YoutubeLoader 패키지로 유튜브 자막 가져오기

결과 파일: sec03/youtube_summary.ipynb

언어 모델을 이용해 분석할 때는 영상보다 텍스트로 된 정보가 처리하기 편리합니다. 다행히 유튜브는 업로드된 영상에 자동으로 자막을 붙여 주는 기능이 있습니다. 이 자막을 사용해 텍스트로 영상 내용을 파악해 보겠습니다.

1. 유튜브 자막을 내려받기 위해 다음처럼 `youtube_transcript_api`를 설치합니다.

youtube_transcript_api 설치하기

youtube_summary.ipynb (4)

```
%pip install youtube_transcript_api
```

2. 랭체인에서도 이런 기능을 YoutubeLoader를 통해 제공하고 있습니다. 사용 방법도 간단합니다. 다음과 같이 작성하면 해당 영상의 자막을 가져올 수 있습니다. `language`를 `'ko'`와 `'en'`으로 설정하면 한국어와 영어 자막을 가져옵니다.

YoutubeLoader로 유튜브 자막 가져오기

youtube_summary.ipynb (5)

```
from langchain_community.document_loaders import YoutubeLoader

loader = YoutubeLoader.from_youtube_url(
    video_url,
```



```

    language=['ko', 'en'] # 자막 언어
)

loader.load()

```

이 셀을 실행하면 다음처럼 자막 내용을 받아 올 수 있습니다. 이때 한국어와 영어 자막을 찾지 못하는 경우가 발생할 수 있습니다. 테스트해 본 결과 위 코드와 동일하게 ['ko', 'en']으로 설정하는 경우에 오류가 발생하는 경우가 적었습니다.

```

[Document(metadata={'source': '34PYyv0X4Sc'}, page_content='네 공화당의 도널드 트럼프 후보가 말씀드린 것처럼 사실상 승리를 확정지었습니다 이번 선거의 특징과 트럼프 후보를 선택한 배경 (... 생략 ...) 그만큼 트럼프 행정부를 하원에서 견제하는 역할을 많이 했는데 만약 이번에 하원까지 공화당으로 넘어가게 된다면 트럼프를 견제할 수 있는 의회의 세력은 없다 이렇게 말씀드릴 수 있겠습니다네 알겠습니다 오늘 말씀 고맙습니다 di [음악']')]

```

3. 이전 실습에서 가져왔던 영상에 자막을 추가해 봅시다. 이미 `videos`가 딕셔너리 형태로 되어 있으므로 여기에 `video_url`을 추가하고 그 `video_url`을 이용해 자막을 가져와서 딕셔너리에 추가합니다.

유튜브 영상 자막 가져오기

youtube_summary.ipynb (6)

```

for v in videos:
    # url_suffix를 이용하여 video_url 만들기
    v['video_url'] = 'https://youtube.com' + v['url_suffix']

    # YoutubeLoader를 이용하여 비디오 로드
    loader = YoutubeLoader.from_youtube_url(
        v['video_url'],
        language=['ko', 'en']
    )

    v['content'] = loader.load()

videos

```

이 셀을 실행해 보면 다음과 같이 자막 내용이 잘 추가되었습니다.

```
[{'id': 'oTpiRBV4kpw',
  'thumbnails': ['https://i.ytimg.com/vi/oTpiRBV4kpw/hq720.jpg?sqp=-oaymwEjC0gCEMoBSFr
yq4qpAxUIARUAAAAAGAE1AADIQj0AgKJDeAE&rs=A0n4CLBoWaMgWU4RjMjE0zWPr0mgUUEl5w',
  'https://i.ytimg.com/vi/oTpiRBV4kpw/hq720.jpg?sqp=-oaymwEXCNAFEJQDSFryq4qpAwkIARUAA
IhCGAE&rs=A0n4CLABaxIVYLGFmyz8V0FZ-Yw7Sw96hw'],
  'title': '"7개 경합주 싸움이 '압승'..무너뜨린 '파란 장벽' (2024.11.07/930MBC뉴스)",
  'long_desc': None,
  'channel': 'MBCNEWS',
  'duration': '1:55',
  'views': '조회수 9,152회',
  'publish_time': '1일 전',
  'url_suffix': '/watch?v=oTpiRBV4kpw&pp=ygUN66-46rWtI0uMg0yEoA%3D%3D',
  'video_url': 'https://youtube.com/watch?v=oTpiRBV4kpw&pp=ygUN66-46rWtI0uMg0yEoA%3D
%3D',
  'content': [Document(metadata={'source': 'oTpiRBV4kpw'}, page_content='박빙이 예상됐던
이번 미국 대선은 트럼프 전 대통령이 경합주 일곱 곳을 모두 싹쓸이하며 일찍감치 승리를 굳혔습니다 이민
자 문제와 경제 문제를 내세우며 정권 심판론을 제기했던 트럼프의 전략이 주효했다는 분석입니다 임현주 기
자입니다 치열한 경쟁이 예상됐던 일곱 곳의 경주이 일제히 공화당 후보인 트럼프 전 대통령을 선택하면서
트럼프는 일찌감치 승리를 확정지었습니다 트럼프는 일곱 곳의 경합주 가운데 최대 전제로 꼽혔던 펜실베이
니아 주에서 민주당 후보인 카말라 헤리스 부통령을 2.7% 포인트 격차로 이겼고 전통적으로 민주당을 지지
해 온 미시간 위스콘신에서 이따라 승리하면서 파란 장벽을 무너뜨렸습니다 표심을 가온 주요 원인으로 경제
와 이민 문제가 꼽힙니다 히 코로나 이후 고물가에 시달리던 유권자들의 정심이 영향을 미쳤다는 겁니다 출
구 조사에 따르면 4년 전보다 경제 사정이 안 좋아졌다는 응답이 45% 나타났습니다 또 과거 민주당지지 성
향이 강했던 무슬림 유권자들이 이스라엘과 하마스 전쟁으로 대거 공화당 쪽으로 돌아섰다는 분석입니다 트
럼프는 집권 일기 때 예멘과 소말리아 등 이슬람 일곱개 국민의 미국 입국을 90일간 금지하는 초강경 반무
슬림 정책을 펼쳤습니다 레바논계 무슬림이 많은 미시간주 주요 도시에서 2020년 대선 때에는 조 바이든 대
통령을 택했던 유권자들이 이번 대선에서는 해리스 후보 대신 트럼프를 택한 겁니다 전국 단위 득표율도 트
럼프가 해리스에 앞서 트럼프는 8년 만에 완벽한 승리를 거두며 백악관 재입성을 결정지었습니다 MBC 뉴스
이현주입니다')]]),
(... 생략 ...)]
```

그런데 한 가지 문제가 있습니다. 가끔 길이가 너무 긴 영상이 포함되어 있다는 것입니다. 최근 YTN이나 MBC, JTBC 같은 언론사에서 같은 뉴스를 반복해서 라이브 스트리밍하는 경우가 있습니다. 앞서 검색한 결과에도 미국 대선 결과 속보를 11시간 동안 반복해서 스트리밍하는 영상이 포함되어 있었습니다. 이 영상은 자막이 너무 길고 내용도 반복되므로 언어 모델에 넘기지 않는 것이 좋습니다. 11시간짜리 분량의 텍스트를 언어 모델에 넣으면 토큰이 많이 소모되기 때문입니다.

4. 1시간이 넘는 영상은 대상에서 제외해 보겠습니다. 영상 길이는 `duration`에 기록되어 있는데 '00:00:00'처럼 시간·분·초로, 또는 '00:00'처럼 분·초로 표시됩니다. 1시간 미만인 영상만 고르려면 시간 정보를 콜론(:) 기준으로 나누고 그 길이가 3 미만인 영상만 선택하면 됩니다.



길이 1시간 이하인 영상만 고르기

youtube_summary.ipynb (7)

```
print('총 영상 수:', len(videos))
# 영상 길이가 60분 이하인 영상만 남기기
videos = [v for v in videos if len(v['duration'].split(':')) < 3]
print('60분 이하 영상 수:', len(videos))
```

코드를 실행하니 영상 2개가 제외되어 3개만 남았습니다.

```
총 영상 수: 5
60분 이하 영상 수: 3
```

Do it! 실습 자막 내용 요약하기

결과 파일: sec03/youtube_summary.ipynb

이제 자막을 기반으로 영상 내용을 요약해 보겠습니다. 내용 요약은 09-2절에서 사용한 랭체인 기능인 `create_stuff_documents_chain`을 사용해 보겠습니다.

1. 언어 모델 `gpt-4o-mini`를 사용하기 위해 다음과 같이 셀을 작성합니다.



언어 모델 설정하기

youtube_summary.ipynb (8)

```
# 랭체인, openai 임포트
from langchain_openai import ChatOpenAI

model = ChatOpenAI(model="gpt-4o-mini")
model.invoke('안녕?') # 언어 모델이 잘 설정되었는지 테스트
```

이 셀을 실행하면 언어 모델이 잘 설정되었는지 확인할 수 있습니다.

```
AIMessage(content='안녕하세요! 어떻게 도와드릴까요?',
(... 생략 ...))
```


2. `create_stuff_documents_chain`을 이용해 영상 내용을 요약합니다. 테스트로 `videos`의 첫 번째 영상만 골라 요약합니다.

영상 하나만 요약하기 youtube_summary.ipynb (9)

```
from langchain_core.prompts import ChatPromptTemplate
from langchain.chains.combine_documents import create_stuff_documents_chain

# 동영상 요약 프롬프트 작성
prompt = ChatPromptTemplate.from_messages(
    [("system", "다음 영상에 대한 요약을 한국어로 만들어줘 :\n\n{context}")]
)

chain = create_stuff_documents_chain(model, prompt)

result = chain.invoke({"context": videos[0]['content']})
result
```

이 셀을 실행해 보니 다음과 같이 요약 내용이 잘 나오는군요.

'이 영상은 미국의 정치적 상황과 도널드 트럼프의 대통령 후보로서의 입장을 다루고 있습니다. 영상에서는 트럼프가 미국을 다시 위대하게 만들겠다고 주장하며, 경제 회복, 범죄 방지, 이민 문제 해결 등을 강조합니다. 또한 그는 자신의 이전 행정부에서 이룬 성과를 자랑하며, 현재의 정치적 상황에 대한 불만을 표현합니다.\n\n영상에는 다양한 지지자들의 인터뷰가 포함되어 있으며, 그들은 트럼프를 지지하는 이유로 그의 솔직함과 경제 관련 정책을 언급합니다. 반면 카말라 해리스와 민주당에 대한 비판도 강하게 나타나며, 그들이 이전에 이룬 성과가 부족하다는 주장도 담겨 있습니다.\n\n결국 이 영상은 트럼프가 2024년 대선에 재출마하기 위한 캠페인 메시지를 전달하며, 경제적 안정과 국가의 안전을 강조하는 내용을 중심으로 구성되어 있습니다.'

3. 이제 `for` 문을 사용해 모든 영상의 요약 내용을 딕셔너리에 추가합니다. `videos`의 각 요소를 반복문으로 처리하면서 자막 내용을 요약한 `content`를 `summary`에 넣습니다.

모든 영상 요약하기 youtube_summary.ipynb (10)

```
# 모든 비디오에 대해 요약 생성
from tqdm import tqdm # tqdm은 진행 상황을 보여 주는 라이브러리

for v in tqdm(videos):
    v['summary'] = chain.invoke({"context": v['content']})

videos
```


이 셀을 실행해 보면 영상 3개를 요약한 내용이 추가되었습니다.

```
{'id': 'oTpiRBV4kpw',
  'thumbnails': ['https://i.ytimg.com/vi/oTpiRBV4kpw/hq720.jpg?sqp=-oaymwEjC0gCE-MoBSFryq4qpAxUIARUAAAAAGAEIAADIQj0AgKJDeAE=&rs=A0n4CLBoWaMgWU4RjMjE0zWPr0mgUUEl5w',
    'https://i.ytimg.com/vi/oTpiRBV4kpw/hq720.jpg?sqp=-oaymwEXCNAFEJQDSFryq4qpAwkIARU-AAIhCGAE=&rs=A0n4CLABaxIVYLGFmyz8V0FZ-Yw7Sw96hw'],
  'title': "7개 경합주 싸움이 '압승'..무너뜨린 '파란 장벽' (2024.11.07/930MBC뉴스)",
  'long_desc': None,
  'channel': 'MBCNEWS',
  'duration': '1:55',
  'views': '조회수 9,152회',
  'publish_time': '1일 전',
  'url_suffix': '/watch?v=oTpiRBV4kpw&pp=ygUN66-46rWtI0uMg0yEoA%3D%3D',
  'video_url': 'https://youtube.com/watch?v=oTpiRBV4kpw&pp=ygUN66-46rWtI0uMg0yEo-A%3D%3D',
  'content': [Document(metadata={'source': 'oTpiRBV4kpw'}, page_content='박빙이 예상됐던 이번 미국 대선은 트럼프 전 대통령이 경합주 일곱 곳을 모두 싹쓸이하며 일찍감치 승리를 굳혔습니다 이민자 문제와 경제 문제를 내세우며 정권 심판론을 제기했던 트럼프의 전략이 주효했다는 분석입니다 임현주 기자입니다 치열한
(... 생략 ...)
대선에서는 해리스 후보 대신 트럼프를 택한 겁니다 전국 단위 득표율도 트럼프가 해리스에 앞서 트럼프는 8년 만에 완벽한 승리를 거두며 백악관 재입성을 결정지었습니다 MBC 뉴스 이현주입니다')]],
  'summary': '이번 영상에서는 도널드 트럼프 후보가 미국 대선에서 사실상 승리를 확정지었다는 내용을 다루고 있습니다. 트럼프 후보는 이미 승리 연설을 했으며, 여러 경합주에서 이길 가능성이 높아지고 있습니다. 특히 조지아와 노스 캐롤라이나에서는 승리가 확정되었고, 펜실베이니아에서도 트럼프가 승리할 것이라는 전망이 나오고 있습니다
(... 생략 ...)
트럼프의 대외 정책에 대한 영향력이 커질 것으로 예상됩니다. 만약 공화당이 상하원을 모두 장악하게 된다면, 트럼프 대통령을 견제할 세력이 없게 될 것이라는 전망도 나옵니다.'},
  (... 생략 ...)
```

10-4 웹과 유튜브 검색을 활용한 챗봇 만들기

지금까지 인터넷과 유튜브를 활용해서 검색하는 방법을 배웠으니 이를 활용한 챗봇을 구현해 봅시다.

Do it! 실습 챗봇에 웹 검색 도구 추가하기

■ 결과 파일: sec04/streamlit_with_web_search.py

먼저 인터넷 검색 기능을 활용한 챗봇을 만들어 봅시다. 이번 예제에서는 08-5절에서 만든 `langchain_streamlit_tool.py` 코드를 활용하겠습니다. 이 파이썬 파일을 복사해서 `streamlit_with_web_search.py` 파일을 만들고 코드를 수정하며 실습을 진행하겠습니다.

1. 이 예제에서는 웹 검색 도구로 덕덕고를 사용합니다. 필요한 라이브러리를 다음과 같이 импорт합니다.

덕덕고 관련 라이브러리 설치하기

■ streamlit_with_web_search.py

```
(... 생략 ...)  
from langchain_core.tools import tool  
from datetime import datetime  
import pytz  
  
from langchain_community.tools import DuckDuckGoSearchResults  
from langchain_community.utilities import DuckDuckGoSearchAPIWrapper  
  
# 모델 초기화  
llm = ChatOpenAI(model="gpt-4o-mini")  
(... 생략 ...)
```

2. 덕덕고를 활용해 웹 검색을 하기 위해 `get_web_search` 함수로 만듭니다.

```
# 도구 함수 정의
@tool
def get_current_time(timezone: str, location: str) -> str:
    """현재 시각을 반환하는 함수."""
    try:
        tz = pytz.timezone(timezone)
        now = datetime.now(tz).strftime("%Y-%m-%d %H:%M:%S")
        result = f'{timezone} ({location}) 현재 시각 {now}'
        print(result)
        return result
    except pytz.UnknownTimeZoneError:
        return f"알 수 없는 타임존: {timezone}"

@tool
def get_web_search(query: str, search_period: str) -> str: ❶

    """
    웹 검색을 수행하는 함수
    Args:
        query (str): 검색어
        search_period (str): 검색 기간 (e.g., "w" for past week, ❷
        "m" for past month, "y" for past year) ❸
    Returns:
        str: 검색 결과
    """

    wrapper = DuckDuckGoSearchAPIWrapper(region="kr-kr", time=search_period)

    print('----- WEB SEARCH -----')
    print(query)
    print(search_period)

    search = DuckDuckGoSearchResults(
        api_wrapper=wrapper,
        # source="news",
        results_separator=';\n'
    )

    docs = search.invoke(query)
    return docs
(... 생략 ...)
```

- 1 이 함수에서 사용하는 매개변수는 query와 search_period입니다. query는 인터넷 검색을 하기 위한 검색어를 의미하고, search_period는 웹 검색을 할 때 옵션으로 사용할 검색 기간입니다.
- 2 "" "" 사이의 내용은 단순히 주석이 아니라 이 함수가 어떻게 활용될 수 있는지 언어 모델에게 명확하게 전달하는 독스트링 docstring입니다. 함수 위에 @tool 데코레이터를 붙일 때는 이렇게 함수에 대한 설명을 정확하게 작성하는 것이 중요합니다.
- 3 최근 1주일은 'w', 최근 한달은 'm', 최근 1년은 'y' 으로 지정해야 한다는 설명을 추가합니다. 이렇게 하면 언어 모델이 이 함수를 사용할 때 적절한 값을 채워서 실행합니다.

3. 새 함수를 tools에 추가하여 GPT가 선택할 수 있게 합니다.

새 함수를 tools에 추가하기

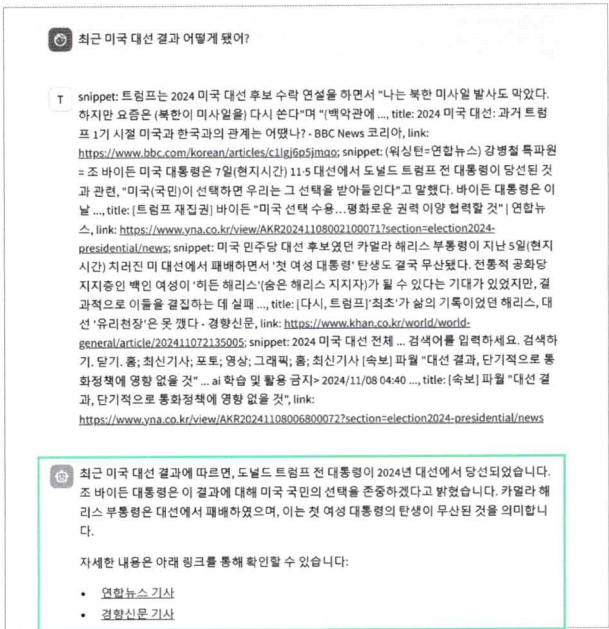
streamlit_with_web_search.py

```

(... 생략 ...)
# 도구 바인딩
tools = [get_current_time, get_web_search]
tool_dict = {
    "get_current_time": get_current_time,
    "get_web_search": get_web_search,
}
(... 생략 ...)

```

터미널 창에 streamlit run 파일명.py을 입력해 코드를 실행해 보니 최근 대선 결과도 제대로 답을 해줍니다. 여러분은 이 책을 읽는 시점의 최신 내용으로 대화해 보세요.



Do it! 실습 유튜브 검색 도구 추가하기

■ 결과 파일: sec04/streamlit_with_youtube_search.py

유튜브를 활용해 검색하는 기능도 추가해 봅시다. streamlit_with_web_search.py 파일에 이어서 작업하세요. 여기서는 10-3절에서 작성한 코드를 활용하겠습니다.

1. 유튜브 검색을 위해 필요한 라이브러리들을 임포트합니다.

유튜브 검색 기능을 위한 라이브러리 설치하기

■ streamlit_with_web_search.py

```
(... 생략 ...)
from langchain_community.tools import DuckDuckGoSearchResults
from langchain_community.utilities import DuckDuckGoSearchAPIWrapper

from youtube_search import YoutubeSearch
from langchain_community.document_loaders import YoutubeLoader
from typing import List
(... 생략 ...)
```

2. 유튜브 검색 기능을 구현한 get_youtube_search 함수를 만듭니다.

유튜브 검색 도구 추가하기

■ streamlit_with_web_search.py

```
@tool
def get_web_search(query: str, search_period: str) -> str:
    (... 생략 ...)
    return docs

@tool
def get_youtube_search(query: str) -> List: ②
    """
    유튜브 검색을 한 뒤, 영상들의 내용을 반환하는 함수.

    Args:
        query (str): 검색어

    Returns:
        List: 검색 결과
    """
    print('----- YOUTUBE SEARCH -----')
    print(query)
```

```

videos = YoutubeSearch(query, max_results=5).to_dict()

videos = [video for video in videos if len(video['duration']) <= 5]—❸

for video in videos:
    video_url = 'https://youtube.com' + video['url_suffix']—❹

    loader = YoutubeLoader.from_youtube_url(
        video_url,
        language=['ko', 'en'] # 자막 언어
    )

    video['video_url'] = video_url
    video['content'] = loader.load()

return videos

# 도구 바인딩
(... 생략 ...)
```

- ❶ 함수 위에 @tool 데코레이터를 사용하고 이 함수에 대한 설명을 작성합니다.
- ❷ get_youtube_search 함수에 필요한 매개변수는 query 하나뿐이고 검색된 결과는 리스트 형태로 반환됩니다. List를 임포트하고 반환 자료형을 List로 명시합니다.
- ❸ 영상의 길이가 너무 긴 경우 언어 모델에서 많은 토큰을 사용하고 시간도 오래 걸리므로 duration이 59분 59초 이하인 영상만 남기도록 했습니다. duration은 문자열로 주어지므로 그 문자열의 최대 길이는 '59:59'에 해당하는 5입니다. 따라서 다섯 자 이하인 영상만 선택합니다.
- ❹ video_url을 만들고 이것을 이용해 자막을 가져와 content에 담습니다. 이 코드는 10-3절 'Youtube Loader 패키지로 유튜브 자막 가져오기' 실습에서 사용한 코드와 동일합니다.

3. 이 함수를 GPT가 선택할 수 있도록 tools와 tool_dict에 등록합니다.

GPT가 함수를 선택할 수 있도록 등록하기

streamlit_with_web_search.py

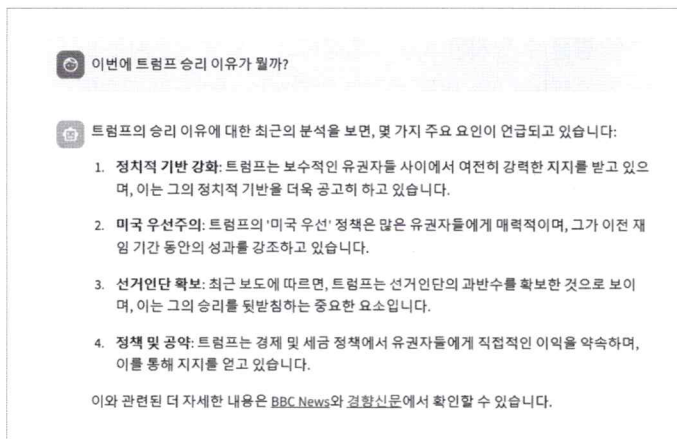
```

(... 생략 ...)
# 도구 바인딩
tools = [get_current_time, get_web_search, get_youtube_search]
tool_dict = {
    "get_current_time": get_current_time,
    "get_web_search": get_web_search,
    "get_youtube_search": get_youtube_search,
}
```

```
llm_with_tools = llm.bind_tools(tools)
(... 생략 ...)
```

이 코드에는 요약하는 기능은 추가하지 않았습니다. 언어 모델이 답변하기 전에 전체 텍스트를 한번 읽어서 답변을 생성하므로 요약이 반드시 필요하지 않기 때문입니다.

streamlit run 파일명.py을 입력해 실행하면 다음처럼 질문 내용을 웹과 유튜브에서 검색한 후 답변해 주는 챗봇을 확인할 수 있습니다.



이제 우리가 만든 GPT 기반 챗봇은 GPT가 학습한 내용뿐만 아니라 최신 인터넷과 유튜브 정보까지 파악하고 답변할 수 있게 되었습니다!

