

# 판다스 실무 마케팅 문제 30제 — 쇼핑물 데이터로 푸는 실전 분석 문제집 — 문제편

---

## 목차

---

### 1장. 매출 성과 진단과 채널 리포트 [실무 기본]

- 무대: 월간 성과 보고를 맡다
- 문제 01 신뢰할 수 있는 매출 원장 만들기
- 문제 02 상반기 성장 기여 분해 브리핑

### 2장. 고객 세분화 — RFM과 타겟 목록 [실무 기본]

- 무대: CRM 캠페인 타겟을 설계하다
- 문제 03 RFM 스코어 산출과 세그먼트 정의
- 문제 04 멤버십 등급제 설계 시뮬레이션

### 3장. 코호트와 리텐션 분석 [실무 기본]

- 무대: 그로스팀의 리텐션 점검
- 문제 05 첫 구매 코호트 리텐션 매트릭스
- 문제 06 2회차 구매 전환율 개선 과제
- 문제 07 상·하반기 신규 코호트 질 비교

### 4장. 퍼널과 전환 분석 [실무 심화]

- 무대: 전환율 개선 스프린트
- 문제 08 세션 퍼널 구축과 단계별 이탈
- 문제 09 요일×시간대 전환 패턴과 광고 시간 최적화
- 문제 10 행동 로그와 주문 데이터 대사

### 5장. 상품 포트폴리오와 MD 전략 [실무 심화]

- 무대: MD팀의 상품 전략 리뷰

- 문제 11 카테고리 확대·유지·축소 매트릭스
- 문제 12 동시구매 분석과 번들 후보
- 문제 13 상품 마스터 이상 진단과 지표 영향

## 6장. 가격과 할인 효과 분석 [실무 심화]

- 무대: 프로모션 예산 회의
- 문제 14 할인율 구간별 손익 분석
- 문제 15 할인 의존 상품 검출
- 문제 16 할인 마진 잠식 시뮬레이션

## 7장. 고객 생애가치와 이탈 관리 [실무 심화]

- 무대: 고객 가치 중심으로 예산을 다시 짜다
- 문제 17 6개월 실현 LTV와 가치 집중도
- 문제 18 코호트별 LTV 곡선과 획득비 상한
- 문제 19 이탈 기준선 탐색과 민감도
- 문제 20 이탈 위험 스코어카드

## 8장. 시계열 수요와 시즌성 [실무 고급]

- 무대: 하반기 수요 계획 수립
- 문제 21 주간 매출 추세와 이동평균
- 문제 22 시간 단위 수요 프로파일과 피크 운영 계획
- 문제 23 7월 수요 나이브 예측과 한계 보고

## 9장. 비교 분석과 준실험적 사고 [실무 고급]

- 무대: '앱이 웹보다 낫다'는 주장 검증
- 문제 24 앱 vs 웹 성과의 구성 보정 비교
- 문제 25 반품 경험이 재구매에 남기는 흔적
- 문제 26 할인 첫 구매 고객은 남는가

## 10장. 대용량 로그 마케팅 파이프라인 [실무 고급]

- 무대: 매달 반복되는 리포트를 파이프라인으로
- 문제 27 100만 행 로그 메모리 진단과 최적화
- 문제 28 청크 집계로 일별 활성 고객 산출
- 문제 29 로그 기반 상품 관심 스코어 파이프라인
- 문제 30 월간 마케팅 지표 자동화 파이프라인

## 이 책에 대하여 (머리말)

### 이 책의 목적

판다스 기본기를 이미 배운 사람이 실제 마케팅 업무에서 마주치는 분석 의뢰 30건을 직접 풀어 보며, '문법을 아는 것'과 '업무 질문에 데이터로 답하는 것' 사이의 간극을 메우는 실전 문제집입니다. 모든 문제는 가상 쇼핑물의 실제 규모 데이터셋(고객 5천·주문 20만·주문상세 50만·행동 로그 100만 행) 위에서 이해관계자의 의뢰 형식으로 주어지며, 해설은 접근 설계부터 정제·결합·집계·해석·보고 문구까지 실무 흐름 전체를 다룹니다. 단일 함수 연습용 기본 문제와 통계 지식이 필요한 문제는 실지 않았습니다.

### 이 책을 마치면 할 수 있는 것

- 취소·반품·중복·타입 오염을 반영한 신뢰할 수 있는 순매출 지표를 정의하고 채널·지역·기간별 성과 보고 표를 만들 수 있습니다
- RFM 세분화, 코호트 리텐션, 퍼널 전환, LTV 같은 핵심 마케팅 분석 기법을 판다스로 직접 구현하고 타깃 목록·개선 과제를 도출할 수 있습니다
- 할인 효과, 채널 비교 같은 질문에서 단순 비교의 함정(구성 차이·자기선택 편향)을 식별하고 보정된 비교와 정직한 결론을 제시할 수 있습니다
- 100만 행 로그를 메모리 최적화·체크·Parquet으로 처리하는 반복 가능한 지표 파이프라인을 구축할 수 있습니다

### 대상 독자

판다스 기본 문법(선택·필터·정제·groupby-merge·시계열 기초)을 한 번 배운 마케터·데이터 분석 입문자를 대상으로 합니다. 『판다스로 배우는 쇼핑물 데이터 분석』을 마쳤거나 그에 준하는 수준이면 충분합니다. 통계·머신러닝 지식은 전제하지 않으며, 통계 계산이 필요한 문제는 실지 않았습니다.

### 선수 지식

- 파이썬 기본 문법과 판다스 기본기(read\_csv·loc·불리언 필터·groupby·merge·to\_datetime)
- 『판다스로 배우는 쇼핑물 데이터 분석』 수료 또는 동등한 학습 경험(권장)
- 터미널에서 python 스크립트 실행과 pip 설치

### 실습 환경

- pip install pandas numpy pyarrow로 판다스 2.2·넘파이·PyArrow 설치
  - 동봉된 generate\_shop\_data.py를 실행해 data 폴더에 CSV 다섯 개 (customers-products-orders-order\_items-web\_logs)를 생성 — 시드 42 고정으로 누가 실행해도 해설과 동일한 결과가 재현됩니다
  - 문제를 먼저 스스로 푼 뒤 해설과 대조하는 방식을 권장합니다(해설의 모든 출력은 실제 실행 결과)
  - 대상 OS: Windows 11(macOS·Linux 동일 동작)
-



# 제1장 매출 성과 진단과 채널 리포트

당신은 이번 달에 합류한 마케팅 데이터 분석가입니다. 첫 출근 날 CMO가 회의실로 부릅니다. 재무팀이 보고한 '5월 매출'과 마케팅팀이 대시보드에서 읽은 '5월 매출'이 서로 달라, 지난달 예산 회의가 통째로 어긋났다는 이야기입니다. CMO의 요구는 단순합니다. "누가 물어도 같은 답이 나오는 하나의 매출 기준을 만들어 주십시오. 그다음 그 기준으로 상반기 성장의 동력까지 진단해 주십시오."

이 장은 그 요구를 두 개의 실무 의뢰로 나눠 풉니다. 문제 01에서 **표준 순매출 원장(net sales ledger)** 을 직접 도출합니다. 취소·반품·중복·타입 오염을 어떻게 처리했는지 손실 건수와 금액까지 대사표로 남겨, 이 책의 나머지 29문제가 모두 이 기준 위에서 계산되도록 못 박습니다. 문제 02는 그 기준 위에서 상반기 성장의 진짜 동력을 구매 고객수·주문 빈도·객단가로 분해합니다.

시작하기 전에 데이터셋을 만들어야 합니다. 동봉된 `generate_shop_data.py` 를 데이터 폴더에서 `python generate_shop_data.py` 로 한 번 실행하면 `data/` 폴더에 CSV 다섯 개 (`customers-products-orders-order_items-web_logs`)가 생성됩니다. 시드 42가 고정되어 있어 누가 실행해도 이 해설과 똑같은 수치가 재현됩니다. 아래 모든 코드는 이 `data/` 폴더 옆에서 실행한다고 가정하고 상대 경로 `data/orders.csv` 로 읽습니다.

## 문제 01 신뢰할 수 있는 매출 원장 만들기

난이도: ★★★☆☆

### 상황

CMO가 던진 첫 과제입니다. 재무팀과 마케팅팀의 '5월 매출'이 다른 이유는 십중팔구 **매출의 정의**가 다르기 때문입니다. 한쪽은 취소 주문을 빼고, 다른 쪽은 넣습니다. 한쪽은 반품을 매출에서 차감하고, 다른 쪽은 그대로 둡니다. 여기에 데이터 자체의 오염(중복 주문, 날짜가 비어 있는 행, 기간을 벗어난 행)까지 겹치면 같은 원본에서도 서로 다른 숫자가 나옵니다. 당신의 임무는 이 모든 처리 규칙을 한 번에 확정하고, 각 단계에서 무엇을 얼마나 걸러냈는지 검증 가능한 형태로 남기는 것입니다.

### 과제

1. `orders` 와 `order_items` 를 결합해 주문 라인 단위의 매출 원장을 만듭니다. 조인 키와 방식의 선택 근거를 밝힙니다.
2. 중복행을 제거하고, `order_datetime` 의 타입 오염을 `errors="coerce"` 로 정제한 뒤 손실 행수를 보고합니다. 상태별 처리 규칙(총매출 대 순매출)을 정의합니다.
3. 월별 총매출·순매출·취소반품 제외액·유효 주문수 대사표를 만들고, 두 팀 수치가 달랐던 원인을 상태 포함 범위 차이로 설명합니다.
4. 제출물: 월×(총매출, 순매출, 취소·반품 제외액, 유효 주문수) 대사표 한 장과 매출 정의 문서화 한 단락.

## 사용 데이터

- `orders` (200,000행): `order_id`, `customer_id`, `order_datetime` (빈 문자열 오염 1,933건, 2025년 기간 밖 40건), `channel`, `status`
- `order_items` (500,000행): `order_id`, `product_id`, `quantity`, `unit_price`, `discount` (완전 중복 120행)
- 주문 헤더에는 금액 컬럼이 없습니다. 매출은 오직 `order_items` 의 라인 금액을 합산해야만 구할 수 있습니다.

## 힌트

정제 순서를 고정합니다. 중복 제거 → 날짜 파싱 → 기간 필터 → 상태 필터 순서로 가면 각 단계 손실을 깔끔히 셀 수 있습니다. 총매출은 모든 상태를 포함하고, 순매출은 `canceled` · `returned` 를 뺀 값입니다. 두 원장을 따로 만들어 두면 제외액이 저절로 대사됩니다.

## 문제 02 상반기 성장 기여 분해 브리핑

난이도: ★★☆☆☆

### 상황

상반기 순매출이 1월 55.3억 원에서 6월 101.1억 원으로 크게 늘었습니다. CMO의 질문은 날카롭습니다. "성장한 건 알겠는데, 왜 성장했나요? 주문이 늘어서인가요, 한 번에 더 많이 사서인가요, 고객이 늘어서인가요?" 세 가지는 완전히 다른 처방으로 이어집니다. 고객이 늘었다면 획득 마케팅을, 주문이 늘었다면 재구매 유도를, 객단가가 늘었다면 상향 판매를 강화해야 합니다. 한 페이지 브리핑으로 답해야 합니다.

## 과제

1. 월별 순매출을 **구매 고객수 × 고객당 주문수 × 주문당 금액(AOV)** 로 분해합니다.
2. 분해 항등식이 실제 순매출과 일치하는지 **검산 코드**를 포함합니다.
3. 1월 대비 6월의 각 요인 변화율을 계산하고 **성장의 주된 동력**을 판정합니다.
4. 제출물: 월별 분해표(고객수·고객당 주문·AOV·순매출)와 성장 동력 판정 결론.

## 사용 데이터

- `orders`, `order_items`: 순매출 원장을 재사용합니다. 고객수는 '그 달에 구매한 고객'( `customer_id` 의 `nunique` ) 기준입니다.

## 힌트

순매출 = 구매고객수 × (주문수 / 구매고객수) × (순매출 / 주문수) 라는 곱셈 항등식을 이용합니다. 각 항을 따로 `groupby`로 구한 뒤 곱해서 원래 순매출과 같은지 검산합니다. 어느 요인이 가장 많이 변했는지 보려면 1월 대비 6월 변화율을 비교하고, 로그를 쓰면 각 요인의 기여 비중을 100%로 분해할 수 있습니다.



## 제2장 고객 세분화 — RFM과 타겟 목록

지난 장에서 우리는 취소·반품·중복·타입 오염을 걸러 낸 신뢰할 수 있는 순매출 원장을 세웠습니다. 상반기 순매출은 466억 원, 유효 주문은 16만 8,312건입니다. 이제 CMO의 다음 지시가 내려왔습니다. "매출이 누구에게서 나오는지, 그리고 그들에게 어떻게 말을 걸지 데이터로 정하라."

이 장의 무대는 CRM팀입니다. 지금까지 이 쇼핑몰의 CRM은 전 고객에게 같은 문자를 보내는 일괄 발송 방식이었습니다. 열어 보지도 않는 고객에게 매주 같은 쿠폰을 뿌리다 보니 수신 거부가 늘고, 정작 아껴야 할 우량 고객에게는 특별한 대접이 없었습니다. CRM 매니저는 이 방식을 세그먼트별 맞춤 메시지로 바꾸려 합니다. 그 첫걸음이 고객을 행동으로 나누는 작업입니다.

이 장에서는 두 개의 의뢰를 순서대로 풀니다. 문제 03에서 **RFM 세분화**로 전 고객을 6개 세그먼트로 나누고, 문제 04에서 내년 멤버십 등급제의 두 가지 설계안을 예산 관점에서 비교합니다.

모든 문제의 RFM 기준일은 **2024-07-01**로 고정합니다. 상반기(1~6월) 데이터를 관측하는 시점을 7월 1일로 두고, 그 시점에서 과거를 돌아보는 구도입니다. 순매출 정의(취소·반품 제외, 라인 금액 = 수량 x 단가 x (1 - 할인))는 1장 문제 01에서 도출한 기준을 그대로 씁니다. 각 문제는 아무 장이나 펼쳐 풀 수 있도록 원장 코드를 처음 쓸 때 다시 수록합니다.

### 문제 03 RFM 스코어 산출과 세그먼트 정의

난이도: ★★☆☆☆

#### 상황

CRM 매니저가 회의실 화이트보드에 딱 한 문장을 적어 두었습니다. "모두에게 같은 말을 하는 건 아무에게도 말을 걸지 않는 것과 같다." 매니저는 전 고객 일괄 발송을 세그먼트별 메시지로 바꾸려 합니다. 우량 고객에게는 감사와 독점 혜택을, 식어 가는 고객에게는 되돌아올 이유를, 잠들어 버린 고객에게는 재방문의 계기를 주고 싶어 합니다.

그 첫 단계로 **RFM 세분화**를 의뢰받았습니다. RFM은 마케팅에서 가장 오래되고 검증된 고객 분류법으로, 최근성(Recency, 마지막 구매 이후 얼마나 지났는가), 빈도(Frequency, 얼마나 자주 사는가), 금액(Monetary, 얼마나 많이 쓰는가) 세 축으로 고객을 나눕니다. 매니저는 이 세 축의 점수를 바탕으로 실무에서 바로 쓸 수 있는 세그먼트 규칙표를 원합니다.

## 과제

1. 기준일 2024-07-01을 기준으로 고객별 R(마지막 구매 경과일)·F(유효 주문수)·M(순매출)을 산출합니다. 취소·반품은 제외합니다.
2. 구매 이력이 없는 고객을 어떻게 처리할지 규칙을 명시합니다.
3. qcut 으로 각 축에 1~5점을 매기고, 동점 경계를 어떻게 처리하는지 설명합니다.
4. 챔피언·충성·잠재 충성·이탈 위험·휴면 등 6개 세그먼트를 규칙으로 정의하고, 세그먼트별 인원과 매출 비중을 산출합니다.

**제출물:** 고객별 RFM 테이블 + 세그먼트 정의 규칙표 + 세그먼트별 인원·매출 비중표.

## 사용 데이터

orders, order\_items, customers 세 테이블을 씁니다. 주문 헤더에는 금액이 없으므로 order\_items 의 라인을 합산해 주문 금액을 만듭니다. customers 에는 고유 id가 4,950명뿐인데 주문에는 그보다 많은 고객 id가 등장하는 정합성 문제가 있어, 이 점을 미구매 고객 처리와 함께 짚습니다.

## 힌트

R은 값이 작을수록(최근일수록) 좋은 점수여야 하므로 점수 라벨 방향을 F·M과 반대로 둡니다. qcut 은 동점이 많으면 분위 경계가 겹쳐 오류가 날 수 있으니, 빈도처럼 이산적인 축은 rank(method="first") 로 순위를 매긴 뒤 분위기를 나누면 5개 그룹이 균등하게 갈립니다.

## 문제 04 멤버십 등급제 설계 시뮬레이션

난이도: ★★★★★☆

### 상황

내년 멤버십 등급제(실버·골드·VIP) 도입을 앞두고 회의가 교착 상태입니다. 등급을 나누는 기준을 두고 두 진영이 맞섭니다. 한쪽은 "상위 5%를 VIP로" 같은 **비율 기준**을 주장하고, 다른 쪽은 "연 100만 원 이상 VIP" 같은 **고정 금액 기준**을 주장합니다. CFO가 논쟁을 끊었습니다. "말로 하지 말고 데이터로 두 안을 돌려 보라. 어느 쪽이 등급별 인원이 안정적이고, 혜택 예산이 감당 가능한가."

### 과제

1. 상반기 순매출 기준으로 고객 등급을 두 방식으로 부여합니다. 안 A는 `qcut` 으로 상위 5%/다음 15%/나머지 80%, 안 B는 `cut` 으로 100만 원·30만 원 고정 금액 컷입니다.
2. 두 안의 등급별 인원·매출 커버리지·경계 근처 고객 수를 대조합니다.
3. 등급 혜택(적립) 가정 하에 두 안의 예산을 추정하고 권고안과 근거를 제시합니다. 예산 가정은 반드시 표로 명시합니다.

**제출물:** 두 설계안 비교표(인원·매출 커버리지·예산) + 권고안과 근거 한 단락.

## 사용 데이터

`orders`, `order_items` 를 결합해 고객별 상반기 순매출을 만듭니다. 이 순매출 분포가 두 방식에서 어떻게 다르게 잘리는지가 이 문제의 핵심입니다.

## 힌트

`qcut` 은 **인원**을 고정합니다(상위 5%는 언제나 5%). `cut` 은 **금액 경계**를 고정합니다(100만 원이 언제나 경계). 이 점포의 순매출 분포 위에서 두 방식이 어떻게 다른 인원 구성을 낳는지 보면 논쟁의 답이 나옵니다. 예산은 등급별 매출에 가정한 적립률을 곱해 더합니다.

## 제3장 코호트와 리텐션 분석

그로스팀 주간 회의에서 매번 같은 장면이 반복됩니다. 누군가 "요즘 리텐션이 좋아지는 것 같다"고 말하면, 다른 누군가 "체감상 나빠진 것 같은데"라고 받습니다. 두 사람 다 숫자가 없습니다. 이번 장의 의뢰는 이 논쟁을 데이터로 끝내는 것입니다. 리텐션(retention) 분석의 핵심은 고객을 '언제 들어왔는지'로 묶어(코호트, cohort) 시간이 지나며 얼마나 남아 다시 사는지를 보는 것입니다. 매출 총량은 신규 유입만 늘려도 커지지만, 코호트 리텐션은 '한 번 데려온 고객이 계속 사는가'라는 사업의 체력을 드러냅니다.

이 장에서는 세 개의 의뢰를 풀니다. 첫 구매 월 코호트의 표준 리텐션 매트릭스(문제 05), 첫 구매가 2회차로 이어지는 비율을 특성별로 쪼개는 문제(문제 06), 그리고 가장 어려운 신규 코호트의 '질' 비교(문제 07)입니다. 특히 문제 05와 문제 07에는 리텐션 분석에서 가장 자주 사람을 속이는 함정이 들어 있습니다. 관측이 끝나지 않은 기간을 0으로 착각하는 것과, 관찰 창을 맞추지 않고 코호트를 비교하는 것입니다. 이 두 함정은 각각 그 문제 해설의 본체이므로 특히 꼼꼼히 다룹니다.

이 장의 모든 문제는 취소·반품을 제외한 유효 주문(순매출 원장)을 기준으로 합니다. 원장 정제 규칙(중복 제거, order\_datetime 타입 오염 정제, 2024년 상반기 한정, 취소·반품 제외)은 1장 문제 01에서 도출했으며, 각 문제에서 자기완결적으로 다시 씁니다.

### 문제 05 첫 구매 코호트 리텐션 매트릭스

난이도: ★★★☆☆

#### 상황

이번 의뢰가 이 장의 원래 발단입니다. "리텐션이 좋아지는지 나빠지는지 아무도 숫자로 답을 못 합니다. 첫 구매 월로 고객을 묶고, 그 뒤 몇 달이 지날 때마다 몇 %가 다시 사는지를 한 장의 표로 만들어 주기 바랍니다." 이것이 마케팅에서 '표준 리텐션 매트릭스(retention matrix)'라 부르는 삼각형 표입니다.

행은 첫 구매 월(코호트), 열은 첫 구매로부터 경과한 개월 수( $M+0$ ,  $M+1$ ,  $M+2$  ...), 값은 그 시점에 다시 구매한 고객의 비율입니다. 이 표 하나면 "어느 달에 데려온 고객이 더 오래 남는가"를 한눈에 비교할 수 있습니다.

## 과제

1. 고객별 첫 유효 주문 월(코호트)과 각 주문의 경과 월(period 차이)을 계산합니다.
2. 코호트 x 경과월 재구매 고객수 피벗을 만들고, 각 행을 코호트 크기로 나눠 리텐션을 삼각 매트릭스를 완성합니다.
3. M+1 리텐션의 코호트별 추이를 읽고, 관측이 끝나지 않은 셀(삼각형의 우하단 빈칸)을 어떻게 해석해야 하는지 명시합니다.

제출물은 코호트 x M+n 리텐션율 매트릭스와 M+1 추이 해석 한 단락입니다.

## 사용 데이터

`orders` 만 있으면 됩니다(재구매 '여부'를 세트로 금액은 불필요). 유효 주문 기준이므로 취소·반품은 제외합니다. 데이터는 2024년 1월 1일부터 6월 30일까지만 존재하며, 바로 이 관측 창이 이 문제의 핵심 함정을 만듭니다.

## 힌트

경과 월은 `dt.to_period('M')` 로 주문 월과 코호트 월을 만든 뒤 두 `period`를 빼면 정수 개월로 나옵니다. 피벗은 `pivot_table` 에 `aggfunc='nunique'` 를 씁니다. 마지막에 각 행을 코호트 크기로 나눌 때 `div(cohort_size, axis=0)` 로 행 방향을 맞춥니다. 6월 코호트의 M+1은 7월 데이터가 필요한데 데이터가 없으므로, 그 셀은 0이 아니라 빈칸(결측)이어야 합니다.

## 문제 06 2회차 구매 전환율 개선 과제

난이도: ★★☆☆☆

## 상황

팀 안에 소문이 돌니다. "신규 고객의 절반 이상이 한 번 사고는 사라진대요." 사실이라면 큰 문제입니다. 첫 구매를 2회차로 잇는 것이 리텐션의 첫 관문이기 때문입니다. 의뢰는 이 소문의 진위를 확인하고, 어떤 첫 구매 경험이 2회차로 잘 이어지는지를 특성별로 쪼개 개선 과제를 도출하는 것입니다.

## 과제

1. 1~5월 첫 구매 고객 중 30일 내 2회차 유효 주문에 도달한 비율을 산출합니다. 6월 첫 구매 고객은 30일 관찰 창을 채울 수 없으므로 제외하고, 그 이유를 명시합니다.
2. 첫 구매의 채널·카테고리·할인 여부별 2회차 전환율을 비교합니다(할인 여부는 첫 주문 라인에 `discount > 0` 이 있으면 '할인'으로 정의).
3. 전환율이 가장 낮은 조합을 개선 과제로 정의하고 왜 낮은지 가설을 제시합니다.

제출물은 첫 구매 특성별 30일 2회차 전환율 표와 개선 과제 1건 및 가설입니다.

## 사용 데이터

`orders` (첫·둘째 주문 식별), `order_items` · `products` (첫 구매 카테고리·할인 여부)를 씁니다. 관찰 창을 6월 제외로 통제하지 않으면 이른 코호트가 유리해지는 편향이 생깁니다.

## 힌트

고객별로 주문을 시간순 정렬한 뒤 `groupby("customer_id").cumcount()` 로 순번을 매기면, 순번 0 이 첫 주문, 1이 둘째 주문입니다. 첫 주문과 둘째 주문의 날짜 차이가 30일 이하이면 전환 성공입니다. 둘째 주문이 아예 없는 고객은 자동으로 미전환입니다.

## 문제 07 상·하반기 신규 코호트 질 비교

난이도: ★★★★★☆

## 상황

2분기에 광고비를 크게 늘렸고, 신규 고객이 눈에 띄게 늘었습니다. 경영진의 질문은 획득량이 아닙니다. "늘어난 신규가, 예전에 데려온 신규만큼 좋은 고객인가요?" 광고비를 더 쓴 뒤 들어온 고객의 '질'이 유지되는지, 아니면 돈을 써서 질 낮은 고객을 끌어모은 것인지를 가려야 합니다.

이것은 리텐션 분석에서 가장 위험한 비교입니다. 코호트마다 관측된 기간이 다르기 때문입니다. 관찰 창을 맞추지 않고 비교하면 항상 먼저 들어온 코호트가 이깁니다. 단지 시간이 더 많았기 때문입니다. 이 편향을 통제하는 것이 이 문제의 본체입니다.

## 과제

1. 1~2월 첫 구매 코호트(A)와 4~5월 첫 구매 코호트(B)를 정의하고, 각 코호트에 동일한 30일 관찰 창을 적용합니다.

2. 동일 관찰 창 기준 초기 30일 누적 순매출·재구매율·객단가(AOV)를 코호트 간 비교합니다. 대조를 위해 관찰 창을 맞추지 '않은' 편향된 비교도 함께 보여, 두 결과가 얼마나 다른지 드러냅니다.
3. 채널 구성 차이가 결론을 바꾸는지 채널별 증화로 재확인하고 최종 판정을 작성합니다.

제출물은 두 코호트의 초기 30일 성과 비교표(전체 + 채널 증화)와 '질이 유지되는가' 판정입니다.

## 사용 데이터

`orders`, `order_items` (주문별 순매출·AOV)를 씁니다. 데이터는 2024년 상반기만 존재하므로, A는 상대적으로 이른 코호트, B는 늦은 코호트를 뜻합니다.

## 힌트

각 고객의 첫 구매 시각을 기준으로 잡고, 첫 구매 후 0~30일 이내의 주문만 남겨 지표를 계산합니다. 이렇게 하면 A와 B가 똑같이 '첫 30일'만 놓고 겨루게 됩니다. 편향된 비교는 반대로 관찰 창 없이 전체 기간(각 코호트가 실제로 관측된 만큼)을 누적해 보여 주면 됩니다. 두 표를 나란히 놓는 것이 이 문제의 교육 포인트입니다.

## 제4장 퍼널과 전환 분석

전환율 개선 스프린트의 첫 주입니다. 그로스 리드가 화이트보드에 "우리 퍼널이 어디서 새는가?"라고 적어 놓고 회의를 시작합니다. 지금까지 팀은 "장바구니 이탈이 문제다", "검색을 강화하면 전환이 오른다", "저녁 시간에 광고를 몰아야 한다" 같은 말을 감으로 주고받았지만, 어느 것도 수치로 확인된 적이 없습니다. 이 장의 임무는 그 감을 데이터로 바꾸는 것입니다.

무대는 100만 행짜리 행동 로그 `web_logs` 입니다. 고객이 사이트에서 남긴 조회(view)·검색(search)·장바구니 담기(cart)·구매(purchase) 이벤트가 세션(`session_id`) 단위로 쌓여 있습니다. 이 장의 세 문제는 모두 이 로그를 세션 단위로 재구성해 퍼널을 세우고, 이탈 지점을 찾고, 광고 시간을 정하고, 마지막에는 "이 로그를 얼마나 믿어도 되는가"까지 검증합니다.

100만 행을 다루는 만큼 적재 방식이 성능을 좌우합니다. 이 장의 모든 풀이는 필요한 열만 `usecols` 로 고르고 `dtype` 을 지정해 메모리를 줄이는 것으로 시작합니다. 또 하나 이 장을 관통하는 주제가 있습니다. 퍼널 단계나 검색 효과 같은 지표는 **정의를 어떻게 잡느냐에 따라 숫자가 달라지는 자의적 선택**을 포함합니다. 각 문제는 그 선택을 숨기지 않고 규칙으로 고정한 뒤, 그 규칙 위에서만 결론을 내립니다. 특히 문제 10은 "계산은 쉬운데 해석이 어려운" 문제입니다. 상관을 인과로 착각하지 않고, 로그를 맹신하지 않는 규율이 이 장의 진짜 산출물입니다.

### 문제 08 세션 퍼널 구축과 단계별 이탈

난이도: ★★★☆☆

#### 상황

전환율 개선 스프린트의 첫 회의에서 그로스 리드가 요구한 것은 화려한 대시보드가 아니라 "기본 사실"입니다. 방문한 세션 중 몇 퍼센트가 장바구니를 담고, 그중 몇 퍼센트가 결제까지 가는 지, 그 단계별 숫자부터 확정해야 이후 실험을 어디에 걸지 정할 수 있습니다. 당신은 세션 단위 퍼널 표를 만들어 오라는 첫 과제를 받았습니다.

#### 과제

1. `web_logs` 를 세션(`session_id`) 단위로 집계해 view·cart·purchase에 도달한 세션 수를 산출합니다(100만 행이므로 `usecols` · `dtype` 지정으로 가볍게 적재).



2. view->cart, cart->purchase 단계별 전환율과 정규 경로 전체 전환율을 계산합니다.
3. 가장 큰 이탈 단계를 지목하고 개선 실험 아이디어 2건을 제안합니다.
4. 제출물: 퍼널 도달 표(단계별 세션수·전환율)와 병목 진단, 실험 아이디어.

이 문제의 핵심 판단은 **퍼널 단계의 정의**입니다. 특히 장바구니를 거치지 않고 바로 구매한 세션을 어떻게 셀지 규칙을 먼저 고정해야 합니다.

## 사용 데이터

- `web_logs`: `event_type` (view/search/cart/purchase), `session_id`. 100만 행입니다.
- 만나게 될 문제: 한 세션에 같은 이벤트가 여러 번 찍힙니다(이벤트 수가 아니라 도달 여부로 세야 합니다). 또 상당수 세션이 cart 없이 바로 purchase를 남깁니다.

## 힌트

세션×이벤트유형의 "도달 여부" 행렬을 먼저 만들면 이후가 쉽습니다. `drop_duplicates` 로 세션당 이벤트 유형을 한 번씩만 남긴 뒤 `crosstab` 으로 0/1 행렬을 만들어 보십시오. 전환율의 분자·분모를 "세션 수"로 통일하는 것이 관건입니다.

# 문제 09 요일×시간대 전환 패턴과 광고 시간 최적화

난이도: ★★★☆☆

## 상황

퍼포먼스 마케터가 광고 입찰을 시간대별로 차등하려 합니다. 통념은 "저녁·주말에 전환이 잘 되니 그때 입찰을 높이자"는 것입니다. 그런데 쟁점이 하나 있습니다. **트래픽이 많은 시간과 전환이 잘 되는 시간이 다를 수 있다**는 것입니다. 만약 둘이 다르다면, 트래픽만 보고 입찰하면 전환이 낮은 시간에 돈을 쓰게 됩니다. 당신은 요일과 시간대별로 세션 수와 전환율을 갈라 그려, 정말 차등 입찰의 근거가 있는지 확인해야 합니다.

## 과제

1. 세션별 시작 시각(최초 이벤트)으로 요일과 시간대를 부여합니다.
2. 시간대별 세션수·전환율 프로파일과, 요일×시간대 세션수·전환율 피벗 2종을 만듭니다.
3. 트래픽 상위 시간대와 전환율 상위 시간대를 대조해 입찰을 강화/축소할 근거가 있는지 판단하고 제안합니다.

4. 제출물: 시간대·요일 프로파일 표와 요일×시간대 피벗 2종, 입찰 조정 의견.

## 사용 데이터

- `web_logs`: `event_type`, `event_time`, `session_id`.
- 문제: 새벽 시간대는 분모(세션 수)가 작아 전환율이 될 수 있습니다. 최소 표본 기준을 정해 불안정한 셀을 걸러야 합니다.

## 힌트

세션 시작 시각은 세션별 `event_time` 의 최솟값입니다. `dt.dayofweek` · `dt.hour` 로 요일·시간을 뽑고, 세션 단위 표에서 `groupby` 로 세션수와 구매 도달 평균(=전환율)을 함께 집계하십시오.

## 문제 10 행동 로그와 주문 데이터 대사

난이도: ★★★★★☆

## 상황

로그 기반 전환율과 주문 시스템의 매출이 안 맞는다는 지적이 나왔습니다. 대시보드의 "구매 이벤트 수"와 재무의 "주문 수"가 다르니, 경영진이 "그럼 우리가 봐 온 로그 전환율을 믿어도 되느냐"고 묻습니다. 당신은 두 소스를 대사(對査)해 유실이 얼마나 되는지 확정하고, 로그를 어디까지 신뢰해도 되는지 가이드라인을 써야 합니다.

## 과제

1. `orders` 를 web 채널로 한정해 `web_logs` 의 purchase 이벤트 수·고객수와 유효 주문수·고객수를 기간별로 대조합니다. 로그는 사이트 행동 기록이므로 store-app 주문과의 대조는 무의미하며, 그 근거를 명시합니다.
2. 고객·날짜 단위로 두 소스를 병합해 "로그에만 있는 구매"와 "주문에만 있는 구매" 규모를 추정합니다.
3. 로그 유실(또는 과다) 추정치를 제시하고, 로그 기반 지표 사용 가이드라인 3줄을 작성합니다.

## 사용 데이터

- `web_logs`: `event_type` (purchase), `event_time`, `customer_id` (결측 존재).

- `orders`: `order_datetime` (타입 오염), `channel`, `status`, `customer_id`.
- 문제: 로그의 `purchase`와 주문 1건이 1:1이 아닐 수 있어 매칭 단위를 정해야 하고, `customer_id` 결측 로그는 대사가 불가능해 별도 계상합니다.

## 힌트

먼저 왜 web 채널로 한정하는지부터 근거를 세우십시오(전체 채널로 대조하면 유실률이 얼마나 부풀려지는지 직접 보이면 설득력이 생깁니다). 그다음 총량 대조 -> 월별 대조 -> 고객×일 단위 병합(`merge(indicator=True)`) 순으로 해상도를 높여 갑니다.

## 제5장 상품 포트폴리오와 MD 전략

MD(상품기획)팀 회의실에 500개 상품의 상반기 실적이 한 장으로 펼쳐졌습니다. 팀장은 "우리가 500개를 다 똑같이 관리하고 있다"는 말로 회의를 엽니다. 어떤 상품은 매출의 기둥인데 창고 구석에서 재고가 마르고, 어떤 상품은 아무도 안 사는데 진열 앞자리를 차지합니다. 이 장의 무대는 "무엇을 밀고, 무엇을 접고, 무엇을 묶어 팔 것인가"를 데이터로 정하는 상품 전략 리뷰입니다.

이 장에서 푸는 세 문제는 MD 업무의 세 축을 그대로 따라갑니다. 문제 11은 매출만이 아니라 마진과 반품까지 함께 본 카테고리 종합 판단표로 확대·유지·축소를 정합니다. 문제 12는 실제로 함께 사는 조합을 찾아 번들 후보를 뽑고, 문제 13은 마진 리포트를 멈춰 세운 마이너스 마진의 정체(상품 마스터 오류인가 진짜 역마진인가)를 가려냅니다.

세 문제는 하나의 공통 함정을 공유합니다. 상품 카테고리에는 앞뒤 공백 오염이 섞여 있어 '가구'와 '가구 '가 서로 다른 카테고리로 갈라지고, 상품 마스터의 price에는 0원과 음수, 콤마, '원'이 붙은 문자열이 섞여 있습니다. 정제를 건너뛰면 등급표도 마진표도 조용히 틀립니다. 그래서 이 장의 모든 풀이는 정제를 먼저 하고, 정제 후의 숫자를 실측으로 대조하는 데서 출발합니다.

이 장의 매출 지표는 1장 문제 01에서 도출한 표준 순매출 원장을 기준으로 삼습니다. 각 문제는 자기완결로 풀 수 있도록 그 원장 코드를 처음 쓸 때 그대로 씁니다.

### 문제 11 카테고리 확대·유지·축소 매트릭스

난이도: ★★★☆☆

#### 상황

하반기 카테고리 전략 회의입니다. 영업팀은 "전자와 가구가 매출이 크니 더 밀자"고 주장합니다. 그런데 재무팀이 반문합니다. "매출이 큰 게 이익도 큰 겁니까? 반품까지 빼고도 남습니까?" 매출·마진·반품은 서로 다른 이야기를 할 수 있습니다. MD 리더가 요청합니다. "세 지표를 한 표에 놓고 종합 점수로 확대·유지·축소를 정해 주세요. 그리고 매출만 봤을 때와 결론이 달라진 카테고리를 짚어 주세요."

## 과제

1. 카테고리별 순매출·마진율·반품률을 하나의 표로 결합합니다. 마진율은 (거래 단가로 매긴 매출 - 원가)/매출, 반품률은 반품 주문수/취소 제외 주문수로 정의합니다.
2. 각 지표를 순위 점수로 바꿔 가중치를 명시한 종합 점수를 만듭니다.
3. 종합 점수로 확대/유지/축소를 카테고리별로 부여하고, 매출 단독 판단과 결론이 달라진 카테고리를 지목합니다. 가중치를 바꾼 민감도도 한 번 보여 줍니다.
4. 제출물: 카테고리 3지표 종합표 + 확대·유지·축소 제안 + 판단 변경 사례 해설.

## 사용 데이터

order\_items·orders·products를 씁니다. 마진 계산에는 products.cost가 필요한데, cost는 결측이 없습니다(문제 13에서 확인). 매출과 마진은 상품 마스터의 오염된 price가 아니라 실제 거래 단가(order\_items.unit\_price)로 계산해 마스터 오류의 영향을 받지 않게 합니다. 반품률 계산에는 취소·반품을 포함한 전체 주문 상태가 필요합니다.

## 힌트

세 지표를 따로 집계해 카테고리 인덱스로 join 합니다. 반품률의 분모를 무엇으로 할지(취소 포함 여부)를 먼저 정하십시오. 지표 단위가 제각각이므로 값 자체가 아니라 rank() 로 순위를 매겨 더합니다. 매출·마진은 클수록 좋고 반품률은 작을수록 좋으니 순위 방향을 지표마다 맞춰야 합니다.

## 문제 12 동시구매 분석과 번들 후보

난이도: ★★★★★☆

### 상황

객단가를 올리려 번들 프로모션("이 상품 사면 저 상품 할인")을 기획합니다. 문제는 '무엇과 무엇을 묶을까'입니다. 감으로 정하면 안 됩니다. MD가 요청합니다. "실제로 같은 주문에 함께 담긴 조합을 데이터에서 찾아 주세요. 단, 단순히 인기 상품끼리 자주 겹치는 착시는 걸러 주세요."

## 과제

1. 같은 주문에 함께 담긴 카테고리 쌍을 self-merge로 만들고 쌍별 동시구매 주문수를 집계합니다.
2. 개별 카테고리 인기로 인한 착시를 줄이기 위해 보정 지표(지지도·향상도 lift)를 병행합니다.
3. 상품 수준에서도 상위 동시구매 쌍을 뽑아 번들 후보 3건과 예상 효과 논리를 제시합니다.
4. 제출물: 카테고리 쌍 동시구매 상위표(원지표+보정지표) + 상품 번들 후보 3건.

## 사용 데이터

order\_items·orders·products를 씁니다. order\_items는 50만 행이라, 같은 주문의 상품을 서로 짝짓는 self-merge를 원본에 그대로 걸면 메모리가 폭발합니다. 반드시 '주문×카테고리' 고유 조합으로 축약한 뒤 조인해야 합니다.

## 힌트

먼저 라인을 (주문, 카테고리) 고유쌍으로 줄입니다(`drop_duplicates`). self-merge는 같은 `order_id` 로 조인한 뒤, 같은 카테고리끼리 짝지어진 행( $A=A$ )을 버리고  $A<B$  조건으로 (A,B)와 (B,A) 중복을 하나로 만듭니다. 향상도(lift)는 두 카테고리가 서로 무관할 때 1이 되도록 설계된 보정 지표입니다.

## 문제 13 상품 마스터 이상 진단과 지표 영향

난이도: ★★★☆☆

### 상황

마진을 리포트를 화면에 띄우자 마이너스 마진 상품이 무더기로 뿔었습니다. "우리가 손해 보고 파는 상품이 이렇게 많다고?" 회의가 멈췄습니다. 데이터 분석가인 당신에게 질문이 떨어집니다. "이게 진짜 손해 보고 파는 겁니까, 아니면 상품 마스터 데이터가 틀린 겁니까? 가려 주세요."

### 과제

1. products에서 price 0·음수·비수치 형식·결측 등 이상 레코드를 유형별로 검출·집계합니다.
2. 이상 상품이 실제 판매(order\_items)에서 어떤 단가로 팔렸는지 대조해 '마스터 오류'와 '진짜 역마진'을 구분합니다.

3. 마진 리포트를 거래 단가 기준으로 재산출해 마스터 price 기준과의 차이를 수치로 보이고, 마스터 정비 우선순위 목록을 작성합니다.
4. 제출물: 이상 유형별 상품 목록.건수 + 두 기준 마진 차이표 + 정비 우선순위.

## 사용 데이터

products.order\_items.orders를 씁니다. products.price는 숫자가 아니라 문자열(object) 타입입니다. 콤마가 붙은 '14,200', '원'이 붙은 '12300원' 같은 형식 오염과 0·음수 값이 섞여 있기 때문입니다. 반면 order\_items.unit\_price는 주문 시점에 실제로 청구된 단가라 깨끗한 숫자입니다.

## 힌트

price를 `pd.to_numeric(errors="coerce")` 로 숫자화하면 형식 오염 값은 NaN이 되어 자동으로 걸러집니다. 이상 유형을 서로 겹치지 않게 정의하십시오(형식 오염 / 0 / 음수 / 결측 / 유효한데 역마진). '진짜 역마진'인지 판정하려면 마스터 price가 아니라 order\_items에서 그 상품이 실제로 팔린 단가를 봐야 합니다.

## 제6장 가격과 할인 효과 분석

프로모션 예산 회의는 언제나 같은 지점에서 막힙니다. 마케팅팀은 "할인을 걸면 매출이 뛴니다"라고 말하고, 재무팀은 "그 매출이 이익을 남기긴 합니까"라고 되받습니다. 두 말은 모두 맞을 수 있습니다. 할인은 매출을 늘리면서 동시에 이익을 갉아먹기 때문입니다. 이 장의 의뢰는 그 둘을 한 표 안에서 나란히 보이게 만드는 일입니다.

이 장에서는 세 개의 질문을 차례로 품니다. 할인을 구간마다 손익이 어떻게 갈리는지(문제 14), 어떤 상품이 사실상 정가로는 팔리지 않는지(문제 15), 그리고 할인으로 포기한 이익이 실제로 얼마이며 그것이 정당화되려면 무엇이 참이어야 하는지(문제 16)입니다.

세 문제를 관통하는 규율이 하나 있습니다. 이 장의 거의 모든 표는 "할인 구간에서 많이 팔렸다"는 사실을 보여 주지만, 그것은 "할인해서 팔렸다"와 다릅니다. 할인 구간에 놓인 상품 구성 자체가 다르기 때문입니다. 관찰된 상관을 인과로 바꿔 읽는 순간 보고서는 틀리므로, 각 문제의 해석 절에서 "여기까지가 관찰이고, 인과라고 말하려면 무엇이 더 필요한가"를 반복해서 못 박습니다.

마지막으로 이 장은 원가(products.cost)를 쓰는 첫 장입니다. 상품 마스터에는 값이 0인 정가, 심표와 '원' 문자가 섞인 가격, 완전히 중복된 상품 행이 있으므로, 문제 14에서 마진 계산 규칙을 먼저 고정하고 세 문제에서 같은 규칙을 그대로 씁니다.

### 문제 14 할인을 구간별 손익 분석

난이도: ★★★☆☆

#### 상황

프로모션 예산 회의에서 CFO가 질문을 던졌습니다. "할인이 매출을 늘린다는 건 알겠는데, 그게 이익까지 남기는 겁니까, 아니면 매출만 부풀리고 이익은 갉아먹는 겁니까." 회의 자료에는 총매출만 있고 마진이 없어 아무도 답하지 못했습니다. 마케팅 데이터 분석가인 당신에게 "할인을 구간별로 수량과 매출과 마진을 한 표에서 보게 해 달라"는 요청이 떨어졌습니다.

#### 과제

1. 할인율(discount)을 정가(0%), 0~10%, 10~20%, 20% 초과로 네 구간으로 나눕니다.



- 구간별로 판매 수량, 순매출, 마진액, 마진율, 평균 판매 단가를 하나의 표로 만듭니다.
- 구간별 평균 판매 단가와 수량의 관계를 관찰해 "할인이 수량을 늘렸는가"에 관찰적 답변을 쓰되, 그것이 인과가 아님을 분명히 합니다.
- 마진 관점에서 가장 비효율적인 구간을 지목하고 할인 상한 정책을 한 단락으로 제안합니다.

제출물은 할인 구간 x (수량, 순매출, 마진액, 마진율) 표와 정책 제안 한 단락입니다.

## 사용 데이터

order\_items(수량·단가·할인), orders(상태·주문일), products(원가·카테고리)를 씁니다. 이 문제에서 만나는 품질 문제는 세 가지입니다. products에 완전히 중복된 상품 행이 3건 있어 그대로 결합하면 매출이 부풀고, category에 앞뒤 공백이 섞여 있으며, cost는 결측이 없지만 할인이 깊어지면 판매가가 원가 아래로 내려가는 역마진 라인이 생깁니다.

## 힌트

먼저 1장 문제 01의 표준 순매출 원장을 그대로 만든 뒤, products를 결합하기 전에 중복 행부터 제거하십시오. 마진은 상품 마스터의 정가가 아니라 실제로 팔린 단가(order\_items.unit\_price)를 기준으로 계산해야 합니다. 구간화는 `pd.cut`에 경계를 직접 지정하면 정가(0%)를 독립 구간으로 떼어낼 수 있습니다.

## 문제 15 할인 의존 상품 검출

난이도: ★★★☆☆

## 상황

MD팀장이 우려를 꺼냈습니다. "상시 할인을 너무 오래 걸어 두니, 고객이 정가를 아예 안 믿습니다. 정가로는 사실상 안 팔리는 상품이 어떤 것들인지 추려서 가격 정책을 다시 봐야 합니다." 당신은 "정가에 의존하지 못하고 할인에 기대어 팔리는 상품" 목록을 만들어 달라는 의뢰를 받았습니다.

## 과제

- 상품별로 할인 판매 비중(할인 라인 수량 / 전체 수량)과 수량 가중 평균 할인율을 산출합니다.

2. 할인 판매 비중이 높고(80% 이상) 판매량이 유의미한 상품을 '할인 의존' 목록으로 추출합니다. 표본이 적은 상품이 비중 100%로 튀지 않도록 최소 판매량 컷을 둡니다.
3. 이들 상품의 정가 판매 실적을 대조하되, 정가 판매 표본이 정의상 작다는 점(비중 80% 이상의 여집합)을 명시하고, 최소 정가 판매 건수에 못 미치는 상품은 '대조 불가'로 따로 계상한 뒤 정가 인하 대 할인 유지의 논점을 정리합니다.

제출물은 할인 의존 상품 목록(비중·평균 할인율·판매량)과 가격 정책 논점 정리입니다.

## 사용 데이터

order\_items(수량·할인)와 products(상품명·카테고리)를 씁니다. 이 문제의 핵심 데이터 특성은 할인이 거의 모든 거래에 걸쳐 있다는 점입니다. 그래서 정가 판매 라인이 매우 희소하고, 이 희소성 자체가 분석의 결론을 좌우합니다.

## 힌트

상품별 집계에서 할인 수량과 정가 수량을 각각 조건부 합계로 구하면 비중이 나옵니다. 평균 할인율은 단순 평균이 아니라 수량 가중 평균이어야 소량 라인의 극단값에 휘돌리지 않습니다. 목록을 뽑기 전에 할인 판매 비중의 분포를 먼저 확인해 보십시오. 임계값을 정하기 전에 데이터가 어떻게 퍼져 있는지 보는 것이 순서입니다.

# 문제 16 할인 마진 잠식 시뮬레이션

난이도: ★★★★★☆

## 상황

CFO가 반사실 질문을 던졌습니다. "상반기 할인으로 우리가 포기한 금액이 정확히 얼마입니까. 그리고 그 할인 덕분에 실제로 그만큼 더 팔린 게 맞습니까." 앞의 질문은 계산으로 답할 수 있지만, 뒤의 질문은 "할인이 없었다면 어떻게 됐을까"라는 일어나지 않은 세계를 상상해야 합니다. 가정을 명시한 시뮬레이션이 이 문제의 본체입니다.

## 과제

1. 실제 순매출·마진과 '할인이 없었다면'(동일 수량 가정) 매출·마진을 대조해 할인으로 포기한 금액을 산출합니다.

2. 할인이 없었다면 수량이 줄었을 시나리오(할인 라인 수량 20%~50% 감소) 두 가지를 추가해 손익을 비교합니다.
3. '할인이 정당화되려면 할인 판매의 몇 %가 할인 덕에 발생했어야 하는가'를 손익분기 감소율로 역산해 결론으로 제시합니다.

제출물은 실제 대 시나리오별 손익 대조표, 손익분기 감소율, 결론 문구입니다.

## 사용 데이터

order\_items·orders·products를 씁니다. 새로운 품질 문제는 없지만, 이 문제는 데이터 정제보다 가정의 명시가 핵심입니다. 어떤 가정을 두었는지가 결론의 신뢰도를 전부 결정합니다.

## 힌트

order\_items.unit\_price는 할인 전 단가이고 실제 판매가는  $\text{unit\_price} \times (1 - \text{discount})$  입니다. 따라서 '할인이 없었다면'의 정가 매출은  $\text{수량} \times \text{unit\_price}$  로 바로 계산됩니다. 동일 수량 가정은 계산이 쉽지만 비현실적으로 낙관적인 상한이라는 점을 반드시 명시하십시오. 손익분기는 방정식을 세워 미지수(수량 유지율)를 역산하면 나옵니다.

## 제7장 고객 생애가치와 이탈 관리

앞선 여섯 장에서 우리는 매출을 정확히 세고, 고객을 나누고, 코호트와 퍼널로 흐름을 읽고, 상품과 할인의 손익을 따졌습니다. 이번 장의 무대는 한 단계 위입니다. 성장팀 회의에서 CMO가 이렇게 말합니다. "이제 매출 총량 말고, 고객 한 명이 우리에게 얼마를 남기는지를 기준으로 예산을 다시 짜고 싶습니다. 획득에 얼마까지 써도 되는지, 떠나는 고객을 어떻게 붙잡을지 데이터로 답을 주십시오."

이 요구는 세 가지 질문으로 갈라집니다. 첫째, 고객 한 명의 가치는 얼마인가(LTV). 둘째, 언제부터 고객이 '떠났다'고 볼 것인가(이탈 정의). 셋째, 떠나는 고객 중 누구를 먼저 붙잡을 것인가. 이 장의 네 문제가 정확히 그 순서를 따라갑니다.

한 가지 원칙을 장 전체에서 지킵니다. 우리 데이터는 2024년 상반기 6개월뿐입니다. 그래서 우리가 구하는 값은 **실현 LTV**(관측된 6개월 안에 실제로 발생한 가치)이지, 고객이 평생 남길 **예측 LTV**가 아닙니다. 6개월 숫자에 2를 곱해 "연간 가치"라 부르는 순간 그것은 관측이 아니라 가정입니다. 이 구분을 흐리면 획득비 상한도, 이탈 손실 추정도 전부 부풀려집니다. 문제 17은 그 기준선을 세우고, 문제 18은 코호트 곡선으로 획득비 상한을 논의하며, 문제 19는 이탈의 기준선을, 문제 20은 위험 스코어카드와 우선 관리군 목록을 완성합니다.

이 장의 모든 문제는 1장 문제 01에서确定的한 표준 순매출 원장을 공통 기반으로 씁니다(취소·반품 제외, 라인 금액 = 수량 x 단가 x (1 - 할인율), 상반기 순매출 합계 466억 원). 원장을 만드는 코드는 문제 17에서 한 번 전부 실행하고, 이후 문제는 그 원장을 재사용한다고만 밝힙니다.

### 문제 17 6개월 실현 LTV와 가치 집중도

난이도: ★★★☆☆

#### 상황

고객 획득 예산을 늘리자는 안건이 올라왔습니다. 퍼포먼스팀은 "고객 한 명당 5만 원까지 써도 남는다"고 주장하지만 근거가 '평균 LTV'입니다. CMO는 그 평균이 소수 대형 고객에 끌려 올라간 것은 아닌지 의심합니다. 예산 논의에 앞서, 상반기에 고객 한 명이 **실제로** 남긴 가치가 얼마이고 그 가치가 얼마나 소수에게 몰려 있는지부터 확정해야 합니다.

## 과제

1. 표준 순매출 원장에 상품 원가(cost)를 붙여 고객별 **순매출 LTV**와 **마진(기여이익) LTV**를 함께 산출합니다.
2. 두 지표의 분포(평균·중앙값·P90·P99)와 상위 10% 고객의 가치 점유율(집중도)을 계산합니다.
3. "평균 LTV로 획득비를 정하면 안 되는 이유"를 분포 수치를 근거로 서술합니다.
4. 제출물: 매출·마진 기준 LTV 분포 요약표 + 상위 고객 집중도 수치 + 획득비 논의에 주는 시사점 한 단락.

## 사용 데이터

`orders`, `order_items`, `products` (원가), `customers` (고객 모수 확인)를 씁니다. 마진 계산에는 상품 마스터의 `cost` 를 쓰되, 매출 단가는 마스터의 오염된 `price` 가 아니라 거래 시점 값인 `order_items.unit_price` 를 씁니다. 주문에 등장하는 고객 id가 고객 마스터보다 많다는 데이터 특성도 이 문제에서 드러납니다.

## 힌트

원장 라인마다  $\text{margin} = \text{quantity} \times (\text{unit\_price} \times (1 - \text{discount}) - \text{cost})$  를 파생하면 마진 LTV를 매출 LTV와 같은 방식으로 집계할 수 있습니다. 집중도는 고객을 가치 내림차순으로 정렬해 상위 n명의 합을 전체 합으로 나눕니다. 평균과 중앙값의 간극이 곧 왜곡의 크기입니다.

## 문제 18 코호트별 LTV 곡선과 획득비 상한

난이도: ★★★★★☆

### 상황

퍼포먼스팀이 단도직입으로 묻습니다. "고객 1명 획득에 얼마까지 써도 됩니까?" 문제 17에서 우리는 고객당 가치가 소수에 몰려 있음을 확인했습니다. 이제 '평균 한 명'이 아니라 '언제 획득한 코호트가, 시간이 지나며 얼마를 누적하는지'를 곡선으로 보여야 합니다. 곡선의 초기 기울기가 획득비 회수 속도를 결정합니다.

## 과제

1. 첫 구매 월 코호트별로, 경과 월에 따른 **1인당 누적 순매출(및 마진) 곡선**을 산출합니다.

2. 곡선의 형태(초기 집중형인지 지속 누적형인지)를 읽고, 첫 구매 후 **90일 시점의 1인당 마진**을 산출합니다.
3. '마진 회수 기간 90일' 정책 가정에서 획득비 상한을 제안하되, 6개월 관측이라는 한계와 가정을 표로 명시합니다.
4. 제출물: 코호트별 누적 LTV 곡선표 + 90일 마진 기준 획득비 상한 제안(가정 3개 명시).

## 사용 데이터

`orders`, `order_items`, `products` 로 만든 표준 순매출 원장(문제 17)을 재사용합니다. 여기에 고객별 첫 구매일과 첫 구매 월(코호트)을 파생합니다.

## 힌트

경과 월은 (주문월 period) - (코호트월 period) 로 계산합니다. 코호트별 경과월 합을 코호트 크기로 나눈 뒤 경과월 방향으로 cumsum 하면 1인당 누적 곡선이 됩니다. 90일 마진은 월 단위가 아니라 첫 구매일 기준 실제 날짜 차이로 계산하고, **관측이 끝난(90일 차이가 6/30 안에 들어오는) 코호트만** 평균에 넣습니다.

## 문제 19 이탈 기준선 탐색과 민감도

난이도: ★★★☆☆

## 상황

사내에는 "90일 무구매면 이탈"이라는 통념이 있습니다. 그런데 누구도 그 90일의 근거를 대지 못합니다. 리텐션 담당자는 "우리 고객은 훨씬 자주 사는데 90일은 너무 느슨한 것 아니냐"고 의심합니다. 재구매 간격 데이터로 기준선을 다시 세우고, 기준을 어떻게 잡느냐에 따라 이탈률이 얼마나 출렁이는지 보여야 합니다.

## 과제

1. 재구매 간격 분포에서 P75-P90 등 후보 기준선을 도출합니다(주문 1회 고객은 간격이 없어 분포에서 제외 — 인원 보고).
2. 기준선 후보(60-90-120일 등)별로 관측 종료일(6/30) 시점 이탈률을 각각 계산해 민감도표를 만듭니다.
3. 권고 기준선과 그 근거를 보고 문구로 작성하고, 관측 종료 근처 고객의 이탈 미확정(검열)을 개념적으로 짚습니다.

4. 제출물: 기준선 후보별 이탈률 민감도 표 + 권고 기준선과 근거 문구.

## 사용 데이터

`orders` (유효 주문, 주문 단위)만 있으면 됩니다. 고객별로 시간순 정렬해 연속 주문 간격을, 그리고 마지막 구매 후 경과일(recency)을 계산합니다.

## 힌트

간격은 `sort_values` 후 `groupby(...).shift(1)` 로 이전 주문 시각을 당겨 빼면 됩니다. recency 는 기준일에서 마지막 구매일을 빼되, 시각이 아니라 날짜 단위로 맞춰야 음수가 나오지 않습니다(같은 날 오후 구매 주의). 이탈률은 `recency > 기준선` 비율입니다.

## 문제 20 이탈 위험 스코어카드

난이도: ★★★★★☆

## 상황

경영진은 머신러닝 이탈 예측 모델 도입을 검토 중이지만, 운영팀은 "그 전에 지금 당장 쓸 수 있는, 설명 가능한 점수부터 달라"고 합니다. 왜 이 고객이 위험한지 한 줄로 설명되고, 매달 같은 규칙으로 재계산되는 규칙 기반 스코어카드가 목표입니다.

## 과제

1. recency-frequency-최근 30일 로그 활동(방문 여부) 3요소를 각 0~2점으로 점수화해 위험 점수(0~6)를 합산합니다.
2. 점수 구간과 과거 가치(상반기 순매출)를 교차해 우선 관리군(고위험 x 고가치)을 정의합니다.
3. 우선 관리군 목록과, 이들이 이탈할 경우의 예상 매출 손실(연 환산 가정 명시)을 산출합니다.
4. 제출물: 스코어 규칙표 + 위험 x 가치 분포 + 우선 관리군 목록과 손실 추정.

## 사용 데이터

`orders · order_items` (recency-frequency-가치), `web_logs` (최근 30일 방문 여부)를 씁니다.

`web_logs` 는 100만 행이므로 `usecols` 와 `dtype` 을 지정해 필요한 두 열만 가볍게 읽습니다. 로그

에 한 번도 없는 고객(웹 미사용)의 처리 규칙도 정합니다.

## 힌트

recency 컷은 문제 19의 이탈선(60일)보다 **앞선** 값으로 잡아야 조기 경보가 됩니다(이미 60일 침묵하면 늦음). frequency 컷은 분위수로 데이터에서 뽑습니다. 로그 방문은 6월(최근 30일) 등 장 여부의 이진값입니다. 위험과 가치를 교차하면 이 데이터의 중요한 구조가 드러납니다.



## 제8장 시계열 수요와 시즌성

하반기 사업계획 시즌이 돌아왔습니다. 수요 계획팀은 재고 발주와 CS 인력 배치, 프로모션 캘린더를 짜기 위해 "상반기 수요가 어떻게 움직였고, 다음 달은 얼마나 팔릴까"를 하나의 문서로 정리해 달라고 요청했습니다. 지금까지의 장이 "누가·무엇을·왜·샀는가"를 다뤘다면, 이번 장은 축을 시간으로 옮깁니다. 같은 순매출 데이터라도 시간 축에 올려놓으면 추세, 요일과 시간의 리듬, 계절의 그림자, 이례적인 급증, 그리고 아직 오지 않은 달의 전망이 보입니다.

이 장의 세 문제는 시계열 분석의 표준 흐름을 그대로 따릅니다. 먼저 일별 매출의 출렁임을 건너내고 진짜 추세를 확정하고(문제 21), 하루 안에서 주문이 언제 몰리는지 시간 단위로 그린 뒤(문제 22), 마지막으로 한계를 명시한 정직한 방법으로 7월 수요를 전망합니다(문제 23).

이 장에서 반복해 강조하는 태도가 하나 있습니다. 시계열은 사람을 쉽게 속입니다. 상승 추세 위에서는 무엇을 재도 "오른다"는 답만 나오고, 요일 구성을 무시한 채 달끼리 비교하면 없는 변화를 있다고 읽게 됩니다. 그래서 이 장의 해설은 계산만큼이나 "이 수치를 이렇게 읽으면 왜 틀리는가"에 지면을 씁니다. 데이터가 뚜렷한 신호를 주지 않을 때 "신호 없음"이라고 정직하게 보고하는 것도 이 장의 중요한 결론 중 하나입니다.

모든 문제는 1장 문제 01에서 도출한 표준 순매출 원장(취소·반품 제외, 중복·타입 오염 정제, 라인 금액 = 수량 x 단가 x (1 - 할인))을 시간 축에 올려 사용합니다. 앵커 수치(유효 주문 168,312 건, 상반기 순매출 466억 원, 월별 55.3억 원에서 101.1억 원으로 상승)와 어긋나면 코드를 의심하십시오.

### 문제 21 주간 매출 추세와 이동평균

난이도: ★★☆☆☆

#### 상황

수요 계획 회의에 매일 아침 일별 매출 그래프가 올라옵니다. 문제는 이 그래프가 톱니처럼 출렁여서, 어제가 좋으면 "회복세"라 하고 오늘이 나쁘면 "꺾였다"고 해석이 매번 뒤집힌다는 점입니다. 데이터 분석가로서 팀장은 여러분에게 "일별 등락에 흔들리지 말고 진짜 추세를 하나의 숫자로 확정해 달라"고 요청했습니다. 주간 단위로 묶고 이동평균으로 다듬은 뒤, 상반기 성장률을 보고 문구로 정리하는 것이 이번 과제입니다.

## 과제

1. 표준 순매출 원장을 datetime 인덱스의 일별 순매출 시계열로 구성합니다.
2. 주간 리샘플(일요일 마감, W-SUN)과 4주 이동평균을 병행 산출해 원계열과 대조합니다.
3. 이동평균 기준으로 상반기 추세를 판정하고 성장률을 계산합니다.
4. "일별 등락에 반응하지 말아야 할 이유"를 보고 문구로 작성합니다.

제출물: 주간 매출·4주 이동평균 표 + 추세 판정과 성장률 + 보고 문구 한 단락.

## 사용 데이터

- orders (order\_datetime, status), order\_items (quantity, unit\_price, discount)
- 주의: order\_datetime 에는 문자 오염과 기간 밖 이상값이 섞여 있어 표준 정제가 선행되어야 합니다. 2024년 상반기는 1월 1일(월요일)에 시작해 6월 30일(일요일)에 끝나므로, 일요일 마감 주간으로 자르면 26개 주가 모두 온전한 7일짜리 주간이 됩니다.

## 힌트

set\_index("order\_datetime") 후 resample("D") 로 일별 시계열을 만들고, 다시 resample("W-SUN") 으로 주간 합계를 냅니다. 이동평균은 주간 계열에 rolling(4).mean() 을 적용합니다. 성장률은 이동평균이 안정된 첫 값과 마지막 값을 비교하면 노이즈에 덜 흔들립니다.

# 문제 22 시간 단위 수요 프로파일과 피크 운영 계획

난이도: ★★★☆☆

## 상황

운영팀이 CS 상담 인력의 근무 시간대와 당일 출고 마감 시각을 수요에 맞춰 재배치하려 합니다. 지금은 감으로 "낮에 바쁘다"고 배치하는데, 실제로 주문이 하루 중 언제 몰리는지 데이터로 확인해 달라는 의뢰입니다. 주의할 점이 있습니다. 문제 09에서 이미 웹 로그의 세션을 기준으로 "전환이 잘 되는 시간"을 광고 입찰 관점에서 다뤘습니다. 이번 문제는 다른 물건입니다. 여기서는 실제로 결제까지 이어진 "주문 수요"를 시간 단위로 그려 운영 인력을 배치하는 것이 목적입니다. 두 관점이 어떻게 다른지도 함께 정리해야 합니다.

## 과제

1. `order_datetime` 을 시간 단위로 리샘플(`resample("h")`)해 상반기 전체의 시간대 수요 곡선을 만들고, 이와 구분되는 평균 일중 프로파일(시간대별 `groupby` 평균)을 평일/주말로 나눠 산출합니다.
2. 주문 피크 시간 구간(상위 25% 시간대)을 규칙으로 정의하고, 채널별(웹·앱·매장)로 피크가 다른지 층화 확인합니다.
3. 피크 커버리지 관점의 운영 배치를 제안하고, "주문 피크"와 문제 09의 "세션 전환 피크"가 다를 수 있는 이유를 대조 해설합니다.

제출물: 일중 수요 프로파일(평일/주말·채널별) + 피크 구간 정의 + 운영 배치 제안.

## 사용 데이터

- `orders` (`order_datetime`, `channel`, `status`), `order_items`
- 주문 수요는 유효 주문 헤더 단위로 셉니다(라인 수가 아니라 주문 건수).

## 힌트

두 가지를 헷갈리지 마십시오. `resample("h")` 는 달력의 시간 축(4368개 시점의 연속 계열)을 만들고, `dt.hour` 로 `groupby` 하면 하루 안의 시간 축(0시부터 23시까지 24칸)을 만듭니다. 운영 배치에 필요한 것은 후자, 즉 "평균적인 하루 안에서 몇 시에 몇 건이 들어오는가"입니다. 평일과 주말은 일수가 다르므로 합계가 아니라 "일수로 나눈 평균"으로 비교해야 공정합니다.

## 문제 23 7월 수요 나이트 예측과 한계 보고

난이도: ★★★★★☆

## 상황

수요 계획팀이 7월 매출 전망치를 요구합니다. 우리 팀에는 시계열 모델링 전문가가 없지만, 그렇다고 "모르겠다"고 답할 수는 없습니다. 다행히 근거와 한계가 명확한 "정직한 나이트 예측"은 지금 데이터로 충분히 가능합니다. 서로 다른 가정에 기댄 두 가지 방법으로 전망치를 내고, 각 방법을 과거 데이터로 백테스트해 어느 쪽이 더 믿을 만한지 실측한 뒤, 구간으로 제시하는 것이 이번 과제입니다.

## 과제

1. 예측 2안을 산출합니다. A안은 최근 3개월 평균 월간 성장률을 외삽하고, B안은 6월 요일별 일평균에 7월 달력의 요일 구성을 반영합니다.
2. 두 안의 전망치와 차이를 대조하고 각 방법의 가정을 명시합니다.
3. 백테스트(1~5월 데이터로 6월을 예측해 실제와 오차 측정)로 두 방법의 신뢰도를 실측하고 권고안을 선택합니다. 전망치는 낙관/보수 구간으로 제시합니다.

제출물: 7월 전망 2안 + 가정표 + 6월 백테스트 오차 실측 + 권고안.

## 사용 데이터

- `orders`, `order_items`
- 월별·요일별 순매출은 표준 원장에서 리샘플로 산출합니다.

## 힌트

백테스트가 이 문제의 핵심입니다. 미래(7월)는 정답을 모르지만, 과거(6월)는 답을 압니다. 그러니 1~5월만 써서 두 방법으로 6월을 예측하고 실제 6월과 비교하면, 각 방법이 얼마나 틀리는지 실측할 수 있습니다. B안의 요일 계수는 `daily.groupby(daily.index.dayofweek).mean()` 으로 요일별 일평균을 구한 뒤, 대상 달 달력의 각 날짜에 해당 요일 평균을 더하면 됩니다.

## 제9장 비교 분석과 준실험적 사고

지금까지의 장에서는 "무엇이 얼마인가"를 셧습니다. 이 장은 성격이 다릅니다. 회의실에는 이미 결론이 나와 있고, 그 결론을 뒷받침하는 표가 붙어 있습니다. "앱 고객의 객단가가 더 높으니 앱에 투자하자", "반품한 고객은 떠난다", "할인으로 유치한 고객은 할인만 먹고 도망간다". 이런 문장들은 모두 어떤 비교에서 나옵니다. 그리고 그 비교의 대부분은 공정하지 않습니다.

두 집단을 나란히 놓고 평균을 비교하는 순간, 우리는 암묵적으로 "다른 조건은 같다"고 가정합니다. 그러나 앱을 쓰는 사람과 웹을 쓰는 사람은 애초에 다른 사람이고, 반품을 한 고객은 원래 더 활발한 구매자이며, 할인으로 시작한 고객은 처음부터 가격에 민감한 사람일 수 있습니다. 집단을 가른 기준 자체가 결과에 영향을 주는 다른 요인과 얽혀 있을 때, 우리는 그것을 **구성 차이**나 **자기선택 편향(self-selection bias)**이라고 부릅니다. 이 장의 본체는 이런 편향을 찾아내고, 통제할 수 있는 만큼 통제된 뒤, 남은 불확실성을 정직한 보고 문구로 옮기는 훈련입니다.

세 문제를 준비했습니다. 문제 24는 채널 비교를 연령 구성으로 층화해 심슨의 역설을 점검하고, 문제 25는 반품 발생 시각이 없다는 제약 아래 주문 시각을 대칭으로 부여하는 프록시를 설계하며, 문제 26은 이분 비교 대신 할인 강도 3구간의 용량-반응을 봅니다. 필요한 개념은 그때그때 쉬운 말로 풀고, 계산은 모두 판다스와 넘파이로 직접 구현합니다.

모든 문제는 1장 문제 01에서 도출한 표준 순매출 원장(중복 제거, `order_datetime` 정제, 상반기 한정, `canceled · returned` 제외)을 공통 기준으로 씁니다. 유효 주문 168,312건, 상반기 순매출 46,608,821,601원이 검증 기준입니다.

### 문제 24 앱 vs 웹 성과의 구성 보정 비교

난이도: ★★★★★☆

#### 상황

CRM팀 회의에 "앱 고객이 웹 고객보다 객단가가 높으니 앱 전환에 마케팅 예산을 몰자"는 보고가 올라왔습니다. 근거는 채널별 객단가(AOV) 표 한 장입니다. 그러나 데이터 분석 담당인 당신은 곧바로 의심이 듭니다. 앱을 주로 쓰는 고객과 웹을 주로 쓰는 고객은 연령대 구성부터 다를 수 있고, 그러면 "앱이 낫다"가 아니라 "젊은 층이 많이 쓰는 채널이 낫다"일 수도 있습니다. CMO는 예산을 옮기기 전에 이 비교가 공정한지 검증하라고 지시했습니다.

## 과제

1. 채널별 AOV와 구매 빈도(고객당 주문수)를 단순 비교해 보고서가 제기한 주장을 먼저 재현합니다.
2. 채널별 연령대 구성을 대조하고, 같은 연령대끼리만 채널을 비교하는 **층화 비교**로 재검증합니다.
3. 층화 후에도 차이가 유지되는지(심슨의 역설 여부)를 판정하고, 웹의 연령 구성으로 앱 AOV를 재가중해 구성 보정치를 계산합니다.
4. 제출물: 단순 비교표, 채널별 연령 구성표, 층화 AOV 비교표, 구성 보정치, 그리고 수정된 결론 문구.

## 사용 데이터

`orders` (`channel`:customer\_id), `order_items` (금액 산출), `customers` (`birth_date`로 연령대). 이번 문제의 품질 문제는 `birth_date` 결측(384명)과, 그로 인해 연령대를 부여할 수 없는 주문입니다. 연령 층화 대상에서 이들은 제외하되 몇 건인지 보고합니다.

## 힌트

AOV는 주문 단위 지표이므로 라인 금액을 주문 단위로 먼저 합산한 뒤 평균을 냅니다. 연령은 고객 단위 속성이므로 `customer_id` 로 붙입니다. 층화 비교는 `groupby(["age_band", "channel"])`로 셀을 만든 뒤, 각 셀의 표본 수를 반드시 함께 봅니다.

## 문제 25 반품 경험이 재구매에 남기는 흔적

난이도: ★★★★★☆

## 상황

CS팀과 MD팀이 부딪쳤습니다. CS팀은 "반품을 겪은 고객은 실망하고 떠난다"고 하고, MD팀은 "반품을 잘 처리해 주면 오히려 신뢰가 쌓여 충성도가 오른다"고 맞섭니다. 데이터로 심판해 달라는 의뢰입니다. 그런데 큰 제약이 있습니다. 데이터에는 반품이 실제로 발생한 시각이 없습니다. 우리가 아는 것은 주문 시각과 그 주문의 최종 상태(`returned`)뿐입니다. 이 제약을 다루는 프록시 설계가 이 문제의 진짜 과제입니다.

## 과제

1. 1~4월 중 `returned` 주문이 처음 발생한 고객을 반품 경험군으로, 같은 기간 `returned` 가 전혀 없이 `delivered` 주문을 가진 고객을 비교군으로 구성합니다.
2. 두 군 모두에 **기준 시점**을 대칭으로 부여합니다. 경험군은 첫 반품 주문의 주문 시각, 비교군은 같은 기간의 무작위 1개 `delivered` 주문 시각(시드 고정)을 기준 시점으로 씁니다. 반품 발생 시각은 미관측이므로 주문 시각은 프록시임을 명시합니다.
3. 기준 시점 이후 60일 재구매율을 두 군에서 비교하되, 기준 시점 이전 구매 활동 수준(유효 주문수)이 비슷하도록 층화합니다.
4. 제출물: 층화 전후 재구매율 대조, 판정, 프록시의 한계 주석.

## 사용 데이터

`orders` (상태·시각). 비교군의 기준 주문을 무작위로 고르므로 `random_state=42` 로 재현성을 확보합니다. 두 군의 활동 수준 분포가 다르다는 점(반품 경험군이 더 활발함)이 이 문제에서 만나는 핵심 편향입니다.

## 힌트

두 군에 같은 규칙("기준 시점 이후 60일")을 대칭으로 적용해야 공정합니다. 비교군에 기준 시점이 없으면 "이후 60일"을 정의할 수 없으므로, 비교군에도 인위적 기준 시점을 무작위로 부여합니다. 활동 수준은 기준 시점 이전 유효 주문수로 재고, 이것으로 층화합니다.

## 문제 26 할인 첫 구매 고객은 남는가

난이도: ★★★★★☆

## 상황

"첫 구매를 할인으로 유도하면 할인만 먹고 떠난다"는 오랜 통념이 프로모션 회의마다 반복됩니다. 이번 분기 신규 획득 예산을 짜는 프로모션 회의에서 그로스 리드가 이 통념을 근거로 첫 구매 할인 상한을 낮추자고 제안했고, CMO는 결정을 미루며 당신에게 검증을 의뢰했습니다. "할인이 클수록 정말 빨리 떠나는지, 얼마까지의 할인이면 손해가 아닌지 데이터로 답을 달라"는 것입니다. 그런데 이 통념은 대개 "할인 고객 대 정가 고객"의 이분 비교로 뒷받침되는데, 이 비교는 거칠고 결론을 과장하기 쉽습니다. 이번에는 이분 비교가 아니라 **할인 강도에 따른 용량-반응**으로 접근합니다. 할인이 클수록 정말 더 빨리 떠나는가, 그리고 할인으로 시작한 고객은 이후에도 계속 할인만 찾게 되는가를 봅니다.

## 과제

1. 1~3월 첫 구매 고객의 첫 주문 할인 강도(라인 수량 가중 평균 할인율)를 3구간(정가 0%, 저할인 0~10%, 고할인 10%+)으로 나눕니다.
2. 구간별 90일 재구매율의 기울기(용량-반응)를 확인하고, 재구매 고객의 재구매 주문 할인 이용률을 구간별로 비교해 할인 의존 형성 여부를 봅니다.
3. 첫 구매 카테고리별 총화해 기울기의 강건성을 확인하고, 구간 경계 민감도를 한 번 점검한 뒤 할인 유도 획득의 허용 상한을 조건부로 권고합니다.
4. 제출물: 할인 강도 구간별 90일 행동 대조표(재구매율 기울기+할인 의존)와 허용 상한 조건부 권고.

## 사용 데이터

`orders`, `order_items` (할인·수량), `products` (첫 구매 카테고리, `category` 공백 정제). 이 데이터는 대부분의 주문에 할인이 붙어 있어 정가(0%) 구간의 표본이 매우 작다는 점이 함정입니다.

## 힌트

할인 강도는 주문 안에서 수량 가중 평균으로 계산합니다( $\text{sum}(\text{수량} \times \text{할인}) / \text{sum}(\text{수량})$ ). 수량 합이 0인 주문은 분모가 0이 되므로 단순 평균으로 대체합니다. 재구매 할인 이용률은 재구매자 각자의 "할인 사용 재구매 주문 비율"을 평균합니다.



## 제10장 대용량 로그 마케팅 파이프라인

지금까지 아홉 개 장에서 순매출 원장, 채널 성과, RFM 세분화, 코호트 리텐션, 퍼널 전환, LTV, 시즌성, 준실험적 비교까지 마케팅 분석의 거의 모든 무기를 다뤘습니다. 그런데 실무에서 이 분석들을 한 번 만들고 끝내는 경우는 없습니다. 매달, 매주, 심지어 매일 같은 표를 다시 뽑아야 합니다. 마지막 장의 무대는 바로 그 반복입니다. 분석 서버가 아니라 개인 노트북에서, 100만 행짜리 행동 로그를 매번 열어 가며 리포트를 손으로 다시 만드는 팀이 있습니다. 이들에게 필요한 것은 새로운 지표가 아니라 "무겁지 않게, 그리고 다시 돌려도 같은 값이 나오게" 만드는 공학입니다.

이 장의 데이터 주인공은 `web_logs.csv` 입니다. 조회·검색·장바구니·구매 이벤트 100만 행으로, 그냥 읽으면 200MB가 넘게 메모리를 차지합니다. 노트북에서 여러 데이터프레임을 동시에 다루다 보면 이 한 파일이 작업을 멈추게 만듭니다. 그래서 먼저 이 로그를 가볍게 만드는 표준을 세우고(문제 27), 아예 전량을 올리지도 않고 처리하는 청크 파이프라인을 만들고(문제 28), 이를 응용해 매주 도는 상품 관심 스코어 파이프라인을 만듭니다(문제 29). 마지막 문제 30은 이 책 전체의 총정리입니다. 앞 장에서 만든 지표 다섯 종을 적재부터 저장까지 함수 하나로 묶어, 인자로 달만 바꾸면 매달 자동으로 도는 월간 리포트 파이프라인을 완성합니다.

한 가지 미리 약속할 것이 있습니다. 이 장의 메모리 수치(`memory_usage(deep=True)`)와 시간 수치(`time.perf_counter`)는 모두 실제 실행에서 나온 값을 그대로 옮긴 것입니다. 절대값은 컴퓨터·디스크·판다스 버전에 따라 다릅니다. 그러니 "몇 MB", "몇 초"라는 숫자 자체가 아니라 **단계마다 얼마나 줄고 몇 배 빨라지는가 하는 경향**이 결론입니다. 여러분의 노트북에서 절대값은 달라도 방향은 같게 재현될 것입니다.

### 문제 27 100만 행 로그 메모리 진단과 최적화

난이도: ★★☆☆☆

#### 상황

데이터팀에 "web\_logs만 열면 노트북이 버벅인다"는 불만이 쌓였습니다. 분석 서버 예산은 없고, 당분간 각자 노트북으로 로그를 다뤄야 합니다. 팀 리드가 여러분에게 "그냥 읽지 말고, 가볍게 읽는 표준을 만들어서 팀에 배포하라"고 요청했습니다. 감이 아니라 실측으로, 어떤 옵션이 얼마나 메모리를 줄이는지 근거를 붙여야 합니다.

## 과제

1. 아무 옵션 없이 `read_csv` 로 적재했을 때의 메모리 사용량을 `memory_usage(deep=True)` 로 실측하고, 어느 열이 무거운지 열별로 진단합니다.
2. 숫자열 다운캐스트, 저카디널리티 문자열의 `category` 변환, `usecols` 선택 적재를 단계적으로 적용하며 각 단계의 절감폭을 실측합니다.
3. `category` 가 유리한 열과 불리한 열을 실측으로 구분합니다.
4. 팀 배포용 표준 적재 함수와 before/after 절감 요약표를 제출합니다.

## 사용 데이터

`web_logs.csv` (100만 행): `log_id`, `customer_id` (결측 존재), `event_time`, `event_type` (view/search/cart/purchase), `product_id` (검색 이벤트는 결측), `session_id`. 여기서 만날 문제는 "문자열 열이 메모리를 압도적으로 많이 먹는다"는 점입니다.

## 힌트

`memory_usage(deep=True)` 는 문자열의 실제 바이트까지 셉니다( `deep=False` 는 포인터만 세어 과소평가합니다). `category` 는 고유값이 행수보다 훨씬 적을 때만 이득입니다. 거의 행마다 값이 다른 열은 오히려 손해라는 것을 직접 재 보세요.

## 문제 28 청크 집계로 일별 활성 고객 산출

난이도: ★★★★★☆

## 상황

로그는 앞으로 더 커집니다. 지금은 100만 행이지만 내년이면 노트북 메모리에 아예 안 올라갈 규모가 됩니다. 그로스팀은 매일 일별 활성 고객수(DAU)와 이벤트 요약을 봐야 하는데, "전량을 메모리에 올리지 않고도 DAU를 뽑는" 파이프라인이 필요합니다. 여러분이 그 청크 처리 표준을 만들어야 합니다.

## 과제

1. `read_csv(chunksize=)` 로 청크를 순회하며 일자별 방문 고객 집합을 점진적으로 누적합니다. 청크 경계를 넘나드는 중복 고객 문제를 올바르게 처리하는 것이 핵심입니다.

2. 일별 DAU와 이벤트 유형별 건수를 산출하고, 전량 적재 결과와 대조해 정확성을 검증합니다.
3. 청크 크기를 두 개 이상 바꿔 처리 시간을 실측 비교하고 권장 청크 크기를 제안합니다.

## 사용 데이터

`web_logs.csv` 의 `customer_id` · `event_time` · `event_type` 세 열만 사용합니다. `customer_id` 가 결측인 로그(익명 방문)는 DAU 분모에서 제외합니다. 누가 방문했는지 특정할 수 없기 때문입니다.

## 힌트

DAU는 "그날의 고유 고객 수"입니다. 청크마다 `nunique()` 를 세어 더하면 안 됩니다. 같은 고객이 여러 청크에 흩어져 있으면 여러 번 세어집니다. 정답은 날짜별로 고객 id를 **집합(set)**에 누적한 뒤, 마지막에 집합 크기를 세는 것입니다.

## 문제 29 로그 기반 상품 관심 스코어 파이프라인

난이도: ★★★★★☆

## 상황

추천 시스템 도입은 다음 분기 과제인데, 그 전에 MD팀이 "지금 뜨는 상품"을 매주 가볍게 뽑아 보고 싶어 합니다. 조회·장바구니·구매 이벤트를 가중 합산한 관심 스코어를, 100만 행 로그에서 돌아가는 재실행 가능한 파이프라인으로 만들어 달라는 의뢰입니다. 매주 함수 한 번만 호출하면 최신 상위 상품 리포트가 나와야 합니다.

## 과제

1. 청크 순회로 상품×이벤트 유형 집계를 누적하고 가중 스코어(view 1·cart 3·purchase 5, 가중치 가정 명시)를 산출합니다.
2. 최근성 반영(6월 이벤트 1.5배)을 추가해 "지금 뜨는" 성격을 부여합니다.
3. 상위 20 상품에 `products`를 결합해 카테고리·가격을 붙인 추천 후보 리포트를 함수 한 번 호출로 재생성 가능하게 만듭니다.

## 사용 데이터

`web_logs.csv` 와 `products.csv` . 검색(search) 이벤트는 `product_id` 가 결측이므로 상품 스코어 대  
상에서 제외합니다. `products.category` 에는 앞뒤 공백 오염이 있어 정제가 필요합니다.

## 힌트

가중치는 비즈니스 가정입니다. 반드시 명시하고, 가정을 바꿨을 때 순위가 얼마나 흔들리는지  
민감도를 한 번 확인하세요. 청크마다 상품×유형×(최근월 여부) 건수를 누적해 두면, 나중에 가  
중치만 바꿔 스코어를 다시 계산할 수 있어 재읽기가 필요 없습니다.

## 문제 30 월간 마케팅 지표 자동화 파이프라인

난이도: ★★★★★☆

## 상황

이 책에서 만든 지표들, 즉 월 순매출·채널별 객단가·신규 매출 비중·리텐션·퍼널 전환율을 매달  
손으로 다시 만드는 것은 지속 가능하지 않습니다. 실수도 생기고 시간도 잡아먹습니다. CMO가  
"매달 1일에 버튼 하나로 도는 월간 리포트"를 요구했습니다. 이 마지막 문제는 새 지표를 만드  
는 것이 아니라, 앞서 만든 지표들을 **적재→정제→지표→저장까지 한 번에 도는, 다시 돌려도 같  
은 값이 나오는 구조로 총정리하는 것**입니다.

## 과제

1. 적재(dtype·기간)→정제(중복·타입·상태 규칙)→핵심 지표 5종(월 순매출, 채널별 AOV, 신  
규 매출 비중, M+1 리텐션, 퍼널 전환율)→CSV 저장을 함수들로 분리해  
`run_monthly_report(month)` 하나로 실행합니다. M+1 리텐션은 "전월(m-1) 첫 구매 코호트  
가 당월(m)에 재구매한 비율"로 정의를 고정합니다.
2. 5월과 6월을 각각 인자로 실행하고, 재실행으로 동일하게 재현됨을 확인합니다.
3. 각 지표 함수에 자가 검증(`assert`)을 내장하고, 검증 실패 시 중단하는 운영 수칙을 명시  
합니다.

## 사용 데이터

`orders` · `order_items` · `customers` · `products` · `web_logs` 전부. 표준 순매출 원장(1장 문제 01에서 도  
출한 기준: 중복 제거, `order_datetime` 타입 오염 제거, 기간 밖 이상값 제거, canceled·returned  
제외, 라인 금액 = `quantity×unit_price×(1-discount)`)을 그대로 씁니다.

## 힌트

"매달 도는" 파이프라인의 함정은 마지막 달입니다. M+1 리텐션을 "당월 코호트가 다음 달에 재구매한 비율"로 정의하면, 6월 리포트를 만들 때 아직 오지 않은 7월 데이터가 필요해 계산이 불가능해집니다. 그래서 "전월 코호트가 당월에 재구매"로 방향을 뒤집습니다. 이러면 당월까지의 데이터만으로 항상 계산됩니다. 전역 변수 없이 인자로만 동작하게 만들어야 아무 달이나 넣어도 됩니다.