

SEMI PROJECT 안내서

# 머신러닝 기반 데이터 분석 프로젝트

4개의 공개 데이터셋 분석, 문제 정의부터 전처리·모델링·성능평가에 이르는 전체 분석 과정을 직접 수행

분류

분류

군집

회귀

# 과제 목적

최근 산업 전반에서 데이터 기반 의사결정 역량이 핵심 경쟁력으로 부상하고 있다. 본 과제는 실제 공개 데이터셋을 활용해 분석 전 과정을 직접 설계·수행하는 것을 목표로 한다.

1

## 고차원 · 대규모 데이터 탐색

수백 개 변수 규모의 데이터를 통계적으로 이해하고, 시각화를 통해 특성과 구조를 파악한다.

2

## 전처리 및 불균형 데이터 처리

결측치·이상치 처리, 파생 변수 생성, 클래스 불균형 보정 (SMOTE 등) 기법을 적용한다.

3

## 모델링 및 성능 비교

문제 유형에 맞는 여러 모델을 학습시키고, 적절한 지표로 성능을 비교·검증한다.

4

## 하이퍼파라미터 최적화

Hyperopt 등 자동화 기법으로 모델 성능을 체계적으로 개선한다.

# 데이터셋 선택

아래 4개 데이터셋 전체를 프로젝트를 진행

1

분류 (이진)

## Santander Customer Satisfaction

약 370개 익명화 변수로 구성된 은행 고객 데이터. 만족 여부 (TARGET)를 예측하는 이진 분류 문제를 설계하라.

2

분류 (이진)

## Credit Card Fraud Detection

28개 PCA 변수와 거래 정보로 구성된 극도로 불균형한 데이터. 사기 거래 탐지 모델을 구축하라.

3

군집 (비지도)

## Opinosis Opinion / Review

UCI 리뷰 텍스트 데이터셋. 벡터화 및 클러스터링 기법을 적용해 의미 있는 리뷰 그룹을 도출하라.

4

회귀

## Mercari Price Suggestion

중고거래 플랫폼 상품 텍스트 데이터. 텍스트 특징을 활용해 적정 판매 가격을 예측하라.

# 수행 과업

선택한 데이터셋에 대해 아래 절차를 모두 수행하고, 각 단계의 근거와 결과를 보고서에 기록한다.

## 01

### 데이터 이해 및 EDA

데이터 출처·구조·변수 특성을 파악하고, 기술통계·상관관계·이상치를 시각화로 분석한다.

## 02

### 데이터 전처리

결측치·이상치 처리, 중복/상관 변수 제거, 스케일링, 클래스 불균형 보정 등을 수행한다.

## 03

### 모델링 및 비교

문제 유형에 맞는 3개 이상의 모델(또는 기법)을 적용하고 결과를 비교한다.

## 04

### 하이퍼파라미터 최적화

Hyperopt 등을 활용해 최적 파라미터를 탐색하고, 적용 전/후 성능을 비교한다.

## 05

### 성능 평가 및 해석

문제 유형에 맞는 평가지표(ROC-AUC, F1, RMSLE, Silhouette 등)로 최종 모델을 선정하고 해석한다.

## 06

### 결론 및 회고 작성

분석 결과가 갖는 의미와 한계를 정리하고, 향후 개선 방향을 제시한다.

# 제출물 및 평가기준

아래 형식을 갖춰 제출하며, 평가는 다음 기준에 따라 이루어진다.

## 제출물

- 분석 보고서 pdf  
(서론·데이터소개·EDA·전처리·모델링·결과·결론·회고 순 구성)
- 함수화된 분석 코드 (전처리·모델링·평가 함수 포함)-압축 ipynb
- 핵심 결과를 요약한 발표자료 ppt

## 일정

- 1차 정리 : 2026.08.19 ~ 2026.08.28(금)
- 2차 정리 : 2026.08.31 ~ 2026.09.07(월) 완료
  - 2차 정리 기간중 수업 진행 예정

## 평가기준

- 데이터 이해도 및 EDA의 깊이 캐글에 있다고?
- 전처리 방법의 타당성과 근거 제시
- 모델 비교 논리와 지표 선정의 적절성
- 최적화 적용 여부 및 성능 개선 정도 성능 비교
- 결과 해석의 명확성과 결론의 완성도